

Duale Hochschule Baden-Württemberg Mosbach

Bachelorarbeit

Self-Supervised Learning zur Phishing-Detektion – Konzeption, prototypische Entwicklung und Evaluation eines lernbasierten Klassifikationssystems

Studiengang Wirtschaftsinformatik

Bearbeitungszeitraum	06. Juli 2026 – 30. September 2026
Verfasser	Chris David Kaufmann
Matrikelnummer, Kurs	7940617, MOS-WWI23A
Studiengangsleiter	Prof. Dr. Dirk Palleduhn
Wissenschaftliche Betreuung	Varvara Glivici-Cotruta
Ausbildungsunternehmen	Ihre Volksbank eG Neckar Odenwald Main Tauber Franken-Passage 2, 97941 Tauberbischofsheim
Betriebliche Betreuung	Daniela Keidel

13. September 2026

Zusammenfassung

Diese Arbeit untersucht, ob eine zusätzliche selbstüberwachte Anpassung bereits vortrainierter Transformer den Bedarf an gelabelten Trainingsdaten für die Phishing-Webseitenerkennung verringert und eine ressourcenschonende Verarbeitung unterstützt. Auf PhreshPhish werden vier Repräsentationsvarianten verglichen: unveränderte Basisencoder sowie Task-Adaptive Pretraining (TAPT) für URL, HTML-Text oder beide Eingabemodalitäten. Lineare und nichtlineare Probes verwenden sieben verschachtelte Labelbudgets von 2.000 bis 200.000 Webseiten. Die finale Evaluation umfasst 168.060 Webseiten sowie vier überlappende Teilmengen mit Domain-, Template- oder Zeitbedingungen. Schwellen werden auf einem getrennten Bestand von 50.000 legitimen Webseiten für eine Ziel-False-Positive-Rate von 0,5 % kalibriert.

Die kombinierte Anpassung RUT verbessert gegenüber unveränderten Encodern bei 20.000 Trainingslabels die mittlere True-Positive-Rate auf dem vollständigen Testbestand um 6,08 Prozentpunkte (zehn gepaarte Läufe; 95-%-Konfidenzintervall [5,38; 6,79]). 50.000 Labels bilden die kleinste untersuchte Budgetstufe, die die festgelegte Nichtunterlegenheitsentscheidung gegenüber den mit 200.000 Labels trainierten R0- und TF-IDF/XGBoost-Referenzen über alle fünf Bedingungen erfüllt. Die damit verbundene Reduktion um 75 % betrifft die Downstream-Trainingslabels; Labels für Stichprobenauswahl, Entwicklung und Kalibration sind darin nicht enthalten.

Auf dem externen Putra-Datensatz steigt die über 200 bis 2.000 Labels integrierte Average-Precision-Lernkurve durch RUT um 2,54 Prozentpunkte. Eine weitere MLM-Anpassung auf dem frühen Putra-Bestand verschlechtert diese Größe hingegen um 1,14 Prozentpunkte. Der Nutzen zusätzlicher Anpassung ist somit korpus- und protokollabhängig. Ein multimodaler Prototyp aus URL, HTML-Text und DOM erreicht 96,12 % TPR bei 0,666 % FPR. Seine URL-first-Kaskade erreicht 95,77 % TPR, eskaliert 14,93 % der Testseiten und steigert den gemessenen In-Memory-Durchsatz von 183,2 auf 447,0 Seiten pro Sekunde.

Die Ergebnisse stützen einen begrenzten Nutzen von TAPT für Label-Effizienz und gestufte Verarbeitung. Feste TAPT-Checkpoints, nachträglich ergänzte Analysen, überlappende Testbedingungen und die retrospektive externe Evaluation begrenzen die Verallgemeinerbarkeit. Laufzeitmessungen erfassen den aufbereiteten Modellpfad auf einer GPU und keine vollständige betriebliche Verarbeitungskette.

Abstract

This thesis examines whether additional self-supervised adaptation of pretrained transformers reduces the labelled training data required for phishing website detection and supports efficient processing. Four representation variants are compared on PhreshPhish: unchanged base encoders and task-adaptive pre-training (TAPT) of the URL encoder, the HTML text encoder, or both. Linear and nonlinear probes use seven nested label budgets ranging from 2,000 to 200,000 websites. Final evaluation covers 168,060 websites and four overlapping subsets defined by domain, template, or time conditions. Thresholds are calibrated on a separate set of 50,000 legitimate websites for a target false positive rate of 0.5%.

At 20,000 training labels, the combined adaptation RUT improves mean true positive rate over unchanged encoders by 6.08 percentage points on the complete test set (ten paired runs; 95% confidence interval [5.38, 6.79]). A budget of 50,000 labels is the smallest tested level meeting the specified noninferiority decision against both the R0 and TF-IDF/XGBoost references trained with 200,000 labels across all five evaluation conditions. The resulting 75% reduction concerns downstream training labels; labels used for sample selection, development, and calibration are excluded from this accounting.

On the external Putra dataset, RUT improves the integrated average precision learning curve over budgets of 200 to 2,000 labels by 2.54 percentage points. Additional masked language modelling on the early Putra data instead decreases this measure by 1.14 percentage points. Benefits of further adaptation therefore depend on the corpus and training protocol. A multimodal prototype combining URL, HTML text, and DOM reaches a true positive rate of 96.12% at a false positive rate of 0.666%. Its URL-first cascade reaches a true positive rate of 95.77%, escalates 14.93% of test websites, and increases measured in-memory throughput from 183.2 to 447.0 websites per second.

The results support a qualified benefit of TAPT for label efficiency and staged processing. Fixed TAPT checkpoints, analyses added after initial experiments, overlapping evaluation conditions, and retrospective external evaluation limit generalisability. Runtime measurements cover the prepared model path on one GPU and do not represent a complete operational processing pipeline.

Erklärung zur Nutzung von Hilfsmitteln aus dem Bereich der Künstlichen Intelligenz

Ich erkläre (Zutreffendes bitte ankreuzen), dass

- (1) ☐ ich bei der Erstellung dieser Arbeit keine Hilfsmittel aus dem Bereich der Künstlichen Intelligenz genutzt habe,
- (2) ☒
- Teile dieser Arbeit unter Verwendung von Hilfsmitteln aus dem Bereich der Künstlichen Intelligenz erstellt wurden (z. B. Abbildungen, Text und/oder Quellcode),
 - ich alle Inhalte, die unter Verwendung von Hilfsmitteln aus dem Bereich der Künstlichen Intelligenz erstellt wurden, im Text sowie den zugehörigen Artefakten (z. B. Quellcode) an den betreffenden Stellen entsprechend gekennzeichnet habe,
 - mir bewusst bin, dass ich als Autor*in dieser Arbeit die Verantwortung für die in ihr gemachten Angaben und Aussagen trage.

Ort, Datum

Unterschrift

Verwendete KI-Hilfsmittel

Nach Angabe des Verfassers wurden ChatGPT und teilweise Claude über die unten genannten Arbeitsschritte hinweg eingesetzt. Der Verfasser hat die Inhalte bearbeitet und trägt die Verantwortung für ihre Auswahl, Prüfung und Verwendung. Die Angabe beansprucht keine vollständig ohne KI erzeugte Text-, Code- oder Bildfassung. Die Fußzeilen kennzeichnen den umfassenden Einsatz an den betreffenden Textstellen; Abbildungsnachweise und Kommentare in den beigefügten Codeartefakten ergänzen diese Kennzeichnung.

Nr.	Arbeitsschritt	Produkt und Vorgehensweise
1	☒ Ideen und Konzeption	ChatGPT, teilweise Claude: Ideen und Untersuchungsaufbau; Codex: betrieblicher Prozess- und Pilotentwurf.
2	☒ Methoden und Modelle	ChatGPT, teilweise Claude: Unterstützung bei Auswahl, Einordnung und Umsetzung.
3	☒ Datensammlung und Analyse	ChatGPT, teilweise Claude: Unterstützung bei Datenaufbereitung und Auswertung.
4	☒ Quellcode	ChatGPT, teilweise Claude: Code und Notebooks; Codex: Prüfskripte und Betriebsrechner.
5	☒ Textstruktur	ChatGPT, teilweise Claude: Unterstützung bei Gliederung und Aufbau.
6	☒ Textformulierung	ChatGPT, teilweise Claude: Entwürfe und Umformulierungen; Überarbeitung durch den Verfasser.
7	☒ Redaktion	ChatGPT, teilweise Claude; zusätzlich Codex: sprachliche und fachliche Revision.
8	☒ Visualisierungen	ChatGPT, teilweise Claude: Abbildungen; Codex: Reproduktion empirischer Diagramme und betriebliche Prozessgrafik.
9	☒ Interpretation und Validierung	ChatGPT, teilweise Claude; Codex: Code-, Quellen- und Zahlenprüfung sowie ergänzende Reproduktionen.
10	☒ Sonstiges	Codex: Rekonstruktion des LaTeX-Projekts, Kompilierung und Layoutprüfung.

Produkte: ChatGPT – <https://chatgpt.com/>; Claude – <https://claude.ai/>; Codex – <https://openai.com/codex/>. Einzelne Modellversionen früherer Nutzungen wurden nicht dokumentiert. Der abschließende Codex-Review erfolgte im September 2026.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

Abkürzungsverzeichnis	iii
Abbildungsverzeichnis	iv
Tabellenverzeichnis	v
Quellcodeverzeichnis	vi
1. Einleitung	1
1.1. Problemstellung und Motivation	1
1.2. Zielsetzung und Forschungsfragen	2
1.3. Vorgehensweise und Methodik der Arbeit	3
2. Theoretische Grundlagen	4
2.1. Phishing-Webseiten als Anwendungsdomäne	4
2.1.1. Phishing und Social Engineering	4
2.1.2. URL-, HTML-Text- und DOM-Daten als Informationsgrundlage	4
2.1.3. Herausforderungen der automatisierten Erkennung	5
2.2. Lernbasierte Repräsentationen und Klassifikation	5
2.2.1. Numerische Repräsentation textueller Eingaben	5
2.2.2. Neuronale und graphbasierte Repräsentationsmodelle	7
2.2.3. Transformerbasierte Repräsentationsmodelle	8
2.2.4. Downstream-Klassifikation und multimodale Verarbeitung	10
2.3. Self-Supervised Representation Learning	10
2.3.1. Maskierte selbstüberwachte Lernziele	11
2.3.2. Kontrastives Repräsentationslernen	12
2.3.3. Task-Adaptive Pretraining	12
2.4. Evaluationsrahmen und Bewertungsmetriken	13
2.4.1. Klassifikations- und Betriebspunktmetriken	13
2.4.2. Generalisierung unter Distribution Shift	14
2.4.3. Statistische Auswertungsverfahren	15
2.4.4. Effizienz- und Betriebsmetriken	16
3. Stand der Forschung und Forschungslücke	17
3.1. Task-adaptive Repräsentationen und Label-Effizienz	17
3.2. Informationsgrundlage und Systemarchitektur	17
3.3. Generalisierung und betriebliche Evaluationsbedingungen	18
3.4. Forschungslücke und Einordnung der Arbeit	19
4. Methodisches Vorgehen und Systemkonzeption	20
4.1. Forschungsdesign und Untersuchungslogik	20

4.2.	Datengrundlage und Datenprotokoll	21
4.2.1.	Rollenpartitionierung und Leakage-Prävention	21
4.2.2.	Aufbereitung der Informationsmodalitäten	22
4.3.	Repräsentations- und Versuchsdesign	22
4.3.1.	Task-adaptive Repräsentationen R0, RU, RT und RUT	22
4.3.2.	Downstream-Probes, Labelbudgets und Referenzverfahren	23
4.4.	Evaluations- und Statistikdesign	24
4.4.1.	Kalibration und Evaluationsbedingungen	24
4.4.2.	Statistische Entscheidungsregeln	25
4.5.	Konzeption des prototypischen Klassifikationssystems	26
4.5.1.	Zielbild und Gesamtarchitektur	26
4.5.2.	Sequenzielle Komponentenablation	27
4.5.3.	URL-first-Kaskade und Frontend-Vergleich	28
4.6.	Freeze, Reproduzierbarkeit und Grenzen des Untersuchungsdesigns	29
5.	Implementierung	30
5.1.	Entwicklungs- und Ausführungsumgebung	30
5.2.	Implementierung der Datenverarbeitung	30
5.3.	Implementierung der Self-Supervised Repräsentationen	31
5.4.	Implementierung des multimodalen Deep-Systems	34
5.4.1.	Sequenzielle Komponentenablation	36
5.5.	Implementierung der Kaskade und Messinstrumentierung	36
5.6.	Artefaktbereitstellung und Reproduzierbarkeit	38
6.	Empirische Evaluation	39
6.1.	Versuchsrahmen	39
6.2.	FF1: Task-adaptive Repräsentationsanpassung	39
6.3.	FF2: Einfluss der Labelverfügbarkeit	41
6.4.	FF3: Erreichen des 200k-Referenzniveaus	43
6.5.	FF4: Inkrementeller Systembeitrag und URL-first-Verarbeitung	45
6.6.	Ergänzende Unsicherheits- und Prävalenzeinordnung	47
6.7.	Szenarioanalyse am eingefrorenen Betriebspunkt	48
7.	Diskussion und Schlussbetrachtung	49
7.1.	Interpretation und Beantwortung der Forschungsfragen	49
7.2.	Limitationen und Aussagegrenzen	52
7.3.	Betriebliches Einsatzkonzept und Handlungsempfehlung	53
7.4.	Fazit und Ausblick	57
	Literaturverzeichnis	58
A.	Ergänzende Implementierungs- und Prüfdetails	66
A.1.	Implementierungsauszüge	66
A.2.	Reproduktionsumfang	71

Abkürzungsverzeichnis

APWG	Anti-Phishing Working Group
AP	Average Precision
AULC	Area Under the Learning Curve
B95	Kleinstes geprüfetes Budget mit mindestens 95 % des eigenen 200k-Niveaus
BERT	Bidirectional Encoder Representations from Transformers
CAL	Kalibrationsmenge
CSIRT	Computer Security Incident Response Team
CUDA	Compute Unified Device Architecture
DAPT	Domain-Adaptive Pretraining
DEV	Development-Daten
DOM	Document Object Model
DUAL	System mit URL- und HTML-Text-Zweig
ENISA	European Union Agency for Cybersecurity
FF	Forschungsfrage
FINAL	Abschließende Testmenge
FN / FP	False Negative / False Positive
FPR / TPR	False Positive Rate / True Positive Rate
GCN	Graph Convolutional Network
GPU	Graphics Processing Unit
HTML	Hypertext Markup Language
KI	Künstliche Intelligenz; bei Intervallangaben: Konfidenzintervall
MLM	Masked Language Modeling
MLP	Multi-Layer Perceptron
N5 / N10	Fünf beziehungsweise zehn Wiederholungen
OOD	Out of Distribution
pp	Prozentpunkte
R0	URL- und Text-Basisencoder ohne zusätzliche TAPT-Anpassung
RU / RT / RUT	TAPT für URL / Text / beide Modalitäten
RoBERTa	Robustly Optimized BERT Pretraining Approach
SHA	Secure Hash Algorithm
SOC	Security Operations Center
SSL / SSLR	Self-Supervised Learning / Self-Supervised Representation Learning
SUP	Separater gelabelter Pool des Data Freeze
TAPT	Task-Adaptive Pretraining
TF-IDF	Term Frequency – Inverse Document Frequency
TN / TP	True Negative / True Positive
TRI	System mit URL-, HTML-Text- und DOM-Zweig
URL	Uniform Resource Locator
VRAM	Video Random Access Memory
XGBoost	Extreme Gradient Boosting

Abbildungsverzeichnis

2.1. Von diskreten Eingabeeinheiten zu gelernten Vektorrepräsentationen	6
2.2. Schematischer Aufbau eines mehrschichtigen neuronalen Netzes	7
2.3. Schematische graphbasierte Repräsentationsbildung einer DOM-Struktur	8
2.4. Grundprinzip des Self-Supervised Representation Learning	11
2.5. Schematisches Prinzip des Masked Language Modeling am Beispiel des HTML-Textzweigs	11
2.6. Schematisches Prinzip des kontrastiven Repräsentationslernens für URL–HTML-Paare .	12
4.1. Ableitung der Informationsmodalitäten und Evaluationsmetadaten aus einer Webseiten- instanz	22
4.2. Faktorielles Design der task-adaptiven Repräsentationsvarianten	23
4.3. Gesamtarchitektur des prototypischen Klassifikationssystems	27
4.4. Sequenzdiagramm der bedingten Verarbeitung in der URL-first-Kaskade	28
6.1. FF1: TPR der vier Repräsentationsvarianten mit linearer und MLP-Downstream-Probe. .	40
6.2. FF2: Lernkurven der Repräsentationsvarianten über die sieben Labelbudgets mit linearer und MLP-Probe.	42
6.3. FF3: Mittlere RUT-TPR über fünf Evaluationsbedingungen und ausgewählte Labelbud- gets, N10-Mittelwerte.	43
6.4. FF3: Schlechtester mittlerer TPR-Abstand von RUT gegenüber R0@200k und TF- IDF/XGBoost@200k über die fünf Evaluationsbedingungen.	45
6.5. FF4: Sequenzielle Komponentenablation und URL-first-Frontendvergleich von URL_BA SE und URL_TAPT.	46
7.1. Konzipierte Einbettung der Webseitenklassifikation in die fachliche Fallprüfung. Nur der grau hinterlegte Modellpfad wurde experimentell untersucht.	54

Tabellenverzeichnis

3.1. Einordnung des Untersuchungsdesigns in den Stand der Forschung.	19
4.1. Untersuchungsstufen und Funktion im Untersuchungsdesign.	20
4.2. Datenrollen des eingefrorenen Untersuchungsprotokolls.	21
4.3. Evaluationsbedingungen der abschließenden Generalisierungsbewertung.	25
6.1. FF1: DEV-Ergebnisse bei 20.000 Labels, Mittelwerte über fünf Wiederholungen.	40
6.2. FF2: Mittlere FINAL-TPR der linearen Probe über die Labelbudgets.	41
6.3. FF2: Mittlere FINAL-TPR der MLP-Probe über die Labelbudgets.	41
6.4. FF2: Externe Label-Effizienz von R0 und RUT auf dem Putra-Datensatz.	42
6.5. FF3: RUT bei 20k und 50k Labels gegenüber TF-IDF/XGBoost@200k, N10-Mittelwerte.	44
6.6. FF4: In-Memory-Benchmark des mit 200k Labels trainierten Vollsystems und seiner eingefrorenen URL-first-Kaskade.	46
6.7. Base-Rate-Sensitivität von $P_{\geq 90}$	47
6.8. Erwartete Fallzahlen je 10.000 auswertbaren Webseiten am eingefrorenen Betriebspunkt bei reinem Prior-Shift.	48
7.1. Gemessene Alternativen und daraus abgeleitete Einsatzentscheidung. TPR/FPR: FINAL; Durchsatz: DEV-In-Memory-Benchmark auf Tesla T4.	54
7.2. Vorgeschlagene Prüfkriterien für die betriebliche Weiterentwicklung; noch keine gemessene Freigabe.	56

Quellcodeverzeichnis

A.1. Zentraler Trainingsaufbau des URL-TAPT – gekürzter Originalausschnitt	66
A.2. Bestimmung der Development-basierten Kaskadenschwellen	67
A.3. Routingentscheidung der URL-first-Kaskade – gekürzter zusammenhängender Original- auszug	67
A.4. Deterministische Rangbildung für die Datenpartitionierung	67
A.5. Aufbereitung von HTML-Text und strukturellen Webseiteninformationen – gekürzter Ori- ginalausschnitt	68
A.6. Physische Entfernung der Klassenlabels aus dem SSL-Pool	69
A.7. Partielle Freigabe der Transformerencoder	69
A.8. GCN-basierte Repräsentation des statischen DOM – gekürzter Originalausschnitt	70
A.9. Rekonstruktionsverlust des DOM-SSL – gekürzter Originalausschnitt aus dem Trainings- loop	70
A.10. Kern der multimodalen DUAL-/TRI-Fusion – gekürzter Architekturausschnitt	71

1. Einleitung

1.1. Problemstellung und Motivation

Phishing zählt zu den dauerhaft relevanten Bedrohungen der digitalen Wirtschaft. Allein im ersten Quartal 2025 erfasste die Anti-Phishing Working Group mehr als eine Million Phishing-Angriffe; die im selben Bericht wiedergegebene Branchenanalyse von OpSec Security ordnet Online-Payment-Diensten sowie Finanz- und Bankdienstleistungen zusammen 30,9 % der von OpSec erfassten Angriffe zu (vgl. [APWG (2025), S. 3–4]).

Im Zentrum vieler Angriffe stehen manipulierte Webseiten, die vertrauenswürdige Dienste imitieren und Nutzer zur Preisgabe schützenswerter Informationen verleiten (vgl. [APWG (2025), S. 2]). Für ihre automatisierte Erkennung bilden insbesondere URL und HTML-Inhalt relevante Informationsquellen. Während die URL Domain-, Pfad- und Parameterinformationen enthält, stellt das HTML-Dokument textuelle, verlinkungsbezogene und strukturelle Eigenschaften der Webseite bereit (vgl. [Dalton et al. (2026), S. 2–3]).

Die Erkennung wird dadurch erschwert, dass sich Phishing-Kampagnen und Webseiten fortlaufend verändern. Generative Künstliche Intelligenz kann Angreifer zusätzlich bei der Erstellung maßgeschneiderter Kampagnen unterstützen (vgl. [ENISA (2024), S. 67]). Gleichzeitig entstehen regelmäßig neue Webseiten und Angriffsvarianten. Während Sperrlisten insbesondere bekannte Phishing-Webseiten erfassen, können lernbasierte Verfahren URL- und HTML-Eigenschaften zur Klassifikation bislang nicht beobachteter Webseiten nutzen (vgl. [Dalton et al. (2026), S. 1–3]). Eine hohe Leistung auf datensatznahen Testdaten erlaubt dabei noch keine belastbare Aussage über bislang unbekannte Webseiten. Ähnliche Seiten oder gemeinsame Phishing-Kits können in Trainings- und Testdaten auftreten und dadurch die Wiedererkennung bereits bekannter Strukturen begünstigen (vgl. [Dalton et al. (2026), S. 3]).

Für einen betrieblichen Einsatz ist die Klassifikationsleistung nicht losgelöst von den hierfür eingesetzten Ressourcen zu betrachten. Erstens ist relevant, welcher Anteil tatsächlicher Phishing-Webseiten bei einer niedrigen False-Positive-Rate weiterhin erkannt wird, da Fehlalarme legitime Webseiten betreffen und nachgelagerte Sicherheitsprozesse belasten können. Die False-Positive-Rate wird entsprechend auch als Qualitätskennzahl von Security Operations Centers gemeinsam mit Größen wie Eskalationen und Bearbeitungsaufwand betrachtet (vgl. [ENISA (2020), S. 7]).

Zweitens stellt die Verfügbarkeit gelabelter Trainingsdaten eine Ressourcengrenze dar. Die Beschaffung und zuverlässige Annotation hochwertiger Trainingsdaten verursacht zusätzlichen Aufwand und gilt als wesentlicher Engpass datengetriebener Systeme (vgl. [Roh et al. (2021), S. 1]). Drittens stellt sich bei einem leistungsstarken multimodalen Klassifikationssystem die Frage, wie der zusätzliche Informationsumfang technisch effizient genutzt werden kann. Für den Systementwurf ist damit relevant, ob eindeutige Fälle bereits auf Basis der URL-Repräsentation abgeschlossen werden können, während unsichere Fälle weiterhin die vollständige multimodale Verarbeitung durchlaufen. Vor dem Hintergrund begrenzter Budgets und fehlender IT-Sicherheitsspezialisten, wie sie insbesondere für kleine und mittlere Unternehmen berichtet werden, sind damit neben der maximalen Klassifikationsleistung auch der Bedarf an

1. Einleitung

gelabelter Supervision und die bedarfsgerechte Nutzung der verfügbaren Modellkomponenten relevant (vgl. [ENISA (2021), S. 14]).

Self-Supervised Representation Learning (SSLR) setzt an dieser Ausgangslage auf Ebene der Repräsentationsbildung an. Transformerbasierte Encoder können anhand ungelabelter Daten selbstüberwacht vortrainiert und anschließend für eine gelabelte Downstream-Aufgabe genutzt werden (vgl. [Devlin et al. (2019), S. 4171 und 4173–4175]). Darauf aufbauend kann das Vortraining gezielt auf den ungelabelten Trainingsdaten einer konkreten Zielaufgabe fortgesetzt werden. Gururangan et al. bezeichnen diese Weiteranpassung als Task-Adaptive Pretraining (TAPT) und zeigen über mehrere Aufgaben hinweg Verbesserungen gegenüber ausschließlich allgemein vortrainierten Modellen (vgl. [Gururangan et al. (2020), S. 8346–8347]). Für die Phishing-Webseitenerkennung ist damit zu untersuchen, welchen zusätzlichen Beitrag TAPT gegenüber bereits allgemein vortrainierten Repräsentationen leistet, wie sich dieser Beitrag bei unterschiedlicher Verfügbarkeit gelabelter Trainingsdaten verändert und wie die daraus entstehende Repräsentationsbasis in ein leistungsstarkes multimodales Klassifikationssystem überführt werden kann.

1.2. Zielsetzung und Forschungsfragen

Ziel der Arbeit ist die Konzeption, prototypische Entwicklung und empirische Evaluation eines lernbasierten Klassifikationssystems zur Erkennung von Phishing-Webseiten anhand von URL- und HTML-Daten. Neben der Klassifikationsleistung werden dabei der Umfang gelabelter Downstream-Supervision und die Verarbeitungstiefe des resultierenden Systems betrachtet.

Kapitel 7 konkretisiert die unterstützende Vorprüfung verdächtiger Webseiten für eine Sicherheitseinheit oder einen IT-Dienstleister. Das Einsatzkonzept überträgt die Modellwerte auf angenommene Prüfvolumente; betriebliche Abläufe und Kosten wurden nicht erhoben.

Zunächst wird untersucht, welchen zusätzlichen Beitrag eine task-adaptive selbstüberwachte Anpassung gegenüber bereits allgemein vortrainierten Encodern leistet und wie sich dieser Beitrag mit der verfügbaren gelabelten Supervision verändert. Darauf aufbauend wird geprüft, ab welchem reduzierten Labelbudget das Leistungsniveau vollständig mit 200.000 Labels trainierter Referenzverfahren erreicht wird. Eine klassische TF-IDF/XGBoost-Pipeline dient ergänzend als Vergleichsverfahren; da sich dabei sowohl Repräsentation als auch Klassifikator ändern, können Leistungsunterschiede nicht allein der task-adaptiven Anpassung zugeschrieben werden.

Die Bewertung erfolgt auf dem vollständigen Testbestand sowie auf separat gebildeten domain-, template- und zeitbezogenen Teilmengen an einem auf einer getrennten Kalibrationsmenge bestimmten Low-FPR-Betriebspunkt. Anschließend wird die ausgewählte Repräsentationskonfiguration um eine strukturelle DOM-Repräsentation und multimodale Fusion zum TRI-Vollsystem erweitert. Darauf aufbauend wird untersucht, wie sich dieses System über eine URL-first-Kaskade gestuft einsetzen lässt, wobei unsichere Fälle weiterhin vollständig multimodal verarbeitet werden.

Aus dieser Zielsetzung ergibt sich folgende zentrale Forschungsfrage:

Welchen Beitrag leistet Self-Supervised Representation Learning für ein lernbasiertes Klassifikationssystem zur Erkennung bislang ungesehener Phishing-Webseiten und wie lässt sich dieser Ansatz durch task-adaptive Repräsentationsanpassung sowie multimodale Systemkomponenten weiterentwickeln?

Zur differenzierten Beantwortung werden vier Unterfragen formuliert:

- FF1:** Wie verändert die task-adaptive Anpassung der URL- und HTML-Text-Repräsentationen deren Downstream-Nutzbarkeit gegenüber nicht zusätzlich adaptierten vortrainierten Encodern?
- FF2:** Wie verändert sich der Zusatznutzen der task-adaptiven Repräsentationsanpassung bei unterschiedlicher Verfügbarkeit gelabelter Trainingsdaten und unterschiedlichen Downstream-Klassifikationsmechanismen?
- FF3:** Ab welchem reduzierten Labelbudget erreicht die task-adaptive RUT-Repräsentation über die untersuchten Evaluationsbedingungen hinweg ein nach den festgelegten Margen nicht unterlegenes Leistungsniveau gegenüber mit 200.000 Labels trainierten Referenzverfahren?
- FF4:** Wie verändern eine strukturelle DOM-Repräsentation, multimodale Fusion und eine kaskadierte URL-first-Verarbeitung die Erkennungsleistung und den Inferenzaufwand des prototypischen Klassifikationssystems?

1.3. Vorgehensweise und Methodik der Arbeit

Zur Beantwortung der Forschungsfragen wird ein empirisch-vergleichendes mit einem konstruktionsorientierten Vorgehen verbunden. Als Datengrundlage dient der öffentlich verfügbare PhreshPhish-Datensatz mit zeitlich verorteten URLs, gespeicherten HTML-Inhalten und Klassenlabels für legitime und phishingbezogene Webseiten (vgl. [Dalton et al. (2026), S. 1–4]).

Zunächst werden allgemein vortrainierte Basisencoder mit Varianten verglichen, bei denen die URL-Repräsentation, die HTML-Text-Repräsentation oder beide Informationszweige mittels TAPT auf ungelabelten Webseitendaten weiter angepasst werden. Ihre Downstream-Nutzbarkeit wird mit logistischer Regression und einem kleinen Mehrschicht-Perzeptron über sieben Labelbudgets untersucht. Kontrastives Repräsentationslernen wird ergänzend anhand eines vorgelagerten explorativen Versuchs eingeordnet.

FF3 vergleicht RUT über das gesamte Budgetraster mit $R0@200k$ und $TF-IDF/XGBoost@200k$. Für diese N10-Vergleiche werden Konfidenzintervalle, exakte Tests und korrigierte Nichtunterlegenheitsentscheidungen berichtet. Modell- und Systementwicklung nutzen DEV, die Schwellenbestimmung CAL und die Leistungsbewertung FINAL. Nachträglich ergänzte Analysen werden gesondert gekennzeichnet. Eine externe Putra-Auswertung ergänzt die Labelbudgetanalyse.

Komponentenablation und Frontend-Vergleich untersuchen anschließend das TRI-System und seine Kaskade anhand von Klassifikationsleistung, Latenz, Durchsatz, Speicherbedarf und Eskalation. Kapitel 2 und 3 begründen den Ansatz, Kapitel 4 und 5 erläutern die Umsetzung, Kapitel 6 und 7 präsentieren und diskutieren die Ergebnisse.

2. Theoretische Grundlagen

2.1. Phishing-Webseiten als Anwendungsdomäne

2.1.1. Phishing und Social Engineering

Phishing nutzt betrügerische E-Mails und Webseiten, um sensible Informationen zu erlangen; dazu können legitime Webseiten kopiert und für die Datenerfassung verändert werden (vgl. [Zhang et al. (2007), PDF-S. 1 und 3]). Die Täuschung beruht unter anderem darauf, dass Nutzer visuelle Inhalte als glaubwürdig wahrnehmen (vgl. [Dhamija et al. (2006), PDF-S. 1]).

Dhamija et al. untersuchten 22 Teilnehmende anhand von 20 Webseiten: 23 Prozent berücksichtigten browserbasierte Hinweise wie Adressleiste, Statusleiste oder Sicherheitsindikatoren nicht; die überzeugendste Phishing-Webseite täuschte 90 Prozent der Teilnehmenden (vgl. [Dhamija et al. (2006), PDF-S. 1]). Diese kleine Studie veranschaulicht die Täuschungswirkung, erlaubt aber keine Schätzung heutiger Erfolgsraten.

ENISA nennt Phishing für Juli 2024 bis Juni 2025 als häufigsten initialen Angriffsvektor und ordnet der breit gefassten Kategorie einschließlich Vishing, Malspam und Malvertising rund 60 Prozent der ausgewerteten Eintrittswege zu (vgl. [ENISA (2025a), S. 8]). Der Anteil bezieht sich somit nicht allein auf Phishing-Webseiten. Phishing-as-a-Service-Angebote erleichtern auch weniger versierten Akteuren die Durchführung von Kampagnen, etwa durch automatisiert erstellte Phishing-Kits und nachgebildete Anmeldeseiten (vgl. [ENISA (2025a), S. 11]).

Für den europäischen Finanzsektor wertete ENISA 488 öffentlich berichtete Sicherheitsvorfälle von Januar 2023 bis Juni 2024 aus; Kreditinstitute bildeten mit 46 % die am häufigsten betroffene Gruppe (vgl. [ENISA (2025b), S. 3]). Phishing, Smishing und Vishing richteten sich gegen Institute und Kunden; bei 36 % der betrachteten Social-Engineering-Vorfälle wurden primär Kreditinstitute imitiert (vgl. [ENISA (2025b), S. 13]).

Phishing-Webseiten können somit in unterschiedlichen inhaltlichen und technischen Ausprägungen auftreten. Für ihre automatisierte Erkennung sind insbesondere die unmittelbar auswertbaren Eigenschaften der URL und des HTML-Dokuments relevant, die im folgenden Abschnitt näher betrachtet werden.

2.1.2. URL-, HTML-Text- und DOM-Daten als Informationsgrundlage

URL und HTML-Dokument liefern unterschiedliche Informationen über dieselbe Webseite: Die URL beschreibt deren Adresse, der HTML-Inhalt ergänzt semantische und strukturelle Eigenschaften (vgl. [Opara et al. (2024), S. 2]). Die Arbeit nutzt diese Informationsquellen in getrennten Modellzweigen.

Yoon et al. verarbeiten URLs sowohl als numerisch repräsentierte Zeichenfolgen als auch über eine wortbasierte Darstellung (vgl. [Yoon et al. (2024), S. 6–7]). Die URL kann damit unabhängig vom HTML-Inhalt als sequenzielle Eingabe dienen.

Die Beziehungen zwischen HTML-Elementen lassen sich als Document Object Model (DOM) abbilden; Yoon et al. kombinieren einen HTML-DOM-Graphen mit URL-Repräsentationen (vgl. [Yoon et al. (2024), S. 2]). Im Folgenden werden entsprechend der textuelle HTML-Inhalt und die strukturelle DOM-Repräsentation unterschieden.

2.1.3. Herausforderungen der automatisierten Erkennung

Veränderungen von Phishing-Webseiten können die Übertragbarkeit zuvor trainierter Modelle einschränken (vgl. [Purwanto et al. (2022), S. 1498]). Eine hohe Leistung auf datensatznahen Testdaten genügt daher nicht als Nachweis der Erkennung zukünftiger Webseiten.

Ähnliche Instanzen in Training und Test können die gemessene Generalisierungsleistung begünstigen (vgl. [Dalton et al. (2026), S. 3]). Die Evaluation dieser Arbeit berücksichtigt deshalb zeitliche und strukturelle Trennungen. Zusätzlich wird die Erkennung bei niedriger False-Positive-Rate betrachtet, einem für die Phishing-Erkennung relevanten Betriebspunkt (vgl. [Purwanto et al. (2022), S. 1506]).

Auch im operativen Sicherheitsbetrieb zählt die False-Positive-Rate zu den Qualitätskennzahlen von Security Operations Centers und wird neben Kennzahlen wie der Anzahl von Eskalationen und dem Bearbeitungsaufwand pro Sicherheitsvorfall betrachtet (vgl. [ENISA (2020), S. 7]). Dieser Aspekt ist vor dem Hintergrund begrenzter betrieblicher Ressourcen besonders relevant, da fehlende Budgets und ein Mangel an IT-Sicherheitsspezialisten zu den identifizierten Herausforderungen kleiner und mittlerer Unternehmen zählen (vgl. [ENISA (2021), S. 14]).

Task-Adaptive Pretraining setzt das selbstüberwachte Vortraining auf ungelabelten Trainingsdaten einer konkreten Downstream-Aufgabe fort und kann deren Leistung verbessern (vgl. [Gururangan et al. (2020), S. 8346–8347]). Dies motiviert die Untersuchung einer solchen Anpassung für URL und HTML-Text.

2.2. Lernbasierte Repräsentationen und Klassifikation

2.2.1. Numerische Repräsentation textueller Eingaben

In termbasierten Vektorraummodellen werden Dokumente durch Vektoren dargestellt, deren Dimensionen den Termen eines Wörterbuchs entsprechen (vgl. [Manning et al. (2008), S. 120–121]). Term Frequency-Inverse Document Frequency (TF-IDF) kombiniert die Häufigkeit eines Terms im Dokument mit seiner inversen Dokumenthäufigkeit im Korpus und gewichtet dadurch im Dokument häufige, im Korpus seltene Terme stärker (vgl. [Manning et al. (2008), S. 118–119]).

Neuronale Modelle können diskreten Eingabeeinheiten trainierbare Vektoren zuordnen: Eine Lookup-Operation liest für jeden Vokabularindex den zugehörigen Merkmalsvektor aus einer trainierbaren Matrix aus (vgl. [Collobert et al. (2011), S. 2501]).

Für eine Eingabesequenz bilden die Vektoren der einzelnen Token die numerische Eingabe nachfolgender Netzwerkschichten (vgl. [Collobert et al. (2011), S. 2501]). Abbildung 2.1 veranschaulicht diesen Übergang schematisch.

2. Theoretische Grundlagen




Abbildung 2.1.: Von diskreten Eingabeeinheiten zu gelernten Vektorrepräsentationen

Quelle: (Eigene Darstellung nach [Collobert et al. (2011), S. 2501]; [Turney und Pantel (2010), S. 141 und 148]; [Mikolov et al. (2013), S. 1]); KI-unterstützt.

Die räumliche Anordnung in Abbildung 2.1 verdeutlicht, dass gelernte Vektorrepräsentationen über eine reine numerische Kennzeichnung hinausgehen. Eine konzeptionelle Grundlage für die Interpretation solcher Repräsentationsräume bildet die distributionelle Annahme, nach der sprachliche Einheiten mit ähnlichen Verwendungskontexten tendenziell ähnliche Bedeutungen aufweisen (vgl. [Turney und Pantel (2010), S. 148]). Auch gelernte Wortrepräsentationen können syntaktische und semantische Beziehungen in ihren Vektoren abbilden (vgl. [Mikolov et al. (2013), S. 1]). Die dreidimensionale Darstellung in Abbildung 2.1 dient dabei ausschließlich der schematischen Visualisierung eines tatsächlich mehrdimensionalen Repräsentationsraums; die dargestellten Positionen und Gruppierungen stellen keine empirisch ermittelten Repräsentationen des in dieser Arbeit eingesetzten Modells dar.

Weitere parametrisierte Schichten können Eingaberepräsentationen schrittweise in höherstufige Merkmalsdarstellungen transformieren (vgl. [LeCun et al. (2015), S. 436]). Die Modellrepräsentation geht damit über die anfängliche Zuordnung eines Vektors zu einem Token hinaus.

Für die vorliegende Arbeit bildet dieses Prinzip die Grundlage für die Verarbeitung der textuellen Eingabemodalitäten URL und HTML-Text. Die zusätzlich betrachtete DOM-Struktur bildet demgegenüber explizite Beziehungen zwischen HTML-Elementen ab und kann als Graph repräsentiert werden, in dem HTML-Elemente als Knoten und ihre Eltern-Kind-Beziehungen als Kanten modelliert werden (vgl. [Yoon et al. (2024), S. 9]). Neuronale und graphbasierte Verfahren zur weiterführenden Repräsentationsbildung werden im folgenden Abschnitt betrachtet.

2.2.2. Neuronale und graphbasierte Repräsentationsmodelle

Neuronale Netze bestehen aus verbundenen Verarbeitungseinheiten mit trainierbaren Gewichten; verborgene Einheiten bilden interne Repräsentationen zwischen Ein- und Ausgabe (vgl. [Rumelhart et al. (1986), S. 533]).

Jede Einheit verarbeitet gewichtete Aktivierungen über eine Aktivierungsfunktion; die Gewichte werden anhand des Lernziels angepasst (vgl. [Rumelhart et al. (1986), S. 533]).

Deep Learning verbindet mehrere nichtlineare Verarbeitungsebenen, um geeignete Merkmale und aufeinander aufbauende Repräsentationen aus Daten zu erlernen (vgl. [Bengio (2009), S. 4–6]).




Abbildung 2.2.: Schematischer Aufbau eines mehrschichtigen neuronalen Netzes

Quelle: (Eigene Darstellung nach [Rumelhart et al. (1986), S. 533]); KI-unterstützt.

Abbildung 2.2 zeigt eine vereinfachte mehrschichtige Verarbeitung. Zusätzliche verborgene Ebenen ermöglichen zunehmend abstrakte Merkmalsdarstellungen (vgl. [Bengio (2009), S. 4–6]).

Graphen ergänzen Knotenmerkmale um explizite Beziehungen zwischen den Knoten, die als Kanten dargestellt werden (vgl. [Kipf und Welling (2017), S. 1]).

Graph Convolutional Networks (GCNs) bilden Knotenrepräsentationen unter Berücksichtigung der eigenen Merkmale und der lokalen Nachbarschaft (vgl. [Kipf und Welling (2017), S. 1–2]). Mehrere Verarbeitungsschichten beziehen entsprechend weiter entfernte Nachbarschaften ein (vgl. [Kipf und Welling (2017), S. 3]).

Für Webseiten lässt sich dieses Prinzip auf die DOM-Struktur eines HTML-Dokuments übertragen. HTML-Elemente können dabei als Knoten und ihre hierarchischen Eltern-Kind-Beziehungen als Kanten

2. Theoretische Grundlagen

eines Graphen modelliert werden (vgl. [Yoon et al. (2024), S. 9]). Dadurch können neben den Eigenschaften einzelner HTML-Elemente auch deren strukturelle Beziehungen in die Repräsentationsbildung einbezogen werden.




Abbildung 2.3.: Schematische graphbasierte Repräsentationsbildung einer DOM-Struktur

Quelle: (Eigene Darstellung nach [Kipf und Welling (2017), S. 1–3]; [Yoon et al. (2024), S. 9 und 13]); KI-unterstützt.

Abbildung 2.3 veranschaulicht die graphbasierte Verarbeitung dieser DOM-Struktur. Ein GCN kann dabei Knotenmerkmale gemeinsam mit der lokalen Graphstruktur verarbeiten und daraus strukturabhängige Repräsentationen erzeugen (vgl. [Kipf und Welling (2017), S. 1–2]).

Damit stehen für die weitere Modellierung unterschiedliche Formen der Repräsentationsbildung zur Verfügung. URL und HTML-Text werden als sequenzielle Eingaben verarbeitet, während der DOM die explizite Struktur des HTML-Dokuments graphbasiert abbildet. Für die kontextabhängige Verarbeitung der sequenziellen Eingaben werden in der vorliegenden Arbeit transformerbasierte Encodermodelle eingesetzt, die im folgenden Abschnitt betrachtet werden.

2.2.3. Transformerbasierte Repräsentationsmodelle

Die ursprüngliche Transformer-Architektur besteht aus Encoder und Decoder; der Encoder überführt Eingabesequenzen in kontextabhängige Repräsentationen, die der Decoder für seine Ausgaben nutzt (vgl. [Vaswani et al. (2017), S. 2]). Da die Architektur ohne Rekurrenz und Faltung auskommt, werden den Embeddings Positionsinformationen hinzugefügt (vgl. [Vaswani et al. (2017), S. 6]).

Attention bildet Query-, Key- und Value-Vektoren und gewichtet Values anhand der Ähnlichkeit von Queries und Keys (vgl. [Vaswani et al. (2017), S. 3–4]). Für Scaled Dot-Product Attention gilt (vgl. [Vaswani et al. (2017), S. 4]):

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Quelle: (vgl. [Vaswani et al. (2017), S. 4]).

Q (Query): Repräsentiert die Anfragen, anhand derer bestimmt wird, welche Informationen anderer Sequenzpositionen für die jeweils betrachtete Position relevant sind.

K (Key): Enthält die Schlüsselrepräsentationen der Sequenzpositionen, mit denen die Queries zur Bestimmung ihrer jeweiligen Relevanz verglichen werden.

V (Value): Enthält die zu den Sequenzpositionen gehörenden Informationen, die entsprechend der berechneten Attention-Gewichte in die neue Repräsentation einfließen.

d_k : Bezeichnet die Dimension der Key-Vektoren und dient als Skalierungsfaktor für die berechneten Skalarprodukte.

Die Skalarprodukte werden durch $\sqrt{d_k}$ skaliert, mittels Softmax normalisiert und zur gewichteten Kombination der Values verwendet (vgl. [Vaswani et al. (2017), S. 4]). Bei Self-Attention stammen Queries, Keys und Values aus derselben Sequenz (vgl. [Vaswani et al. (2017), S. 5]). Multi-Head Attention berechnet mehrere solcher Ausgaben mit eigenen Projektionen und führt sie anschließend zusammen (vgl. [Vaswani et al. (2017), S. 4–5]).

Im Encoder folgen auf Multi-Head Attention positionsweise Feed-Forward-Netze; beide Teilkomponenten besitzen Residualverbindungen und Layer-Normalisierung (vgl. [Vaswani et al. (2017), S. 3 und 5]).

Bidirectional Encoder Representations from Transformers (BERT) verwendet einen mehrschichtigen Transformer-Encoder, dessen Attention den Kontext auf beiden Seiten einer Tokenposition berücksichtigt (vgl. [Devlin et al. (2019), S. 4171 und 4173]). Für Klassifikation kann der abschließende Hidden State des speziellen Tokens [CLS] als Sequenzrepräsentation dienen (vgl. [Devlin et al. (2019), S. 4174]).

Neben der Feinabstimmung des Encoders beschreiben Devlin et al. einen feature-basierten Ansatz, bei dem extrahierte Aktivierungen als feste Merkmale nachgelagerter Modelle dienen (vgl. [Devlin et al. (2019), S. 4179]). Die vorliegende Arbeit nutzt diese Trennung für die Repräsentationsvergleiche.

RoBERTa verändert das BERT-Vortraining unter anderem durch umfangreicheres Training, größere Datenmengen, dynamische Maskierung und den Verzicht auf Next Sentence Prediction (vgl. [Liu et al. (2019), S. 1]). Abschnitt 2.3 erläutert die hier relevanten selbstüberwachten Lernziele.

In der vorliegenden Arbeit werden transformerbasierte Encoder für die beiden sequenziellen Informationsquellen URL und HTML-Text eingesetzt. Der URL-Zweig basiert auf BERT, während für den HTML-Text ein RoBERTa-Encoder verwendet wird. Die daraus erzeugten kontextabhängigen Repräsentationen bilden die Grundlage für die nachfolgenden selbstüberwachten Repräsentationsvarianten und deren kontrollierte Downstream-Evaluation.

2.2.4. Downstream-Klassifikation und multimodale Verarbeitung

Die Downstream-Aufgabe dieser Arbeit ist die überwachte Klassifikation einer Webseite als Phishing oder legitim. Eine Linear Probe trainiert einen linearen Klassifikator auf eingefrorenen Repräsentationen, um deren Nutzbarkeit zu bewerten (vgl. [Chen et al. (2020), PDF-S. 3]). Mehrschichtige Netze sind dagegen nicht auf lineare Entscheidungsregionen beschränkt; Cybenkos Approximationsresultat gilt dabei für ausreichend große Netze mit geeigneten sigmoiden Aktivierungen (vgl. [Cybenko (1989), S. 303]). Der empirische Vergleich mit einer nichtlinearen Probe prüft, wie stark die gemessenen Repräsentationsunterschiede vom Klassifikationsmechanismus abhängen.

Multimodale Fusion integriert Informationen mehrerer Modalitäten für eine gemeinsame Vorhersage; merkmalsbasierte Fusion verbindet Repräsentationen vor der Entscheidung, entscheidungsbasierte Fusion dagegen die Ausgaben getrennter Modelle (vgl. [Baltrušaitis et al. (2019), S. 12]). Für URL, HTML-Text und DOM wird hier eine merkmalsbasierte Fusion eingesetzt.

Lernbare Modalitätsgewichte können über Softmax normalisiert und zur gewichteten Summe der Repräsentationen verwendet werden (vgl. [Zhou et al. (2019), PDF-S. 1–2]). Andere Architekturen nutzen abweichende Gating-Funktionen, beispielsweise sigmoide Gated Multimodal Units (vgl. [Arevalo et al. (2017), S. 5]). Eine zusätzliche Entwurfsdimension ist die Kaskadierung: Frühe Stufen schließen einen Teil der Eingaben ab, während verbleibende Fälle aufwendigere Stufen durchlaufen (vgl. [Viola und Jones (2004), S. 144]).

2.3. Self-Supervised Representation Learning

Self-Supervised Representation Learning leitet Trainingsziele aus den Eingabedaten selbst ab; eine solche Hilfsaufgabe (*Pretext Task*) benötigt keine manuell annotierten Zielwerte der späteren Aufgabe (vgl. [Ericsson et al. (2022), S. 42–43]). Die vortrainierten Repräsentationen können anschließend als feste Merkmale oder durch weitere Feinabstimmung für eine *Downstream Task* genutzt werden (vgl. [Ericsson et al. (2022), S. 44–45]).

Abbildung 2.4 veranschaulicht diese Trennung zwischen selbstüberwachtem Vortraining und nachgelagerter Nutzung der erlernten Repräsentationen.




Abbildung 2.4.: Grundprinzip des Self-Supervised Representation Learning

Quelle: (Eigene Darstellung nach [Ericsson et al. (2022), S. 42–46]); KI-unterstützt.

Die Wahl der Pretext-Aufgabe bestimmt das Trainingssignal und beeinflusst die erlernte Repräsentation (vgl. [Ericsson et al. (2022), S. 42–43]). Im Folgenden werden maskierte und kontrastive Lernziele sowie die task-adaptive Weiteranpassung unterschieden.

2.3.1. Maskierte selbstüberwachte Lernziele

Masked Language Modeling (MLM) trainiert einen Encoder darauf, ausgewählte Token aus dem verbleibenden beidseitigen Kontext zu rekonstruieren; die ursprünglichen Token liefern dabei die Zielwerte ohne manuelle Klassenannotation (vgl. [Devlin et al. (2019), S. 4172 und 4174]).

BERT wählt 15 % der Tokenpositionen aus, ersetzt davon 80 % durch das Maskierungstoken und 10 % durch zufällige Token und belässt 10 % unverändert; für diese Positionen wird jeweils das ursprüngliche Token vorhergesagt (vgl. [Devlin et al. (2019), S. 4174]). Auch RoBERTa nutzt MLM als Vortrainingsziel (vgl. [Gururangan et al. (2020), S. 8343]).

Das grundlegende Zusammenspiel aus Maskierung, kontextabhängiger Repräsentationsbildung und Rekonstruktion ist in Abbildung 2.5 exemplarisch für eine HTML-Textsequenz dargestellt.




Abbildung 2.5.: Schematisches Prinzip des Masked Language Modeling am Beispiel des HTML-Textzweigs

Quelle: (Eigene Darstellung nach [Devlin et al. (2019), S. 4174]; [Gururangan et al. (2020), S. 8343]); KI-unterstützt.

Abbildung 2.5 überträgt MLM auf den HTML-Textzweig. Die Wörter sind schematisch; im Code werden Subword-Token maskiert und rekonstruiert. MLM kann auch das Vortraining auf weiteren ungelabelten Daten fortsetzen (vgl. [Gururangan et al. (2020), S. 8343]). Abschnitt 2.3.3 behandelt die aufgabenbezogene Fortsetzung.

2.3.2. Kontrastives Repräsentationslernen

Kontrastives Lernen nähert Repräsentationen positiver Paare einander an und unterscheidet sie von negativen Vergleichsinstanzen; für Text kann dies mit vortrainierten Transformer-Encodern umgesetzt werden (vgl. [Gao et al. (2021), S. 6895]).

Die Ähnlichkeit zweier Repräsentationen kann dabei über die Kosinusähnlichkeit bestimmt werden. Innerhalb der kontrastiven Verlustfunktion beeinflusst ein Temperaturparameter die Skalierung der Ähnlichkeitswerte. Das Lernziel begünstigt dadurch eine hohe Ähnlichkeit positiver Paare relativ zu den verfügbaren negativen Vergleichsinstanzen (vgl. [Gao et al. (2021), S. 6895]).




Abbildung 2.6.: Schematisches Prinzip des kontrastiven Repräsentationslernens für URL–HTML-Paare
Quelle: (Eigene Darstellung nach [Gao et al. (2021), S. 6895]); Übertragung auf URL–HTML-Paare, KI-unterstützt.

Ergänzend wird kontrastives Repräsentationslernen als alternative selbstüberwachte Zielfunktion betrachtet. URL und HTML-Text derselben Webseite bilden dabei ein positives Paar, während Repräsentationen anderer Webseiten als negative Beispiele dienen. Das Trainingssignal entsteht somit ohne Verwendung von Phishing- oder Benign-Labels. Die konkrete Umsetzung wird in Abschnitt 4.3.2 beschrieben.

2.3.3. Task-Adaptive Pretraining

Task-Adaptive Pretraining (TAPT) setzt das RoBERTa-Vortraining auf dem ungelabelten Trainingskorpus einer konkreten Downstream-Aufgabe fort (vgl. [Gururangan et al. (2020), S. 8346]).

Die angepassten Repräsentationen werden anschließend für das überwachte Training der Zielaufgabe verwendet (vgl. [Gururangan et al. (2020), S. 8346]).

Die Trennung beider Lernphasen lässt sich vereinfacht wie folgt darstellen:

2. Theoretische Grundlagen

$$\theta_{\text{pre}} \xrightarrow[\mathcal{D}_{\text{unlabeled task}}]{\mathcal{L}_{\text{MLM}}} \underbrace{\theta_{\text{TAPT}}}_{\text{Task-Adaptive Pretraining}} \rightarrow \theta_{\text{TAPT}} \xrightarrow[\mathcal{D}_{\text{labeled task}}]{\mathcal{L}_{\text{cls}}} \underbrace{\theta_{\text{task}}}_{\text{Downstream-Training}}. \quad (2.1)$$

Quelle: (Eigene Darstellung nach [Gururangan et al. (2020), S. 8346]); KI-unterstützt.

Domain-Adaptive Pretraining (DAPT) nutzt dagegen einen breiteren ungelabelten Korpus der Domäne; TAPT ist durch die Auswahl der Trainingsdaten enger an eine konkrete Zielaufgabe gebunden (vgl. [Gururangan et al. (2020), S. 8342–8343 und 8346]).

In der vorliegenden Arbeit wird TAPT auf die beiden sequenziellen Informationsquellen URL und HTML-Text übertragen. Die vortrainierten Encoder werden hierzu getrennt mittels MLM auf dem ungelabelten Webseiten-Trainingspool weiter angepasst. Da derselbe Pool anschließend die Ausgangsbasis der gelabelten Downstream-Budgets bildet, entspricht dieser Versuchsaufbau der task-adaptiven Variante. Dadurch lassen sich die isolierte Anpassung einzelner Informationsquellen sowie ihre gemeinsame Anpassung gegenüber nicht adaptierten Repräsentationen unter unterschiedlichen Labelbudgets und Evaluationsbedingungen untersuchen.

2.4. Evaluationsrahmen und Bewertungsmetriken

2.4.1. Klassifikations- und Betriebspunktmetriken

True-Positive-Rate, False-Positive-Rate und Precision Bei einer binären Klassifikation ergeben sich aus tatsächlicher und vorhergesagter Klasse die vier Fälle True Positive (TP), False Positive (FP), True Negative (TN) und False Negative (FN). Darauf aufbauend lassen sich True-Positive-Rate (TPR), False-Positive-Rate (FPR) und Precision bestimmen (vgl. [Saito und Rehmsmeier (2015), S. 3–4]):

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}, \quad \text{Precision} = \frac{TP}{TP + FP}.$$

Quelle: (vgl. [Saito und Rehmsmeier (2015), S. 4]).

TPR entspricht dem Recall, FPR dem Anteil falsch positiver unter allen negativen Instanzen und Precision dem Anteil tatsächlich positiver unter allen positiven Vorhersagen (vgl. [Saito und Rehmsmeier (2015), S. 4]). In dieser Arbeit ist Phishing die positive und legitim die negative Klasse.

Betriebspunkt Die Klassifikationsschwelle bestimmt das Verhältnis von TPR und FPR (vgl. [Saito und Rehmsmeier (2015), S. 4]). Für die Phishing-Erkennung sind insbesondere Betriebspunkte mit niedriger FPR relevant (vgl. [Purwanto et al. (2022), S. 1506]).

Die vorliegende Arbeit betrachtet deshalb primär die TPR an einem festgelegten Low-FPR-Betriebspunkt und die dort realisierte FPR. Ergänzend wird mit $FPR@TPR_{90}$ die umgekehrte Perspektive verwendet: Sie gibt an, welche False-Positive-Rate am ersten empirischen ROC-Punkt mit einer TPR von mindestens 90 % erreicht wird. Eine Interpolation auf exakt 90 % erfolgt nicht. Niedrigere Werte entsprechen dabei einer günstigeren Trennung der beiden Klassen. Beide Perspektiven erlauben damit eine Bewertung der Klassifikationsleistung bei kontrollierter Erkennungs- beziehungsweise Fehlalarmrate.

Ergänzende Precision-Recall-Metriken Neben einzelnen Betriebspunkten kann die Modellleistung über unterschiedliche Klassifikationsschwellen betrachtet werden. Die Precision-Recall-Kurve stellt hierzu Precision und Recall über verschiedene Schwellenwerte gegenüber (vgl. [Saito und Rehmsmeier (2015), S. 4 und 7]). Die Average Precision (AP) fasst diese Rankingperspektive über die Kurve zusammen. Dalton et al. verwenden im PhreshPhish-Benchmark ergänzend eine als Precision bei 90 % Recall bezeichnete Kennzahl ($P@R = 0,90$) (vgl. [Dalton et al. (2026), S. 7]).

Precision und darauf aufbauende Precision-Recall-Metriken hängen zusätzlich von der Klassenverteilung der Evaluationsmenge ab (vgl. [Saito und Rehmsmeier (2015), S. 5 und 7]). AP und der nachfolgend präzierte Kennwert $P_{\geq 90}$ werden in der vorliegenden Arbeit daher ergänzend zur Beschreibung der Rankingqualität auf einem festen Evaluationsbestand verwendet. Die zentralen Modell- und Systemvergleiche stützen sich dagegen auf TPR und FPR an den festgelegten Betriebspunkten. Der implementierte Kennwert $P_{\geq 90}$ ist die maximale Precision unter allen empirischen Schwellen mit Recall von mindestens 90 %:

$$P_{\geq 90} = \max_{\tau: TPR(\tau) \geq 0,90} \text{Precision}(\tau).$$

Er bezeichnet somit keine interpolierte Precision bei exakt 90 % Recall. AP wird als Summe der Precision-Werte gewichtet mit den jeweiligen Recall-Zuwächsen berechnet; sie entspricht hier keiner trapezförmigen Flächenintegration.

2.4.2. Generalisierung unter Distribution Shift

Eine besondere Herausforderung für die Generalisierung lernbasierter Modelle entsteht, wenn sich die zugrunde liegende Datenverteilung zwischen Training und späterer Evaluation verändert. Koh et al. bezeichnen als Distribution Shift Situationen, in denen sich Trainings- und Testverteilung unterscheiden (vgl. [Koh et al. (2021), PDF-S. 1]). Vereinfacht lässt sich dieser Zusammenhang durch

$$P_{\text{train}}(X, Y) \neq P_{\text{test}}(X, Y)$$

beschreiben, wobei X die Eingabedaten und Y die zugehörige Zielklasse bezeichnet. Koh et al. zeigen anhand mehrerer realer Datensätze, dass Modelle unter solchen Out-of-Distribution-Bedingungen deutlich

geringere Leistungen als unter vergleichbaren Trainings- und Testbedingungen erreichen können (vgl. [Koh et al. (2021), PDF-S. 1–2]).

Zeitliche Veränderungen und zuvor unbeobachtete Domänen bilden mögliche Ursachen von Verteilungsverschiebungen; WILDS berücksichtigt beide Formen in seinen Testbedingungen (vgl. [Koh et al. (2021), PDF-S. 1–3]).

Für die vorliegende Arbeit bildet diese Unterscheidung die theoretische Grundlage für die spätere Evaluation unter veränderten Datenbedingungen. Die konkrete Konstruktion der verwendeten Testszenarien und die Festlegung des Low-FPR-Betriebpunkts werden in Abschnitt 4.4.1 beschrieben.

2.4.3. Statistische Auswertungsverfahren

Stochastisches Training kann zwischen Läufen unterschiedliche Ergebnisse erzeugen; Reimers und Gurevych empfehlen deshalb die Bewertung mehrerer Ausführungen anstelle einzelner Ergebniswerte (vgl. [Reimers und Gurevych (2017), S. 338]).

Gepaarte Leistungsdifferenzen Werden zwei Modellvarianten unter korrespondierenden Bedingungen verglichen, können die jeweils zusammengehörigen Beobachtungen paarweise gegenübergestellt werden. Holt und Sullivan bilden hierfür die Differenzen zwischen den Beobachtungspaaren und verwenden deren Mittelwert als Teststatistik (vgl. [Holt und Sullivan (2023), S. 787–788]):

$$d_i = x_i - y_i, \quad T = \bar{d}.$$

Quelle: (vgl. [Holt und Sullivan (2023), S. 787–788]).

Die Paarbildung erhält die Zuordnung korrespondierender Beobachtungen (vgl. [Holt und Sullivan (2023), S. 787–788]). Differenzen prozentual ausgewiesener Metriken werden in dieser Arbeit in Prozentpunkten berichtet.

Konfidenzintervalle Konfidenzintervalle ergänzen Punktschätzungen um eine Unsicherheitsangabe, häufig zum Niveau von 95 % oder 99 % (vgl. [Botsch (2023), S. 15]). Hier beschreiben 95%-Intervalle die Unsicherheit mittlerer Differenzen aus gepaarten Downstream-Wiederholungen; ihre Interpretation setzt die in Kapitel 4 genannten Bedingungen voraus.

Bootstrap-Resampling zieht wiederholt Stichproben gleicher Größe mit Zurücklegen und berechnet die Leistungsmetrik erneut (vgl. [Raschka (2018), S. 16]). Beim 95%-Percentile-Intervall bilden das 2,5%- und 97,5%-Quantil der Bootstrap-Verteilung die Grenzen (vgl. [Raschka (2018), S. 18]).

Exakter Sign-Flip-Permutationstest Bei unter der Nullhypothese um null symmetrischen Paardifferenzen lässt sich eine Nullverteilung ihres Mittelwerts durch alle Vorzeichenkombinationen bilden (vgl. [Holt und Sullivan (2023), S. 787–788]).

Für n Paare gibt es 2^n Vorzeichenkombinationen; der zweiseitige exakte p -Wert ist deren Anteil mit einem mindestens so großen absoluten Mittelwert wie beobachtet (vgl. [Holt und Sullivan (2023), S. 788]).

Korrektur multipler Tests Mit mehreren Hypothesentests kann das Risiko mindestens einer falschen Zurückweisung innerhalb der Testfamilie steigen (vgl. [Dror et al. (2017), S. 471 und 474]).

Die Holm-Prozedur sortiert m p -Werte aufsteigend und vergleicht sie nacheinander mit $\alpha/(m - i + 1)$, bis erstmals keine Zurückweisung erfolgt; dadurch wird die familienbezogene Fehlerwahrscheinlichkeit kontrolliert (vgl. [Holm (1979), S. 66–67]).

In der vorliegenden Arbeit werden die Größenordnung der beobachteten Leistungsunterschiede, die Unsicherheit ihrer Schätzung und die Ergebnisse der statistischen Tests gemeinsam berichtet. Die konkrete Anzahl der Wiederholungen, die Paarbildung sowie die Zuordnung mehrerer Vergleiche zu gemeinsamen Testfamilien werden im Methodikkapitel festgelegt.

2.4.4. Effizienz- und Betriebsmetriken

Die technische Evaluation berücksichtigt neben der Klassifikationsgüte auch den Inferenzaufwand. Reddi et al. unterscheiden latenzorientierte Szenarien und durchsatzorientierte Batch-Verarbeitung (vgl. [Reddi et al. (2020), S. 5–6]).

- **Median-Latenz [ms]:** bezeichnet in dieser Arbeit das 50. Perzentil der gemessenen Inferenzzeiten und beschreibt damit die typische Verarbeitungsdauer einer Eingabe.
- **95. Perzentil der Latenz [ms]:** bezeichnet den Latenzwert, den 95 % der beobachteten Inferenzvorgänge nicht überschreiten. Perzentilbasierte Latenzmetriken werden auch in etablierten Inferenzbenchmarks zur Betrachtung langsamerer Bereiche der Laufzeitverteilung eingesetzt (vgl. [Reddi et al. (2020), S. 5–6]).
- **Durchsatz [Seiten/s]:** beschreibt die Anzahl der innerhalb eines Zeitraums verarbeiteten Eingaben. Im Offline-Szenario des MLPerf-Inference-Benchmarks wird entsprechend der Durchsatz in Samples pro Sekunde betrachtet (vgl. [Reddi et al. (2020), S. 6]).
- **Peak-VRAM [MiB]:** bezeichnet in dieser Arbeit den maximal während des betrachteten Inferenzpfads belegten GPU-Speicher.
- **Eskalationsrate [%]:** bezeichnet bei einer kaskadierten Verarbeitung den Anteil der Eingaben, für die nach der ersten Verarbeitungsstufe zusätzlich der vollständige multimodale Modellpfad ausgeführt wird.

Latenz und Durchsatz erfassen unterschiedliche Aspekte der technischen Verarbeitung und sind daher gemeinsam zu betrachten (vgl. [Reddi et al. (2020), S. 11]). Peak-VRAM und Eskalationsrate ergänzen diese Kennzahlen um den Ressourcenbedarf und den Verarbeitungsumfang.

3. Stand der Forschung und Forschungslücke

3.1. Task-adaptive Repräsentationen und Label-Effizienz

Ein Forschungsstrang der Phishing-Erkennung untersucht, wie transformerbasierte Repräsentationen bereits vor der gelabelten Zielklassifikation an Web- und insbesondere URL-Daten angepasst werden können. URLTran vergleicht zwei Ansätze: ausschließlich auf URLs vortrainierte und anschließend feinabgestimmte Transformer sowie die direkte Feinabstimmung öffentlich vortrainierter BERT- und RoBERTa-Modelle. Die Evaluation berücksichtigt gezielt Betriebspunkte mit sehr niedrigen False-Positive-Raten (vgl. [Maneriker et al. (2021), PDF-S. 1–2]). PhishBERT wird auf mehr als drei Milliarden ungelabelten URLs vortrainiert und anschließend für die Phishing-Klassifikation weiterverwendet (vgl. [Wang et al. (2023), Abstract, o. S.]). Auch urlBERT nutzt mehrere Milliarden URLs und kombiniert mehrere selbstüberwachte Vortrainingsziele; ergänzend wird die Sensitivität gegenüber reduziertem gelabeltem Trainingsumfang untersucht (vgl. [Li et al. (2025), S. 1–2 und 12]).

Neben der domänennäheren Repräsentationsbildung rückt damit die verfügbare gelabelte Downstream-Supervision in den Fokus. Gui et al. führen den Aufwand der Erhebung und Annotation großer gelabelter Datenbestände als eine Motivation für Self-Supervised Learning an (vgl. [Gui et al. (2024), S. 1]). Für spezialisierte URL-Repräsentationen untersuchen Li et al. ergänzend, wie sich die Downstream-Leistung bei reduziertem gelabeltem Trainingsumfang verändert (vgl. [Li et al. (2025), S. 12]).

Für die vorliegende Arbeit sind daraus zwei Aspekte relevant. Erstens wird untersucht, welchen zusätzlichen Nutzen die in Abschnitt 2.3.3 eingeführte task-adaptive Weiteranpassung bereits vortrainierter URL- und HTML-Text-Encoder für die Phishing-Klassifikation erzeugt. Durch die getrennte und gemeinsame Anpassung beider Informationszweige wird zugleich betrachtet, wie sich dieser Effekt zwischen URL und HTML-Text verteilt. Zweitens wird die gelabelte Downstream-Supervision systematisch über mehrere Labelbudgets variiert, um zu bestimmen, wie sich der Repräsentationsvorteil mit wachsendem Trainingsumfang entwickelt und ab welchem reduzierten Labelbudget das festgelegte Leistungsniveau vollständig trainierter Referenzen erreicht wird.

3.2. Informationsgrundlage und Systemarchitektur

Neben der Repräsentationsbildung unterscheiden sich bestehende Verfahren hinsichtlich der für die Klassifikation verwendeten Webseiteninformationen. Aljofey et al. kombinieren URL-Zeichenfolgen, Hyperlinkinformationen und textuelle HTML-Merkmale und führen diese einem XGBoost-Klassifikator zu (vgl. [Aljofey et al. (2022), S. 1–2 und 13]). Opara et al. verarbeiten URL- und HTML-Informationen dagegen in einem gemeinsamen neuronalen Verfahren (vgl. [Opara et al. (2024), S. 2]). Damit werden URL und HTML-Inhalt als unterschiedliche Informationsquellen derselben Webseite für die Klassifikation nutzbar gemacht.

Über den textuellen HTML-Inhalt hinaus kann auch die Dokumentstruktur berücksichtigt werden. Yoon et al. kombinieren URL-Repräsentationen mit einem graphbasierten HTML-DOM und untersuchen den zusätzlichen Beitrag der strukturellen Information anhand von Ablationen (vgl. [Yoon et al. (2024), S. 2, 13 und 15]). Die bestehende Forschung liefert damit eine Grundlage dafür, adressbezogene, textuelle und strukturelle Informationen innerhalb eines gemeinsamen Klassifikationssystems zu berücksichtigen.

Die vorliegende Arbeit trennt dabei Repräsentations- und Systemebene. Zunächst wird die task-adaptive URL- und HTML-Text-Repräsentation unter konstant gehaltenen Downstream-Bedingungen untersucht. Die daraus ausgewählte Repräsentationsbasis wird anschließend schrittweise um weitere Systemkomponenten erweitert. Eine sequenzielle Ablation von URL über HTML-Text und DOM bis zur lernbaren Gating-Fusion bestimmt hierbei den inkrementellen Beitrag der zusätzlichen Informations- und Fusionskomponenten.

Neben dem Informationsumfang kann auch die Verarbeitungstiefe Bestandteil des Systementwurfs sein. Liu et al. beschreiben ein mehrstufiges Phishing-Erkennungsverfahren und berichten eine Verkürzung der Ausführungszeit bei zugleich verbesserter Erkennung (vgl. [Liu et al. (2021), Abstract, o. S.]). Dieses Prinzip bildet den konzeptionellen Bezug für die URL-first-Kaskade der vorliegenden Arbeit. Die URL-Stufe dient dabei als vorgelagerter Entscheidungspfad, während für unsichere Fälle weiterhin das vollständige multimodale System ausgeführt wird.

3.3. Generalisierung und betriebliche Evaluationsbedingungen

Die Aussagekraft eines Phishing-Klassifikators hängt neben der Modellarchitektur auch von der Zusammensetzung der Evaluationsdaten ab. Rashid et al. untersuchen URL-Klassifikatoren über unterschiedliche Datensätze hinweg und berichten deutliche Leistungsunterschiede zwischen datensatzinternen und datensatzübergreifenden Evaluationen (vgl. [Rashid et al. (2024), Abstract, o. S.]). Dalton et al. adressieren im PhreshPhish-Benchmark eine verwandte Problematik durch zeitlich getrennte Trainings- und Testdaten sowie eine zusätzliche Reduktion stark ähnlicher Instanzen (vgl. [Dalton et al. (2026), S. 5–6]).

Für die vorliegende Untersuchung wird die Leistungsrelation zwischen den Repräsentationsvarianten und Labelbudgets deshalb nicht ausschließlich auf dem vollständigen Testbestand betrachtet. Ergänzende domain-, template- und zeitbezogene Teilmengen bilden zusätzliche Evaluationsbedingungen. Sie dienen der Prüfung, ob die zuvor beobachteten Repräsentations- und Budgetrelationen auch unter veränderter Zusammensetzung der Testdaten bestehen bleiben.

Eine weitere Evaluationsdimension bildet der Klassifikationsbetriebspunkt. URLTran untersucht seine Modelle gezielt bei niedrigen False-Positive-Raten (vgl. [Maneriker et al. (2021), PDF-S. 1–2]). Auch im operativen Sicherheitsbetrieb werden False-Positive-Raten gemeinsam mit Größen wie Eskalationen und Bearbeitungsaufwand als Qualitätskennzahlen betrachtet (vgl. [ENISA (2020), S. 7]). Die vorliegende Arbeit verwendet daher einen auf einer getrennten Kalibrationsmenge bestimmten Low-FPR-Betriebspunkt, der anschließend unverändert auf die finalen Evaluationsbedingungen übertragen wird.

Für die technische Bewertung des Gesamtsystems kommen Ressourcenkennzahlen der Inferenz hinzu. Reddi et al. unterscheiden insbesondere latenz- und durchsatzorientierte Inferenzszenarien (vgl. [Reddi et al. (2020), S. 5–6]). Entsprechend werden neben der Klassifikationsleistung auch Latenz, Durchsatz, GPU-Speicherbedarf und Eskalationsrate betrachtet.

3.4. Forschungslücke und Einordnung der Arbeit

Die betrachteten Forschungsarbeiten adressieren die für diese Arbeit relevanten Aspekte überwiegend auf einzelnen Ebenen. Spezialisierte selbstüberwachte URL-Repräsentationen zeigen die Nutzbarkeit domänennäherer Repräsentationsbildung; Untersuchungen reduzierter Labelmengen betrachten die Downstream-Leistung bei begrenzter Supervision. Weitere Arbeiten kombinieren mehrere Webseiteninformationen oder verwenden mehrstufige Klassifikationsarchitekturen.

Aus dieser Ausgangslage ergibt sich für die vorliegende Arbeit die Verbindung dreier Untersuchungsebenen. Zunächst wird der zusätzliche Effekt einer task-adaptiven Weiteranpassung bereits vortrainierter URL- und HTML-Text-Repräsentationen isoliert. Darauf aufbauend wird untersucht, wie sich dieser Effekt über unterschiedliche Labelbudgets entwickelt und ab welchem reduzierten Budget das festgelegte Leistungsniveau vollständig trainierter Referenzen erreicht wird. Die ausgewählte Repräsentationsbasis wird anschließend in ein multimodales Gesamtsystem überführt, dessen zusätzliche Komponenten und gestufte Verarbeitung getrennt evaluiert werden.

Tabelle 3.1 fasst die für das Untersuchungsdesign maßgeblichen Forschungsbezüge zusammen.

Tabelle 3.1.: Einordnung des Untersuchungsdesigns in den Stand der Forschung.

Forschungsbereich	Bezug zur vorliegenden Arbeit	Umsetzung
Selbstüberwachte URL-Repräsentationen (vgl. [Maneriker et al. (2021), PDF-S. 1–2]; [Wang et al. (2023), Abstract, o. S.]; [Li et al. (2025), S. 1–2 und 12])	Zusätzliche task-adaptive Anpassung bereits vortrainierter URL- und HTML-Text-Repräsentationen.	Vergleich von R0, RU, RT und RUT bei konstanten Downstream-Probes.
Nutzung ungelabelter Daten und reduzierte Labelbudgets (vgl. [Gui et al. (2024), S. 1]; [Li et al. (2025), S. 1–2 und 12])	Verhalten der Repräsentationsvarianten bei unterschiedlicher gelabelter Downstream-Supervision.	Sieben Labelbudgets sowie Bestimmung der kleinsten ausreichenden RUT-Stufe gegenüber vollständig mit 200.000 Labels trainierten Referenzen.
Mehrquellenbasierte Webseitenklassifikation (vgl. [Aljofey et al. (2022), S. 1–2 und 13]; [Opara et al. (2024), S. 2]; [Yoon et al. (2024), S. 2 und 13–15])	Überführung der ausgewählten Repräsentationsbasis in ein multimodales Klassifikationssystem.	Sequenzielle Erweiterung um HTML-Text, DOM und lernbare Gating-Fusion.
Low-FPR- und gestufte Verarbeitung (vgl. [Maneriker et al. (2021), PDF-S. 1–2]; [Liu et al. (2021), Abstract, o. S.]; [ENISA (2020), S. 7]; [Reddi et al. (2020), S. 5–6])	Bewertung des Gesamtsystems bei festgelegtem Betriebspunkt und unterschiedlicher Verarbeitungstiefe.	CAL-basierter Low-FPR-Betriebspunkt, URL-first-Kaskade sowie Effizienz- und Eskalationsmetriken.

4. Methodisches Vorgehen und Systemkonzeption

4.1. Forschungsdesign und Untersuchungslogik

Zur Beantwortung der Forschungsfragen wird ein mehrstufiges Untersuchungsdesign verwendet, das die Analyse der Repräsentationen von der späteren Bewertung des prototypischen Klassifikationssystems trennt. Die eingesetzten BERT- und RoBERTa-Basisencoder wurden bereits allgemein selbstüberwacht vortrainiert. Zunächst wird untersucht, welchen zusätzlichen Beitrag eine task-adaptive selbstüberwachte Anpassung der URL- und HTML-Text-Repräsentationen leistet. Erst anschließend werden auf Systemebene der Informationsumfang, die multimodale Fusion und die kaskadierte Verarbeitung variiert. Dadurch lassen sich Veränderungen der Repräsentationen getrennt von später eingeführten Architekturkomponenten untersuchen.

Die vier Forschungsfragen folgen dieser Reihenfolge. FF1 vergleicht R0, RU, RT und RUT unter konstant gehaltenen Downstream-Bedingungen. FF2 erweitert den Vergleich über sieben verschachtelte Labelbudgets und zwei Downstream-Probes. FF3 prüft, ab welchem reduzierten Labelbudget RUT das Leistungsniveau vollständig mit 200.000 Labels trainierter Referenzen über alle fünf Evaluationsbedingungen erreicht. FF4 untersucht anschließend auf Systemebene zunächst den zusätzlichen Beitrag von HTML-Text, DOM und Gating zur Erkennungsleistung. Darauf aufbauend wird geprüft, wie das resultierende multimodale Vollsystem innerhalb einer URL-first-Kaskade gestuft eingesetzt werden kann und welche Auswirkungen dies auf Klassifikationsleistung und Inferenzaufwand hat.

Tabelle 4.1.: Untersuchungsstufen und Funktion im Untersuchungsdesign.

Stufe	Vergleich	Zweck
FF1	R0, RU, RT, RUT	Zusätzlicher Beitrag der task-adaptiven URL- und Textrepräsentation
FF2	2k–200k Labels; Linear Probe und MLP	Lernverhalten bei unterschiedlicher gelabelter Supervision
FF3	RUT_B gegen $R0@200k$ und TF-IDF/XGBoost@200k	Erreichen des Leistungsniveaus vollständig trainierter Referenzen
FF4	URL → DUAL → TRI → Gated → Kaskade	Zusätzlicher Systembeitrag und gestufte Systemverarbeitung

Die Untersuchungsstufen greifen damit unterschiedliche Aspekte derselben betrieblichen Problemstellung auf. Die Low-FPR-Evaluation berücksichtigt die Qualität der Klassifikationsentscheidung bei begrenztem Fehlalarmniveau. Die Labelbudgetanalyse untersucht, wie viel gelabelte Downstream-Supervision zum Erreichen eines festgelegten Leistungsniveaus erforderlich ist. Die nachgelagerte Systemanalyse bestimmt zunächst, welchen zusätzlichen Beitrag HTML-Text, DOM und Gating zur Erkennungsleistung leisten. Erst auf Basis dieses leistungsstarken Vollsystems wird anschließend untersucht, wie eine URL-first-Kaskade die Verarbeitungstiefe instanzabhängig steuern kann: eindeutige Fälle können nach dem URL-Zweig abgeschlossen werden, während unsichere Fälle weiterhin den vollständigen multimodalen Pfad durchlaufen.

Die zusätzlichen Testbedingungen bilden keine eigene Architekturstufe, sondern werden durchgängig für die abschließende Bewertung verwendet. Neben dem vollständigen offiziellen Testbestand werden domain-, template-, kombiniert strukturell und zeitlich getrennte FINAL-Teilmenngen betrachtet. Die schwellenwertabhängige Bewertung verwendet auf CAL bestimmte Betriebspunkte mit einer Ziel-False-Positive-Rate von 0,5 %. Entscheidungen zur Repräsentations- und Systementwicklung werden ohne Zugriff auf CAL und FINAL getroffen.

4.2. Datengrundlage und Datenprotokoll

4.2.1. Rollenpartitionierung und Leakage-Prävention

Als gemeinsame Datengrundlage wird der öffentlich bereitgestellte PhreshPhish-Datensatz verwendet. Dalton et al. konzipieren PhreshPhish als umfangreichen Datensatz für die Erkennung von Phishing-Webseiten und stellen zusätzlich einen darauf aufbauenden Benchmark zur standardisierten Modellbewertung bereit (vgl. [Dalton et al. (2026), S. 2]). Für die vorliegende Arbeit sind insbesondere URL, gespeicherter HTML-Inhalt, Klassenzuordnung und Erfassungsdatum relevant. Der von Dalton et al. bereitgestellte Testbestand ist zeitlich vom Training getrennt; zusätzlich werden stark ähnliche Trainings- und Testinstanzen reduziert (vgl. [Dalton et al. (2026), S. 5–6]). Dieser offizielle Testbestand bleibt deshalb als FINAL von der Modell- und Architekturauswahl ausgeschlossen. Vor Beginn der Versuche wird ein verbindlicher Data Freeze erzeugt. Der offizielle Testbestand wird vollständig als FINAL übernommen; SUP, DEV, SSL und CAL werden ausschließlich aus dem offiziellen Trainingsbestand gebildet. Die Rollenzuordnung erfolgt deterministisch anhand der SHA-256-Identifikatoren. Vor und nach der Materialisierung wird die paarweise SHA-256-Disjunktheit der relevanten Rollen geprüft.

Tabelle 4.2.: Datenrollen des eingefrorenen Untersuchungsprotokolls.

Rolle	Umfang	Funktion	Vor Freeze zugänglich
SUP	4.000	Separater gelabelter Pool des Data Freeze	ja
DEV	20.000	Repräsentationsvergleich sowie Entwicklung und interne Komponentenprüfung	ja
SSL	200.000	Label-freies Self-Supervised Pretraining; Ausgangspool der späteren Labelbudgets	ja
CAL	50.000	Ausschließlich legitime Webseiten zur Bestimmung der Klassifikationsschwellen	nein
FINAL	168.060	Offizieller Testbestand für die abschließende Evaluation	nein

Für den SSL-Pool werden selbstüberwachtes Vortraining und überwachte Downstream-Nutzung technisch getrennt. Die materialisierten SSL-Dateien enthalten keine Labelspalte. Für spätere Downstream-Versuche werden die Klassenlabels ausschließlich über ein getrennt gespeichertes Rollenmanifest anhand der SHA-256-Identifikatoren wieder zugeordnet. Derselbe festgelegte Instanzbestand kann damit zunächst label-frei für die Repräsentationsanpassung und anschließend für die kontrollierte Variation der verfügbaren Trainingslabels verwendet werden.

4.2.2. Aufbereitung der Informationsmodalitäten




Abbildung 4.1.: Ableitung der Informationsmodalitäten und Evaluationsmetadaten aus einer Webseiteninstanz
Eigene Darstellung; KI-unterstützt.

Aus jeder Webseiteninstanz werden drei Modellinputs und drei Evaluationsmetadaten abgeleitet. Die URL bleibt als sequenzielle Eingabe erhalten. Aus dem gespeicherten HTML werden ein bereinigter HTML-Text und ein statischer DOM erzeugt. Für den Text werden Kommentare sowie Script-, Style-, Noscript- und Template-Bereiche entfernt, anschließend HTML-Tags entfernt, HTML-Zeichenreferenzen aufgelöst und Whitespace normalisiert. Für den DOM wird das HTML-Dokument als Baum geparkt; pro Knoten werden Tagname, Elternindex, Tiefe, Attributanzahl und Anzahl direkter Kindknoten gespeichert. Es handelt sich um einen aus dem gespeicherten HTML rekonstruierten statischen DOM und nicht um einen browserseitig gerenderten Laufzeit-DOM. Domain, Template-Hash und Datum werden getrennt davon ausschließlich für die spätere Evaluation aufbewahrt. Die Domain wird aus der URL bestimmt; der Template-Hash entsteht aus der normalisierten Folge öffnender und schließender HTML-Tags. Diese drei Größen gehen nicht als Modellmerkmale in die Klassifikation ein. Abbildung 4.1 fasst die Trennung von Modellinputs und Evaluationsmetadaten zusammen.

4.3. Repräsentations- und Versuchsdesign

4.3.1. Task-adaptive Repräsentationen R0, RU, RT und RUT

Zur isolierten Untersuchung der task-adaptiven Anpassung wird ein faktorielles 2×2 -Design für URL und HTML-Text verwendet. Für jede Modalität stehen der bereits allgemein selbstüberwacht vortrainierte

Basisencoder und eine mittels Masked Language Modeling auf den ungelabelten Webseitendaten weitertrainierte Variante zur Verfügung. R0 ist damit keine “No-SSL”-Bedingung, sondern der nicht zusätzlich task-adaptiv angepasste Ausgangspunkt. R0 kombiniert BERT Base und RoBERTa Base, RU ausschließlich den angepassten URL-Encoder, RT ausschließlich den angepassten HTML-Text-Encoder und RUT beide angepassten Encoder. BERT und RoBERTa bilden festgelegte Ausgangsmodelle ihrer jeweiligen Modalität; untersucht wird nicht ihre gegenseitige Überlegenheit, sondern der zusätzliche Adaptationsschritt.

Für die Downstream-Analyse werden URL und HTML-Text getrennt encodiert und die Hidden States unter Berücksichtigung der Attention Mask jeweils zu einer mittleren Sequenzrepräsentation aggregiert. Die beiden 768-dimensionalen Vektoren werden zu einer für alle vier Varianten identischen 1.536-dimensionalen Darstellung konkateniert. DOM-Verarbeitung und multimodale Fusion bleiben in diesem Versuchsblock unberücksichtigt.

	HTML-Text: Basisencoder	HTML-Text: TAPT-Encoder
URL: Basisencoder	R0 URL: BERT Base Text: RoBERTa Base	RT URL: BERT Base Text: RoBERTa TAPT
URL: TAPT-Encoder	RU URL: BERT TAPT Text: RoBERTa Base	RUT URL: BERT TAPT Text: RoBERTa TAPT

Alle Varianten: URL-Repräsentation + HTML-Text-Repräsentation → 1.536-dimensionale Downstream-Darstellung

Abbildung 4.2.: Faktorielles Design der task-adaptiven Repräsentationsvarianten
Eigene Darstellung; KI-unterstützt.

4.3.2. Downstream-Probes, Labelbudgets und Referenzverfahren

Zur Bewertung der Repräsentationen werden eine logistische Regression als Linear Probe und ein kleines Mehrschicht-Perzeptron als nichtlineare Probe eingesetzt. Die Transformer-Encoder bleiben dabei eingefroren. Die Linear Probe misst die unmittelbare lineare Nutzbarkeit der Repräsentationen für die Zielklassifikation (vgl. [Chen et al. (2020), PDF-S. 3]). Innerhalb einer Wiederholung erhalten R0, RU, RT und RUT identische gelabelte Trainingsinstanzen und denselben Downstream-Versuchsaufbau.

Die Downstream-Supervision wird über sieben verschachtelte Budgets von 2.000 bis 200.000 gelabelten Webseiten variiert. Die vollständigen Lernkurven werden mit fünf gepaarten Wiederholungen bestimmt; für den zentralen Vergleich RUT gegen R0 bei 20.000 Labels wird auf zehn Paare erweitert. Die TAPT-Checkpoints werden dabei nicht neu trainiert, sodass N10 die Variation der Labelauswahl und des Downstream-Trainings bei festen Repräsentationen erfasst. Die Budgets unter 200.000 enthalten je zur Hälfte beide Klassen und sind innerhalb einer Wiederholung ineinander verschachtelt. Bei 200.000 wird dagegen der vollständige SSL-Bestand mit 101.578 benignen und 98.422 Phishing-Instanzen verwendet. Die Auswahl benötigt somit Klasseninformationen, obwohl diese beim vorgelagerten TAPT nicht eingelesen werden. FF3 nutzt dasselbe Budgetraster für den Vergleich mit R0@200k als interner Referenz

sowie einer mit 200.000 Labels trainierten TF-IDF/XGBoost-Pipeline. Da sich bei letzterer zugleich Repräsentation und Klassifikator ändern, wird dieser Vergleich nur als verfahrensübergreifende Referenz interpretiert. Ergänzend wird die Label-Effizienz von R0 und RUT auf dem unabhängig erhobenen Phishing Website Dataset von Putra (2023) geprüft. Der Datensatz wird anhand des Erfassungszeitpunkts in einen früheren Trainings- und einen späteren Testbestand getrennt. Auf dem früheren Bestand werden für beide Repräsentationen identische, verschachtelte Budgets von 200, 500, 1.000 und 2.000 gelabelten Webseiten mit zehn gepaarten Linear-Probes verwendet. Primärer Endpunkt ist die über die logarithmierten Labelbudgets integrierte Average-Precision-Lernkurve (AP-AULC).

Für Putra werden 10.391 vollständige Datensätze nach Erfassungszeitpunkt geordnet. Der Schnitt am empirischen 75-%-Quantil (7. April 2023, 03:33:03,372 UTC) ergibt 7.793 frühere Instanzen (3.554 benign, 4.239 Phishing) und 2.598 spätere Instanzen (1.686 benign, 912 Phishing); exakte URL-Überschneidungen zwischen beiden Teilen wurden nicht gefunden. Verarbeitet werden die URL und das bereitgestellte Textmerkmal, kein neu gerendertes HTML. Die externen Auswertungen sind nachträgliche Transferanalysen. In einem zusätzlichen Vergleich werden beide Quell-RUT-Encoder über eine MLM-Epoche auf dem ungelabelten frühen Putra-Pool angepasst (E1); E0 behält die Quell-RUT-Encoder bei. Beide verwenden dieselben zehn Labelauswahlen und das unveränderte externe Testset. Der zusätzliche MLM-Schritt verwendet 15 % Maskierung, Lernrate $5 \cdot 10^{-5}$, Weight Decay 0,01 und 6 % Warmup. Das spätere Putra-Testset wird hierfür nicht verwendet.

Ein früherer explorativer Versuchsblock untersucht ergänzend kontrastive Repräsentationen. R2C und R3C kombinieren modalitätsinterne Ansichten mit URL–HTML-Positivpaaren, während CSAME nur modalitätsinterne Paare nutzt; Domain- und Template-Identitäten werden aus den Negativmengen ausgeschlossen. Da dieser Block nicht unter dem finalen R0/RU/RT/RUT-Protokoll wiederholt wurde, erfolgt ausschließlich eine deskriptive Einordnung anhand der zugehörigen eigenen Ergebnisartefakte.

4.4. Evaluations- und Statistikdesign

4.4.1. Kalibration und Evaluationsbedingungen

Für die schwellenwertabhängige FINAL-Evaluation wird CAL mit 50.000 ausschließlich legitimen Webseiten verwendet. Für jede zu bewertende Modell- und Wiederholungskonfiguration wird auf diesen benignen Instanzen ein Schwellenwert für eine Ziel-False-Positive-Rate von 0,5 % bestimmt. Dieser Wert ist ein festgelegter restriktiver Betriebspunkt der vorliegenden Untersuchung und kein allgemeiner Standard für Phishing-Erkennungssysteme. Der auf CAL bestimmte Schwellenwert wird unverändert auf den vollständigen Finalbestand und die daraus gebildeten Bedingungen übertragen.

Die Zeitbedingung beginnt am 28.10.2025, dem 75-%-Quantil der Erfassungsdaten. Wegen gleicher Datumswerte an der Grenze umfasst sie 46.784 Fälle und damit mehr als genau ein Viertel des Finalbestands.

Zur zusätzlichen Absicherung der Szenariodefinition wurde ein metadatenbasierter Integritätsaudit durchgeführt. Die exakten Domain- und `template_hash`-Identitäten der FINAL-Szenarien wurden hierzu mit

Tabelle 4.3.: Evaluationsbedingungen der abschließenden Generalisierungsbewertung.

Bedingung	Operationalisierung	Umfang
Official Test	Vollständiger offizieller Testbestand	168.060
Domain-OOD	Domain zuvor nicht in den entwicklungszugänglichen Datenrollen beobachtet	115.917
Template-OOD	Template-Hash zuvor nicht in den entwicklungszugänglichen Datenrollen beobachtet	161.223
Domain+Template-OOD	Weder Domain noch Template-Hash zuvor beobachtet	110.095
Late Test Q4	Erfassungsdatum ab dem 75%-Quantil des Finalbestands	46.784

SUP, DEV, CAL und dem 200.000 Instanzen umfassenden SSL/TAPT-Pool abgeglichen. Für alle prüfba-
ren Domain-OOD- und Template-OOD-Instanzen ergab sich keine einzige exakte Überschneidung; dies
gilt ebenso für das kombinierte Domain+Template-OOD-Szenario. Für die vorhandenen Identitätswerte
weist der Audit somit keine Exposition gegenüber den geprüften Lernrollen nach; dies bezieht sich auf
exakte Identitäten und den archivierten Freeze. Für 1,34 % der Domain-OOD-Instanzen beziehungswei-
se 1,38 % im kombinierten Szenario lag kein auswertbarer Domainwert vor; semantische Ähnlichkeiten
oder Near-Duplicates werden in dieser Arbeit nicht geprüft.

4.4.2. Statistische Entscheidungsregeln

Bei gepaarten Repräsentations- und Architekturvergleichen bildet die jeweilige Trainingsreplikation die
statistische Einheit. Als Effektgröße wird die mittlere Differenz der TPR in Prozentpunkten berichtet. Für
mittlere Paardifferenzen wird das zweiseitige t-Intervall $\bar{d} \pm t_{0,975;n-1} s_d / \sqrt{n}$ verwendet; es beschreibt die
Downstream-Variation bei festen Vortrainingszuständen und fester Testpopulation. Die t-Intervalle setzen
unabhängige, näherungsweise normalverteilte Paardifferenzen voraus; die Sign-Flip-Tests benötigen un-
ter der jeweiligen Nullhypothese Vorzeichensymmetrie. Die vollständige Enumeration allein macht einen
Test nicht voraussetzungsfrei. Ergänzend werden die Anzahl der Replikationen mit positiver beziehungs-
weise negativer Differenz angegeben. Für gepaarte Vergleiche wird der exakte Sign-Flip-Permutationstest
verwendet (vgl. [Holt und Sullivan (2023), S. 787–788]). Mehrere gemeinsam geprüfte Hypothesen wer-
den mit der Holm-Prozedur für multiples Testen korrigiert (vgl. [Holm (1979), S. 66–67]). Der N10-
Vergleich von RUT20k und R020k verwendet OFFICIAL_TEST als primären Endpunkt. Die vier zusätzli-
chen domain-, template- und zeitbezogenen Bedingungen bilden eine gemeinsame sekundäre Testfamilie;
ihre vier p-Werte werden innerhalb dieses Vergleichs nach Holm korrigiert.

Für FF3 wird eine Nichtunterlegenheitsmarge von einem Prozentpunkt TPR festgelegt. Gegen R0@200k
wird für jedes Budget und jede Evaluationsbedingung ein exakter einseitiger Sign-Flip-Test auf die
um diese Marge verschobene gepaarte Differenz berechnet. Ein Budget gilt nur dann als ausreichend,
wenn die Nichtunterlegenheit in allen fünf Bedingungen gleichzeitig erreicht wird. Der gemeinsame
p-Wert ist das Maximum der fünf Komponenten-p-Werte (Intersection-Union-Prinzip). Anschließend
werden die sieben Budgetentscheidungen mit der Holm-Prozedur korrigiert. Die Marge von einem
Prozentpunkt dient als Entscheidungsschwelle dieser Untersuchung und stellt keine fachlich oder be-
trieblich validierte Servicegrenze dar. Für den Vergleich von RUT+Linear mit TF-IDF/XGBoost@200k
besteht keine natürliche Paarung der zehn Modellläufe. Deshalb werden die Beobachtungen nicht

nachträglich einander zugeordnet. Dieser nachträgliche Welch-Vergleich wird als ergänzende, verfahrensübergreifende Evidenz interpretiert. Stattdessen wird für jede Evaluationsbedingung ein einseitiger Welch-Nichtunterlegenheitstest mit derselben Marge berechnet.

Auch hier muss die Nichtunterlegenheit in allen fünf Bedingungen erreicht werden; anschließend werden die sieben Budgetentscheidungen nach Holm korrigiert. Zusätzlich wird deskriptiv ausgewiesen, ab welchem Budget die mittlere TPR von RUT in allen fünf Bedingungen mindestens der XGBoost-TPR entspricht und die mittlere FPR gleichzeitig nicht höher liegt. Diese zusätzliche Auswertung beschreibt ausschließlich die beobachteten Mittelwerte und stellt keinen Signifikanztest dar.

Da die Nichtunterlegenheitsmarge von einem Prozentpunkt für diese Untersuchung festgelegt wurde, wird nach Abschluss der primären FF3-Auswertung ergänzend geprüft, wie stark die ermittelte Budgetstufe von dieser Festlegung abhängt. Hierzu wird dasselbe N10-Protokoll zusätzlich mit TPR-Margen von 0,0, 0,5 und 2,0 Prozentpunkten ausgewertet. Gegen R0@200k bleiben der gepaarte einseitige Sign-Flip-Test, die gleichzeitige Bedingung über alle fünf Evaluationsbedingungen und die Holm-Korrektur über sieben Budgets unverändert. Für TF-IDF/XGBoost@200k wird analog mit den einseitigen Welch-Tests verfahren. Bei einer Marge von 0,0 Prozentpunkten wird kein TPR-Nachteil zugelassen; die Entscheidung verlangt damit einen über alle fünf Bedingungen positiven Unterschied im verwendeten Testprotokoll. Die Sensitivitätsanalyse wurde nach der primären 1-pp-Auswertung ergänzt. Sie dient ausschließlich dazu, die Stabilität der resultierenden Budgetstufe gegenüber alternativen Margen zu prüfen. Die 1-pp-Marge bleibt die vorab verwendete Hauptentscheidung und wird durch die ergänzende Auswertung nicht nachträglich ersetzt.

4.5. Konzeption des prototypischen Klassifikationssystems

4.5.1. Zielbild und Gesamtarchitektur

Aufbauend auf der Repräsentationsanalyse wird ein mehrzweiges prototypisches Klassifikationssystem konzipiert. Die DUAL-Variante verarbeitet URL und HTML-Text in getrennten Transformerzweigen. Die TRI-Variante ergänzt zusätzlich die strukturelle DOM-Repräsentation. Die Ausgaben der aktiven Modalitäten werden jeweils in einen gemeinsamen 256-dimensionalen Raum projiziert und L2-normalisiert. Eine lernbare Gating-Komponente bestimmt instanzabhängige Modalitätsgewichte; daraus wird eine gewichtete Fusionsrepräsentation gebildet. Die Verwendung lernbarer, über Softmax normalisierter Modalitätsgewichte entspricht dem Prinzip einer gewichteten multimodalen Fusion (vgl. [Zhou et al. (2019), PDF-S. 2]). Für die abschließende Klassifikation werden die einzelnen Modalitätsrepräsentationen gemeinsam mit der Fusionsrepräsentation verwendet. Modalitätsspezifische Auxiliary Heads erzeugen zusätzliche Hilfsscores, ohne die Gating-Gewichte zu ersetzen. Der URL-Hilfsscore bildet zugleich die Grundlage der URL-first-Kaskade. Die Gesamtarchitektur und die Rollen von DUAL, TRI, Auxiliary Heads, Gating und Main Head sind in Abbildung 4.3 dargestellt. Die technische Parametrisierung der Encoderfreigabe, DOM-GCN-, Gating- und Head-Komponenten wird erst in Kapitel 5 spezifiziert. Die Architektur trennt damit drei Ebenen: die Repräsentationsbildung innerhalb der Modalitätszweige, deren

4. Methodisches Vorgehen und Systemkonzeption

gemeinsame Fusion und die nachgelagerte Klassifikation. Ob jede zusätzliche Systemkomponente gegenüber einer einfacheren Vorstufe einen eigenen Beitrag liefert, wird nicht aus dem Endmodell abgeleitet, sondern in einer gesonderten sequenziellen Ablation geprüft.




Abbildung 4.3.: Gesamtarchitektur des prototypischen Klassifikationssystems

Eigene Darstellung; KI-unterstützt.

4.5.2. Sequenzielle Komponentenablation

Zur kontrollierten FF4-Komponentenprüfung wird die RUT-Repräsentationsbasis festgehalten und vier verschachtelte Systemvarianten werden verglichen:

$$\begin{aligned}
 P_0 &= \text{URL}, & P_1 &= \text{URL+Text, Equal}, \\
 P_2 &= \text{URL+Text+DOM, Equal}, & P_3 &= \text{URL+Text+DOM, Gated}.
 \end{aligned}$$

Damit quantifiziert $P_1 - P_0$ den zusätzlichen Textbeitrag, $P_2 - P_1$ den zusätzlichen DOM-Beitrag und $P_3 - P_2$ den Beitrag der lernbaren Gating-Fusion. Die vier Varianten werden mit zehn gepaarten Replikationen auf derselben balancierten Stichprobe aus 20.000 Labels trainiert. Die initialen RUT-URL- und Textcheckpoints sowie der DOM-SSL-Encoder bleiben identisch; die freigegebenen Modellparameter werden überwacht trainiert. Für alle Varianten werden eine Epoche und Batchgröße acht verwendet. Die Komponentenablation verwendet ausschließlich Development-Daten. Der Schwellenwert wird auf den benignen Beispielen der Teilmenge ENG_TUNE bei einer Ziel-FPR von 0,5 % bestimmt. Primärer Endpunkt der Komponentenablation ist die TPR auf der von ENG_TUNE getrennten Teilmenge ENG_META. CAL und FINAL werden für diese Analyse nicht verwendet. Für die drei benachbarten N10-Vergleiche werden exakte zweiseitige Sign-Flip-Tests berechnet und gemeinsam nach Holm korrigiert.

4.5.3. URL-first-Kaskade und Frontend-Vergleich




Abbildung 4.4.: Sequenzdiagramm der bedingten Verarbeitung in der URL-first-Kaskade
Eigene Darstellung; KI-unterstützt.

Die URL-first-Kaskade führt zunächst ausschließlich den URL-Zweig aus und erzeugt über den URL-Auxiliary-Head den Score f_{URL} . Eine untere und eine obere, auf Development-Daten bestimmte Schwelle begrenzen einen Unsicherheitsbereich. Liegt der Score außerhalb dieses Bereichs, wird die Klassifikation bereits nach dem URL-Pfad abgeschlossen. Nur die dazwischenliegenden Fälle durchlaufen zusätzlich den vollständigen multimodalen Pfad. Dieses Vorgehen entspricht dem Grundprinzip kaskadierter Klassifikatoren (vgl. [Viola und Jones (2004), S. 144–145]). Bei einer Eskalation wird die bereits berechnete URL-Repräsentation wiederverwendet und um HTML-Text sowie in der TRI-Variante um den DOM ergänzt. Die aktiven Repräsentationen durchlaufen anschließend dieselbe Fusion und denselben Klassifikationskopf wie im Vollsystem. Abbildung 4.4 zeigt den Ablauf und verdeutlicht, dass der DOM-Zweig nur für eskalierte TRI-Fälle ausgeführt wird. Zusätzlich wird untersucht, ob die verwendete URL-Repräsentation den Anteil der Eskalationen beeinflusst. TRI-Fallback, Labelbudget und grundsätzliche Routinglogik bleiben hierfür unverändert; variiert wird ausschließlich zwischen der Basis- und der task-adaptierten URL-Repräsentation. Die Routingparameter werden auf Development-Daten für zulässige TPR-Abweichungen von 0,25, 0,5, 1,0 und 2,0 Prozentpunkten gegenüber dem Vollsystem bestimmt. Die primär betrachtete Toleranz beträgt einen Prozentpunkt. Als zentrale Ressourcenkennzahl wird die Eskalationsrate berichtet, also der Anteil der Webseiten, für die der vollständige multimodale Pfad ausgeführt wird. Verglichen wird damit der erforderliche Verarbeitungsumfang unter derselben vorgegebenen TPR-Toleranz.

4.6. Freeze, Reproduzierbarkeit und Grenzen des Untersuchungsdesigns

Die ursprüngliche Repräsentations- und Systementwicklung erfolgt auf den vorgesehenen Development-Daten; vor dem Zugriff auf CAL und FINAL wird für den finalen Integrationslauf ein Architecture-Freeze gespeichert. CAL wird danach ausschließlich zur Schwellenwertbestimmung verwendet, während FINAL und die daraus gebildeten Teilmengen ausschließlich der abschließenden Leistungsbewertung dienen. Datenrollen, Modellzustände, Konfigurationen, Seeds und Auswertungsartefakte werden gespeichert sowie die Disjunktheit der Datenrollen, die erwarteten Instanzzahlen und die Vollständigkeit der Ergebnisartefakte automatisiert geprüft.

Mehrere ergänzende Analysen wurden erst nach Vorliegen früherer Ergebnisse durchgeführt. Der Vergleich mit TF-IDF/XGBoost wurde nach den ersten RUT/R0-Ergebnissen um das vollständige Budgettraster von 2.000 bis 200.000 Labels erweitert; sämtliche sieben Budgetstufen werden berichtet und der Analyseplan wurde vor der Ausführung gespeichert. Auch die sequenzielle FF4-Komponentenablation wurde erst nach Festlegung der finalen Architektur ergänzt. Varianten, neue Seeds, die drei Komponentenvergleiche und die Schwellenlogik wurden vor ihrer Durchführung festgelegt, während CAL und FINAL weiterhin ausgeschlossen blieben. Die Komponentenablation dient damit der nachträglichen Prüfung der bereits festgelegten Systembestandteile und nicht der erneuten Auswahl der finalen Architektur. Die Sensitivitätsanalyse der FF3-Marge wurde nach Abschluss der primären 1-pp-Auswertung ergänzt und wendet ohne erneutes Modelltraining dieselben statistischen Entscheidungsregeln auf alternative Margen von 0,0, 0,5 und 2,0 Prozentpunkten an. Sie prüft ausschließlich, ob sich die kleinste ausreichende Budgetstufe bei alternativen Festlegungen verändert. Die Wiederholungen variieren die Labelauswahl und das Downstream-Training bei unveränderten Repräsentations- beziehungsweise Pretraining-Checkpoints und erfassen daher nicht die Varianz vollständig neu ausgeführter selbstüberwachter Vortrainingsläufe. Aussagen zur reduzierten Labelmenge beziehen sich ausschließlich auf die gelabelte Downstream-Supervision.

Die betriebliche Szenarioanalyse wird nach Abschluss der Modellauswertung ergänzt. Sie verwendet die eingefrorenen FINAL-Konfusionsmatrizen und klassenspezifischen Routinganteile, ohne Schwellen neu auszuwählen. Referenzvolumen und Phishinganteile sind ausdrücklich angenommene Größen. Die Umrechnung setzt unverändertes Fehler- und Routingverhalten innerhalb beider Klassen voraus; ihre Werte sind bedingte Erwartungswerte ohne zusätzliche Unsicherheitsintervalle. Der gemessene In-Memory-Durchsatz bleibt eine separate technische Referenz. Ein betrieblicher Pilot oder ein neuer Verteilungstest wird dadurch nicht ersetzt.

5. Implementierung

5.1. Entwicklungs- und Ausführungsumgebung

Die experimentelle Pipeline wurde Python-basiert in einer GPU-gestützten Kaggle-Notebook-Umgebung umgesetzt. Für Training und Inferenz der neuronalen Modellkomponenten wird PyTorch verwendet, während die transformerbasierten Encoder und Tokenizer über die Transformers-Bibliothek eingebunden werden. Ergänzend kommen NumPy, pandas und PyArrow für die Datenverarbeitung sowie scikit-learn und SciPy für Downstream-Modelle und statistische Auswertungen zum Einsatz. Das statische HTML- und DOM-Parsing der vorgelagerten Data-Freeze-Pipeline basiert auf lxml.

Die rechenintensiven Verarbeitungsschritte werden CUDA-beschleunigt ausgeführt. Die finale Integrationspipeline prüft hierzu beim Start die Verfügbarkeit einer GPU und verwendet eine NVIDIA-Tesla-T4-Umgebung als Zielkonfiguration. Für Trainings- und Inferenzoperationen ist darüber hinaus Mixed Precision aktiviert; die entsprechenden Berechnungen werden über `torch.autocast` mit `float16` ausgeführt. Speicherintensive Verarbeitungsböcke enthalten zusätzliche CUDA-Speicherbereinigungen. Für mehrere Trainings- und Scoring-Schritte sind zudem abgestufte Batchgrößen implementiert, sodass ein Verarbeitungsschritt bei einem `OutOfMemoryError` mit einer kleineren Batchkonfiguration erneut ausgeführt werden kann. Die jeweils verwendeten Batchgrößen werden bei den zugehörigen Modellkomponenten konkretisiert.

Für die reproduzierbare Durchführung der wiederholten Experimente werden die verwendeten Zufallsquellen zentral initialisiert. Der Gesamtlauf verwendet den Master-Seed 20260817; die einzelnen Versuchsblöcke greifen ergänzend auf festgelegte Modell- und Ranking-Seeds zurück. Die Initialisierung umfasst Python, NumPy und PyTorch einschließlich der CUDA-Zufallsquellen.

Die während der Ausführung erzeugten Modellzustände, vorberechneten Repräsentationen, Vorhersagescores sowie Ergebnis- und Auditinformationen werden getrennt als Artefakte gespeichert. Die darauf aufbauenden Completion-, Freeze- und Reproduzierbarkeitsmechanismen werden in Abschnitt 5.6 beschrieben.

5.2. Implementierung der Datenverarbeitung

Die Datenverarbeitung bildet den gemeinsamen Ausgangspunkt sämtlicher nachfolgenden Versuchsblöcke. Der PhreshPhish-Datensatz wird zunächst in einem festen Data Freeze geprüft, aufbereitet und in die in Abschnitt 4.2.1 definierten Rollen SUP, DEV, CAL und SSL überführt. Der offizielle Testbestand bleibt davon getrennt und wird erst in den späteren Evaluationsschritten als FINAL verwendet. Während des Data Freeze werden unter anderem die erwarteten Rollenstärken, doppelte SHA-256-Identifikatoren und exakte Überschneidungen zwischen Trainings- und Testbestand programmatisch geprüft.

Die Rollenbildung erfolgt deterministisch über die SHA-256-Identifikation der einzelnen Webseiten. Hierzu wird der jeweilige Identifikator gemeinsam mit einem festen, rollenspezifischen Zusatzstring

erneut gehasht. Im Code wird dieser Zusatz als `salt` bezeichnet. Dadurch entstehen für die unterschiedlichen Auswahlstufen getrennte, bei erneuter Ausführung jedoch identische Rangfolgen. Listing A.4 im Anhang zeigt die hierfür verwendete Funktion.

SUP und DEV werden auf dieser Grundlage jeweils klassenweise gebildet. CAL wird anschließend ausschließlich aus noch nicht zugeordneten benignen Instanzen bestimmt, bevor der SSL-Pool aus dem verbleibenden Bestand abgeleitet wird. Die Implementierung prüft abschließend die vorgesehenen Größen von 4.000 SUP-, 20.000 DEV-, 50.000 CAL- und 200.000 SSL-Instanzen. Die deterministische Materialisierung setzt damit die in Abschnitt 4.2.1 konzipierte Trennung der Datenrollen technisch um. Parallel zur Rollenbildung werden die in Abschnitt 2.1.2 unterschiedenen Informationsperspektiven für die nachfolgenden Modellzweige aufbereitet.

Für den textuellen HTML-Zweig werden zunächst Kommentare sowie `script`-, `style`-, `noscript`- und `template`-Bereiche entfernt. Anschließend werden die verbleibenden Tags entfernt, HTML-Zeichenreferenzen aufgelöst und Whitespace normalisiert. Aus den normalisierten HTML-Tags wird zusätzlich eine strukturelle Sequenz gebildet. Diese dient unter anderem zur Ableitung des `template_hash`, der später für die Template-basierten OOD-Szenarien benötigt wird. Listing A.5 im Anhang fasst die für Text-, Template- und DOM-Ableitung maßgeblichen Verarbeitungsschritte zusammen.

Der Ausschnitt zeigt nur die für die beschriebenen Ableitungen relevanten Teile der Funktion; die vollständige Implementierung verbleibt in den digitalen Artefakten. Die DOM-Struktur wird aus dem gespeicherten HTML statisch rekonstruiert. Für jeden berücksichtigten Knoten werden Tagname, Elternindex, Tiefe, Attributanzahl und Anzahl direkter Kindknoten gespeichert. Damit bleibt die in Abschnitt 2.2.2 beschriebene graphbasierte Sicht auf die Eltern-Kind-Beziehungen des HTML-Dokuments für den späteren DOM-Zweig erhalten. Im Data Freeze werden maximal 4.096 DOM-Knoten pro Webseite materialisiert; die engere Eingabegrenze des Deep-Modells wird erst in Abschnitt 5.4 angewendet.

Eine zentrale technische Trennung betrifft den SSL-Pool. Entsprechend dem in Abschnitt 2.3 beschriebenen Prinzip des selbstüberwachten Lernens werden dessen physische Parquet-Dateien ohne Downstream-Label gespeichert. Die Spalte `label` wird bereits während der Rollenmaterialisierung explizit entfernt, wie Listing A.6 im Anhang zeigt.

Die finale Pipeline kontrolliert zusätzlich über das Parquet-Schema, dass die physischen SSL-Dateien weiterhin keine Labelspalte enthalten. Die Klasseninformationen verbleiben getrennt in einem privaten Rollenmanifest und werden erst für die späteren überwachten Labelbudgetexperimente über die SHA-256-Identifikation wieder zugeordnet. Die TAPT-Verfahren arbeiten dagegen ausschließlich auf den physisch label-freien Webseiteninformationen. Damit wird die experimentelle Trennung zwischen verfügbarem ungelabeltem Trainingsmaterial und verfügbarer überwachter Trainingsinformation nicht nur konzeptionell, sondern auch in der Datenpipeline umgesetzt.

5.3. Implementierung der Self-Supervised Repräsentationen

Die in Abschnitt 2.3 eingeführte selbstüberwachte Repräsentationsanpassung wird getrennt für die URL- und die HTML-Text-Modalität umgesetzt. Als Ausgangspunkt dienen mit `bert-base-uncased` bezie-

5. Implementierung

hungsweise roberta-base bereits vortrainierte Transformerencoder. Beide Modelle werden mittels Masked Language Modeling auf den 200.000 physisch label-freien Instanzen des SSL-Pools weitertrainiert. Damit wird das in Abschnitt 2.3.3 beschriebene Task-Adaptive Pretraining auf dem aufgabenspezifischen Webseiten-Trainingspool umgesetzt, ohne hierfür das Downstream-Label Phishing beziehungsweise Benign zu verwenden.

Für die Modalitäten gelten unterschiedliche Kontextgrenzen: Der URL-Zweig verarbeitet maximal 128 BERT-Token einschließlich Spezialtoken. Längere Eingaben werden abgeschnitten. Eine vollständige Abdeckung des URL-Bestands durch diese Grenze ist damit nicht belegt.

Für den HTML-Text wird dagegen ein festes Kontextbudget von 256 Tokens verwendet. Die HTML-Dokumente besitzen gegenüber URLs wesentlich umfangreichere und stärker variierende Sequenzen. Die Begrenzung dient daher insbesondere dazu, Speicherbedarf und Rechenaufwand des transformer-basierten Trainings kontrollierbar zu halten. Sie ist nicht als Annahme zu verstehen, dass innerhalb von 256 Tokens der vollständige HTML-Inhalt einer Webseite erfasst wird. Von dieser Transformergrenze ist die vorgelagerte Datenaufbereitung zu unterscheiden: Im Data Freeze wird der bereinigte HTML-Text zunächst mit bis zu 50.000 Zeichen materialisiert; die Begrenzung auf 256 Tokens erfolgt erst bei der Eingabe in den Textencoder.

Für beide Modalitäten wird das TAPT über eine Epoche durchgeführt. Da die Encoder dabei nicht neu initialisiert, sondern bereits vortrainierte BERT- beziehungsweise RoBERTa-Modelle zusätzlich an den Webseiten-Trainingspool angepasst werden, bildet eine Epoche ein bewusst begrenztes Adaptationsbudget für den zusätzlichen SSL-Schritt. Beide Zweige durchlaufen damit den jeweils 200.000 Instanzen umfassenden SSL-Bestand einmal vollständig. Die Festlegung ist als einheitliche experimentelle Vorgabe und nicht als Aussage über ein global optimales Trainingsbudget zu verstehen.

Für das URL-TAPT werden 15 % MLM-Maskierung, AdamW, eine Lernrate von $5 \cdot 10^{-5}$, Weight Decay 0,01 und 6 % Warmup verwendet. Listing A.1 im Anhang zeigt die dafür maßgebliche Trainingskonfiguration.

Der TAPT-Pfad liest ausschließlich URLs aus dem physischen SSL-Pool; als Batch-Fallback sind 16 und 8 hinterlegt. Für den HTML-Text-Zweig wird derselbe MLM-Mechanismus mit 15 % Maskierung, $5 \cdot 10^{-5}$ Lernrate, Weight Decay 0,01 und 6 % Warmup verwendet. Aufgrund der längeren Textsequenzen sind dort Batch-Fallbacks von 16, 8 und 4 vorgesehen. Der vollständige Trainingscode beider Zweige ist in den digitalen Artefakten enthalten.

Die getrennte Anpassung beider Modalitäten bildet die technische Grundlage des in Abschnitt 4.3.1 beschriebenen 2×2 -Versuchsdesigns. Hierzu werden jeweils Basis- und TAPT-Encoder so kombiniert, dass der Anpassungseffekt beider Modalitäten getrennt variiert werden kann. R0 verwendet für URL und HTML-Text die unveränderten Ausgangsmodelle, RU ausschließlich den angepassten URL-Encoder, RT ausschließlich den angepassten Textencoder und RUT die TAPT-Varianten beider Zweige. Die verwendeten Encoderquellen werden für jede Variante in den Audit-Artefakten gespeichert.

Damit bleibt die nachgelagerte Repräsentationsbildung zwischen den vier Bedingungen strukturell identisch; variiert wird ausschließlich die Herkunft des URL- beziehungsweise Textencoders. Auf diese Weise

5. Implementierung

kann der zusätzliche Nutzen der task-adaptiven Anpassung zunächst unabhängig von den späteren Architekturkomponenten wie DOM-Zweig und multimodaler Fusion untersucht werden.

Für die kontrollierten Downstream-Probes werden aus den Hidden States der jeweiligen Transformer feste Repräsentationsvektoren erzeugt. Hierzu wird ein attention-mask-basiertes Mean Pooling verwendet, sodass Padding-Token nicht in die Mittelwertbildung eingehen. Die Summe der gültigen Hidden States wird dabei durch die Anzahl der über die Attention Mask markierten Token geteilt.

Die URL- und Textrepräsentationen werden getrennt extrahiert und als `float32`-Embeddings zwischengespeichert. Die beiden 768-dimensionalen Vektoren werden anschließend zu der in Abschnitt 4.3.1 definierten 1.536-dimensionalen Gesamtrepräsentation konkateniert. Im Probe-Pfad erfolgt danach keine gemeinsame Weiteroptimierung der Transformerencoder mit dem Klassifikator. Auf den festen Repräsentationen werden stattdessen eine logistische Regression als Linear Probe sowie ein kleines MLP trainiert. Damit wird der Repräsentationseffekt von Veränderungen der späteren End-to-End-Architektur getrennt.

Die Probe-Experimente werden für die sieben in Abschnitt 4.3.2 definierten Labelbudgets von 2.000, 5.000, 10.000, 20.000, 50.000, 100.000 und 200.000 gelabelten Instanzen ausgeführt. Innerhalb einer Wiederholung wird hierfür eine deterministische klassenweise Rangfolge verwendet, aus der verschachtelte Teilmengen entstehen. Ein kleineres Budget ist damit Bestandteil der jeweils größeren Budgetstufen derselben Wiederholung. Für R0, RU, RT und RUT werden innerhalb eines gepaarten Vergleichs dieselben Instanzen verwendet, sodass sich die Bedingungen hinsichtlich der verfügbaren Labels nicht unterscheiden. Die Lernkurven werden über fünf gepaarte Wiederholungen erzeugt. Für das zentrale Budget von 20.000 Labels wird zusätzlich der in Abschnitt 4.3.2 beschriebene N10-Lauf durchgeführt; die konkrete Seedsteuerung und Reproduzierbarkeitslogik wird in Abschnitt 5.6 zusammengeführt.

Ergänzend wurde in einem vorgelagerten Entwicklungsversuch ein kontrastiver SSL-Pfad implementiert. R2C und R3C kombinieren modalitätsinterne Ansichten mit URL–HTML-Positivpaaren; CSAME verwendet ausschließlich Same-Modality-Paare. Für den historischen Vergleich wurde eine Temperatur von 0,10 verwendet. Um eng verwandte Webseiten nicht als reguläre Negativbeispiele zu behandeln, werden Kandidaten mit identischer nichtleerer Domain oder identischem nichtleerem Template-Hash aus der jeweiligen Negativmenge ausgeschlossen.

Der kontrastive Pfad stammt aus einem eigenständigen früheren Versuchsblock und wird nicht mit der finalen R0/RU/RT/RUT-Ablation vermischt. Seine Ergebnisse werden in Kapitel 6 deskriptiv als explorativer Objective-Vergleich dokumentiert; die finalen TAPT- und Systementscheidungen werden daraus nicht abgeleitet.

Labelbudgetvergleich und klassische Referenz. Für den statistischen Labelbudgetvergleich werden die bereits extrahierten R0- und RUT-Repräsentationen wiederverwendet; ein erneutes Transformertraining findet in diesem Versuchsblock nicht statt. Die 1.536-dimensionalen URL+Text-Repräsentationen werden an eine logistische Regression mit $C = 1$, `solver=liblinear`, `class_weight=balanced` und `max_iter=2000` übergeben. RUT wird über das vollständige in Abschnitt 4.3.2 festgelegte Budgetraster ausgewertet, während R0@200k als interne Referenz mit identischem Repräsentationsformat und derselben Linear Probe dient.

Die ergänzende klassische Vergleichspipeline verwendet TF-IDF-Merkmale aus URL und Text. Der URL-Pfad basiert auf Character-N-Grammen der Längen drei bis fünf mit $\text{min_df}=2$, sublinearer Termfrequenz, L2-Normalisierung und maximal 25.000 Merkmalen. Für den Text werden Word-N-Gramme der Längen eins bis zwei mit $\text{min_df}=3$, $\text{max_df}=0.995$, sublinearer Termfrequenz, Unicode-Akzentstripping, L2-Normalisierung und maximal 50.000 Merkmalen erzeugt. Die TF-IDF-Transformation wird auf den 200.000 hierfür vorgesehenen Webseiten ohne Verwendung der Klassenlabels angepasst; der resultierende Merkmalsraum umfasst 75.000 Dimensionen.

Die XGBoost-Referenz verwendet 400 Bäume mit maximaler Tiefe sechs, Lernrate 0,08, $\text{min_child_weight}=2$, $\text{subsample}=0.9$, $\text{colsample_bytree}=0.65$, $\lambda = 2$, $\text{max_bin}=128$ und $\text{tree_method}=\text{hist}$. Zehn Modelle mit getrennten Seeds werden im selben Runtime-Stand neu trainiert und erhalten jeweils das vollständige 200.000er-Labelbudget. Die Schwellenbestimmung erfolgt analog zum RUT/R0-Pfad auf CAL. Da sich gegenüber RUT+Linear sowohl Repräsentationsverfahren als auch Klassifikator ändern, bleibt dieser Vergleich ein Systembenchmark und wird nicht als isolierter TAPT-Effekt ausgewertet.

5.4. Implementierung des multimodalen Deep-Systems

Für das prototypische Gesamtsystem werden die in Abschnitt 5.3 ausgewählten Encoder in einen gemeinsamen trainierbaren Modellpfad überführt. DUAL verarbeitet URL und HTML-Text, TRI ergänzt die strukturelle DOM-Repräsentation.

Im Deep-System werden die obersten vier Transformerlayer für das überwachte Training freigegeben. Listing A.7 im Anhang zeigt die entsprechende Parameterselektion.

Alle übrigen Transformerparameter bleiben eingefroren; ein vorhandener Pooler wird ebenfalls trainierbar gehalten. Die über rep gewählten Basis- oder TAPT-Encoder werden nach dem Masked Mean Pooling jeweils auf 256 Dimensionen projiziert und L2-normalisiert. Der DOM-Zweig verarbeitet die im Data Freeze gespeicherten Knotenmerkmale und Eltern-Kind-Beziehungen; pro Webseite werden maximal 512 Knoten in das Deep-System übernommen. Listing A.8 im Anhang zeigt den Kern der GCN-basierten Knotenkodierung.

Tag, Tiefe, Attribut- und Kindanzahl werden mit 96, 16, 8 und 8 Dimensionen eingebettet und zu 128-dimensionalen Knotenvektoren kombiniert. Nach drei GCN-Schichten werden die Knoten lernbar gewichtet aggregiert; der resultierende DOM-Vektor wird anschließend ebenfalls auf 256 Dimensionen projiziert und L2-normalisiert.

Vor dem überwachten TRI-Training wird der DOM-Encoder über die Rekonstruktion maskierter DOM-Tags selbstüberwacht vorangepasst.

Maskiert werden 30 % der Tags; trainiert wird über eine Epoche mit Batchgröße 64 und $2 \cdot 10^{-3}$ Lernrate. Der Verlust wird ausschließlich auf den tatsächlich maskierten Knoten bestimmt. Der resultierende DOM-Encoder wird gespeichert und im TRI-System gemeinsam mit den übrigen Komponenten weiteroptimiert. Das strukturelle Rekonstruktionsziel bleibt dabei vom tokenbasierten MLM der Transformerzweige getrennt.

5. Implementierung

Die aktiven Modalitätsrepräsentationen werden in DeepFusion zusammengeführt. Listing A.10 im Anhang zeigt den für Gating, Fusion und Main Head relevanten Architekturausschnitt.

Das in Abschnitt 4.5.1 konzipierte Gating wird damit unmittelbar auf den normalisierten Modalitätsvektoren umgesetzt. Für jede Modalität berechnet ein zweischichtiges Netz der Form $256 \rightarrow 64 \rightarrow 1$ zunächst einen skalaren Gate-Wert. Ein Softmax über die vorhandenen Modalitäten transformiert diese Werte in relative Gewichte. Die gemeinsame Fusionsrepräsentation ergibt sich anschließend als gewichtete Summe:

$$z_{\text{Fusion}} = \sum_{m=1}^M \alpha_m z_m, \quad \sum_{m=1}^M \alpha_m = 1.$$

Die Gewichte werden damit für jede Eingabe neu aus deren Modalitätsrepräsentationen bestimmt. Neben diesem regulären gating-basierten Forward-Pfad enthält die finale Integrationsimplementierung eine ungewichtete Mittelwertfusion für diagnostische Auswertungen. Von diesem Auswertungsmodus ist die nachfolgende N10-Komponentenablation zu unterscheiden: Dort werden die Equal-Varianten als eigenständige Modelle ohne lernbares Gate trainiert.

Die fusionierte Repräsentation ersetzt die Einzelmodalitäten nicht. Stattdessen erhält der Main Head sowohl die ursprünglichen Modalitätsvektoren als auch z_{Fusion} . Für DUAL entsteht dadurch der 768-dimensionale Eingabevektor

$$[z_{\text{URL}}; z_{\text{TEXT}}; z_{\text{Fusion}}],$$

während TRI mit

$$[z_{\text{URL}}; z_{\text{TEXT}}; z_{\text{DOM}}; z_{\text{Fusion}}]$$

einen 1.024-dimensionalen Eingang verwendet. Der Klassifikationskopf reduziert diese Darstellung zunächst auf 512 und anschließend auf 128 Hidden Units. Zwischen den linearen Schichten werden GELU-Aktivierungen und Dropout mit 0,2 beziehungsweise 0,1 eingesetzt, bevor ein einzelner Hauptlogit erzeugt wird.

Zusätzlich besitzt jede vorhandene Modalität einen eigenen linearen Auxiliary Head. Diese Köpfe arbeiten unmittelbar auf den finalen normalisierten 256-dimensionalen Vektoren z_{URL} , z_{TEXT} und gegebenenfalls z_{DOM} . Ihre Ausgaben werden erst nach der Berechnung des Main Heads erzeugt und gehen weder in die Bestimmung der Gate-Gewichte noch in die Fusion oder als Eingabemerkmale in den Main Head ein. Für den URL-Zweig erzeugt der lineare Auxiliary Head den skalaren Logit

$$f_{\text{URL}} = w_{\text{URL}}^{\top} z_{\text{URL}} + b_{\text{URL}}.$$

5. Implementierung

Höhere Werte entsprechen einer stärkeren Zuordnung zur Phishing-Klasse, niedrigere Werte einer stärkeren Zuordnung zur benignen Klasse. f_{URL} wird nicht als kalibrierte Wahrscheinlichkeit interpretiert, sondern als URL-spezifischer Klassifikationsscore. Dieser Score wird in Abschnitt 5.5 als Routinggröße der URL-first-Kaskade wiederverwendet. Die Auxiliary-Ausgaben bleiben damit vom Main Head und von der Fusionsentscheidung strukturell getrennt.

Die Auxiliary Heads wirken dennoch auf die Parameteroptimierung, da ihre Klassifikationsverluste als zusätzliche Trainingssignale in die Gesamtzielfunktion eingehen. Der Hauptverlust wird um 30 % des mittleren Auxiliary-Loss ergänzt. Die Auxiliary-Verluste werden damit als zusätzliches Trainingssignal verwendet, ohne die Struktur des Main Heads oder die Berechnung der Gate-Gewichte zu verändern.

Für die Optimierung werden Transformerencoder und die übrigen Systemkomponenten in getrennten Parametergruppen geführt. Die freigegebenen URL- und Textencoder werden mit einer Lernrate von $1 \cdot 10^{-5}$ weiteroptimiert. Für Projektions-, DOM-, Gate-, Auxiliary- und Klassifikationskomponenten wird dagegen $2 \cdot 10^{-4}$ verwendet. Beide Gruppen nutzen einen Weight Decay von 0,01; der lineare Warmup umfasst 5 % der vorgesehenen Optimierungsschritte. Die beiden Parametergruppen werden gemeinsam mit AdamW optimiert.

Das reguläre Deep-Training umfasst eine Epoche, Mixed Precision und Gradient Clipping mit maximaler Norm 1,0; als Batch-Fallbacks sind für DUAL 16/8/4 und für TRI 8/4/2 vorgesehen. Die ergänzende Komponentenablation verwendet davon getrennt das nachfolgende feste Kontrollprotokoll.

5.4.1. Sequenzielle Komponentenablation

Für die isolierte FF4-Prüfung wird die Systemfamilie in vier verschachtelte Varianten zerlegt: P0_URL enthält nur den task-adaptierten URL-Zweig, P1_DUAL_EQUAL ergänzt Text mit gleichgewichteter Fusion, P2_TRI_EQUAL zusätzlich den DOM und P3_TRI_GATED dieselben drei Modalitäten mit lernbarem Gating.

Die initialen RUT-URL- und Textcheckpoints sowie der DOM-SSL-Encoder sind über die Replikationen identisch; die im Deep-Training freigegebenen Parameter werden weiterhin überwacht optimiert. Pro Replikation erhalten alle vier Varianten dieselbe balancierte Stichprobe aus 20.000 Labels; zehn Modell- und zehn korrespondierende Ranking-Seeds bilden die gepaarten N10-Läufe. Jede Variante wird eine Epoche mit festem Batch acht trainiert, sodass kein zusätzlicher Unterschied durch OOM-Fallbacks entsteht. Die Schwelle für 0,5 % Ziel-FPR wird ausschließlich auf den benignen Beispielen von ENG_TUNE bestimmt, die primäre TPR auf dem disjunkten ENG_META. CAL und FINAL werden nicht aufgerufen. Protokolliert werden die drei angrenzenden TPR-Kontraste Text, DOM und Gating; Gate-Gewichte dienen nur der ergänzenden Diagnose.

5.5. Implementierung der Kaskade und Messinstrumentierung

Die URL-first-Kaskade nutzt den in Abschnitt 5.4 definierten URL-Auxiliary-Score f_{URL} zur Routingentscheidung. Der Score ist ein unkalibrierter Logit des URL-Auxiliary-Heads und dient innerhalb der Kas-

kade ausschließlich zur Rang- und Schwellenentscheidung. Eine direkte URL-Entscheidung wird nur in den beiden äußeren Bereichen der auf Development beobachteten Scoreverteilung zugelassen. Instanzen im dazwischenliegenden Routingintervall werden an den vollständigen multimodalen Pfad eskaliert.

Die beiden Routinggrenzen werden ausschließlich auf Development-Daten festgelegt. Listing A.2 im Anhang zeigt deren Berechnung.

Die obere Grenze t_{high} wird anhand der benignen URL-Scores so bestimmt, dass sie einem FPR-Ziel von 0,1 % auf Development entspricht. Scores oberhalb dieser Grenze werden direkt der Phishing-Klasse zugeordnet. Die untere Grenze t_{low} wird aus dem unteren Prozent der positiven URL-Scoreverteilung abgeleitet. Scores unterhalb dieser Grenze werden direkt als benign eingeordnet. Beide Grenzen sichern damit unterschiedliche direkte Entscheidungen ab: t_{high} kontrolliert den oberen, phishingnahen Scorebereich anhand der benignen Instanzen, während t_{low} den unteren, benignnahen Bereich anhand der positiven Scoreverteilung abgrenzt.

Für eine Instanz x ergibt sich die Routingentscheidung damit als

$$\text{route}(x) = \begin{cases} \text{Benign,} & f_{\text{URL}}(x) \leq t_{\text{low}}, \\ \text{TRI-Full-Pfad,} & t_{\text{low}} < f_{\text{URL}}(x) < t_{\text{high}}, \\ \text{Phishing,} & f_{\text{URL}}(x) \geq t_{\text{high}}. \end{cases}$$

Der Bereich zwischen beiden Grenzen wird als Unsicherheitsbereich der Kaskade bezeichnet. Dabei handelt es sich nicht um ein probabilistisch kalibriertes Unsicherheitsmaß, sondern um ein empirisch auf Development bestimmtes Scoreintervall, innerhalb dessen keine direkte URL-basierte Entscheidung getroffen wird. Die Routinggrenzen sind zudem vom später auf CAL bestimmten 0,5-%-Betriebspunkt des finalen Klassifikators zu unterscheiden.

Listing A.3 im Anhang zeigt die entsprechende Routinglogik.

Die Kaskade setzt damit nicht voraus, dass der URL-Zweig über den gesamten Datenbestand dieselbe Klassifikationsleistung wie das multimodale Vollsistem erreicht. Der URL-Score wird nur für die auf Development abgegrenzten äußeren Scorebereiche als direkte Entscheidungsgrundlage verwendet. Für den verbleibenden Zwischenbereich bleibt die vollständige multimodale Verarbeitung erhalten. Dadurch können eindeutige URL-Fälle früh abgeschlossen werden, ohne HTML-Text, DOM und Fusion für alle Instanzen auszuführen.

Für eskalierte Instanzen wird die bereits berechnete URL-Repräsentation nicht erneut erzeugt. Stattdessen wird z_{URL} für die betroffenen Zeilen wiederverwendet und um den HTML-Text-Zweig sowie in der TRI-Variante den DOM-Zweig ergänzt. Die entstehenden Modalitätsvektoren durchlaufen anschließend dieselbe gating-basierte Fusion und denselben Main Head wie im vollständigen Deep-System. Die Kaskade verändert damit weder die zugrunde liegenden Repräsentationen noch die Fusionslogik, sondern ausschließlich den für eine Instanz tatsächlich ausgeführten Berechnungspfad.

Bei der Reproduktion sind Datentyp und Grenzwertbehandlung Teil des Protokolls: die gespeicherten Kaskadenscores beruhen auf Float32-Logits und der damaligen NumPy-Skalarumwandlung. Eine nachträgliche Umstellung des Routingvergleichs auf Float64 ändert bei gebundenen Scores die Eskalationsmenge. Das digitale Prüfskript setzt die Routinggrenzen deshalb explizit auf Float32, während der abschließende CAL-Klassifikationsvergleich wie im Originalcode in Float64 erfolgt.

Die Kaskadenkonfiguration wird auf Development-Daten festgelegt; kontrolliert werden TPR-Verlust, Eskalationsrate und Fehlalarmrate gegenüber dem Vollpfad. Erst diese Konfiguration geht in den Architecture-Freeze ein, sodass CAL und FINAL nicht zur nachträglichen Optimierung der Routinggrenzen verwendet werden.

Nach drei Warm-up-Durchläufen wird die Einzelinstanzlatenz für 500 Webseiten bei Batchgröße eins gemessen; CUDA wird vor der Zeitmessung synchronisiert. Berichtet werden Median und 95. Perzentil. Der Durchsatz wird auf 5.000 Webseiten bei Batchgröße 32 über drei Wiederholungen bestimmt; zusätzlich wird Peak-VRAM erfasst. Der Benchmark umfasst nur den aufbereiteten In-Memory-Modellpfad ohne Netzwerkzugriffe, Browser-Rendering, Datenträger-I/O und vorgelagerte HTML-Verarbeitung.

Die Kaskade wird zusätzlich mit URL_BASE und URL_TAPT als Frontend ausgeführt; TRI-Fallback und Routinglogik bleiben unverändert. Auf Development-Daten werden Routingparameter für erlaubte TPR-Abweichungen von primär 1,0 sowie 0,25, 0,5 und 2,0 Prozentpunkten bestimmt. Fünf Systemläufe werden über alle fünf finalen Bedingungen bewertet. Zentrale Kennzahl ist die Eskalationsrate beziehungsweise der Anteil vermiedener Full-Path-Ausführungen; die TPR-Vorgabe beschreibt die auf Development festgelegte Toleranz und keine identische realisierte Test-TPR.

5.6. Artefaktbereitstellung und Reproduzierbarkeit

Seeds, deterministische Datenpartitionierungen sowie gespeicherte Checkpoints, Embeddings, Scores und Auditdateien dokumentieren die einzelnen Verarbeitungsschritte. Bereits abgeschlossene Schritte werden durch Completion-Marker gekennzeichnet, sodass ein unterbrochener Lauf an definierten Stellen fortgesetzt werden kann. Die Datei ARCHITECTURE_FREEZE.json hält die auf Development getroffenen Systementscheidungen fest, bevor CAL und FINAL verwendet werden. Beim Übergang in die abschließende Evaluationsphase wird zusätzlich erneut die SHA-256-Disjunktheit der Datenrollen geprüft.

Für die ergänzte Labelbudgetanalyse und die FF4-Komponentenablation werden Analyseplan, Seeds, Testgruppen und Schwellenlogik vor der jeweiligen Ausführung gespeichert. Anschließend Coverage-Audits prüfen, ob die erwarteten Ergebnisdateien für alle vorgesehenen Varianten und Wiederholungen vorliegen. Bei fehlenden Ergebnissen wird die Auswertung abgebrochen. Dadurch lassen sich die in Kapitel 6 berichteten Ergebnisse ihren jeweiligen Konfigurationen und Versuchsständen eindeutig zuordnen.

6. Empirische Evaluation

Dieses Kapitel berichtet die Ergebnisse entlang der vier Forschungsfragen. Zunächst wird der zusätzliche Nutzen der task-adaptiven Repräsentationsanpassung untersucht (FF1) und über unterschiedliche Labelbudgets weiterverfolgt (FF2). FF3 prüft anschließend, ab welchem reduzierten Labelbudget die kombinierte RUT-Repräsentation das Niveau vollständig mit 200.000 Labels trainierter Referenzen über alle fünf Evaluationsbedingungen erreicht. FF4 wechselt auf die Systemebene und untersucht die zusätzlichen Beiträge von HTML-Text, DOM und Gating sowie die Auswirkungen der URL-first-Kaskade auf Leistung und Inferenzaufwand. Konfidenzintervalle, p-Werte und gegebenenfalls korrigierte p-Werte werden unmittelbar bei den jeweiligen Ergebnissen berichtet. Abschnitt 6.6 ergänzt die Auswertung um eine Unsicherheits- und Prävalenzordnung der finalen Rankingmetriken.

6.1. Versuchsrahmen

Die Evaluation verwendet den in Abschnitt 4.2 definierten Data Freeze mit insgesamt 442.060 Rolleninstanzen. Davon entfallen 4.000 Instanzen auf SUP, 20.000 auf DEV, 200.000 auf den für TAPT und die nachgelagerte Labelbudgetanalyse verwendeten SSL-Pool, 50.000 ausschließlich legitime Instanzen auf CAL sowie 168.060 Instanzen auf FINAL. Die ursprüngliche Repräsentations- und Systementwicklung wurde vor dem Zugriff auf CAL und FINAL abgeschlossen. Die später ergänzten Labelbudget-, Komponenten- und Sensitivitätsanalysen werden entsprechend der in Abschnitt 4.6 beschriebenen zeitlichen Reihenfolge getrennt ausgewiesen.

Für FINAL wird die TPR bei einer auf CAL für 0,5 % FPR bestimmten Schwelle berichtet. Die DEV-Auswertungen von FF1 und FF2 verwenden dagegen die interne Teilung REP_CAL/REP_EVAL; die FF4-Komponentenablation nutzt ENG_TUNE/ENG_META. Die Schwelle wird für die FINAL-Auswertung nicht erneut angepasst. Neben OFFICIAL_TEST werden DOMAIN_OOD_EXACT, TEMPLATE_OOD_EXACT, DOMAIN_TEMPLATE_OOD_EXACT und LATE_TEST_Q4 ausgewertet. Die jeweiligen Umfänge betragen 168.060, 115.917, 161.223, 110.095 und 46.784 Webseiten. Die vier Teilmengen prüfen unterschiedliche Eigenschaften der Testdaten; aus ihrer Reihenfolge wird keine Schwierigkeitsskala abgeleitet. FF1 und die ursprünglichen Lernkurven von FF2 beruhen auf fünf gepaarten Wiederholungen. Für den zentralen Equal-Budget-Vergleich und die Labelbudgetanalyse werden fünf weitere Wiederholungen ergänzt. N10 variiert damit Labelauswahl und Downstream-Training bei unveränderten TAPT-Checkpoints. Die sequenzielle FF4-Komponentenablation verwendet zehn neu festgelegte gepaarte Replikationen auf Development-Daten. Der Frontend-Vergleich der Kaskade basiert auf fünf Systemläufen.

6.2. FF1: Task-adaptive Repräsentationsanpassung

FF1 vergleicht die vier in Abschnitt 4.3.1 definierten Repräsentationszustände R0, RT, RU und RUT mit identischen 20.000 gelabelten Trainingsinstanzen und korrespondierenden Seeds. R0 kombiniert dabei die allgemein selbstüberwacht vortrainierten Basisencoder. Geändert wird ausschließlich, ob URL,

HTML-Text oder beide Modalitäten zusätzlich mittels TAPT angepasst wurden. Mit der linearen Probe steigt die mittlere TPR am festgelegten Low-FPR-Betriebspunkt von 81,35 % für R0 auf 87,56 % für RT und 88,95 % für RU; RUT erreicht 90,05 %. Mit der MLP-Probe ergibt sich dasselbe Rangmuster mit 91,17 % für RUT. Die mittleren RUT–R0-Differenzen betragen damit +8,70 beziehungsweise +8,73 Prozentpunkte. Die faktorielle Interaktion

$$(RUT - RT) - (RU - R0)$$

beträgt jedoch –5,10 Prozentpunkte für die lineare Probe und –2,83 Prozentpunkte für die MLP-Probe. Die isolierten Adaptationsgewinne von URL und HTML-Text addieren sich damit nicht vollständig.

Tabelle 6.1.: FF1: DEV-Ergebnisse bei 20.000 Labels, Mittelwerte über fünf Wiederholungen.

Probe	Rep.	TPR@0,5 % FPR	FPR	FPR@TPR90
Linear	R0	81,35 %	0,53 %	1,316 %
Linear	RT	87,56 %	0,64 %	0,908 %
Linear	RU	88,95 %	0,42 %	0,480 %
Linear	RUT	90,05 %	0,42 %	0,408 %
MLP	R0	82,44 %	0,58 %	1,360 %
MLP	RT	86,68 %	0,63 %	0,956 %
MLP	RU	89,76 %	0,51 %	0,492 %
MLP	RUT	91,17 %	0,49 %	0,412 %

Auch aus der umgekehrten Betriebspunktperspektive ergibt sich dasselbe Bild. Wird die TPR auf mindestens 90 % angehoben, gibt FPR@TPR90 die False-Positive-Rate am ersten entsprechenden ROC-Punkt an; niedrigere Werte sind entsprechend günstiger. RUT erreicht mit 0,408 % beziehungsweise 0,412 % die niedrigste mittlere FPR beider Probes. Die Repräsentationsauswahl wird damit durch zwei komplementäre Low-FPR-Perspektiven gestützt. Bei fünf Beobachtungspaaren beträgt der kleinste mögliche zweiseitige p-Wert des exakten Sign-Flip-Tests 0,0625. Die inferenzstatistische Prüfung des zentralen RUT–R0-Vergleichs erfolgt mit zehn Beobachtungspaaren auf FINAL in Abschnitt 6.4. Wegen der anderen Evaluationspopulation ist dies keine inferenzstatistische Nachprüfung desselben DEV-Effekts.




Abbildung 6.1.: FF1: TPR der vier Repräsentationsvarianten mit linearer und MLP-Downstream-Probe. Eigene Darstellung; KI-unterstützt.

6.3. FF2: Einfluss der Labelverfügbarkeit

FF2 untersucht den Repräsentationsvergleich über sieben verschachtelte Labelbudgets von 2.000 bis 200.000 Instanzen. Die Encoder bleiben je Repräsentationszustand unverändert; variiert wird ausschließlich die gelabelte Downstream-Supervision.

Tabelle 6.2.: FF2: Mittlere FINAL-TPR der linearen Probe über die Labelbudgets.

Labels	R0	RT	RU	RUT
2.000	51,64%	52,91%	58,62%	60,94%
5.000	62,10%	65,07%	65,21%	67,96%
10.000	68,00%	71,28%	71,10%	73,51%
20.000	71,63%	75,90%	75,20%	77,73%
50.000	75,12%	79,32%	78,97%	82,01%
100.000	76,99%	81,04%	81,36%	84,04%
200.000	77,92%	82,26%	83,40%	85,72%

Für die lineare Probe zeigt sich über das gesamte Budgetraster ein Vorteil von RUT gegenüber R0. Die mittlere FINAL-TPR steigt für RUT von 60,94 % bei 2.000 Labels auf 77,73 % bei 20.000 und 85,72 % bei 200.000 Labels; R0 erreicht an denselben Punkten 51,64 %, 71,63 % und 77,92 %.

Auch mit der nichtlinearen MLP-Probe bleibt dieses Rangmuster bestehen. Der Abstand zwischen RUT und R0 beträgt bei 2.000 Labels 10,77 Prozentpunkte, bei 20.000 Labels 8,59 Prozentpunkte und bei 200.000 Labels noch 5,30 Prozentpunkte.

Tabelle 6.3.: FF2: Mittlere FINAL-TPR der MLP-Probe über die Labelbudgets.

Labels	R0	RT	RU	RUT
2.000	42,31%	43,34%	50,30%	53,08%
5.000	53,68%	55,44%	60,49%	63,32%
10.000	60,94%	63,64%	67,23%	69,81%
20.000	68,27%	72,24%	74,67%	76,86%
50.000	78,85%	82,06%	83,63%	85,31%
100.000	82,40%	86,33%	87,09%	89,89%
200.000	84,95%	87,88%	88,35%	90,25%

Der Vorteil der task-adaptierten Repräsentation bleibt damit bei beiden Downstream-Klassifikatoren über sämtliche untersuchten Labelbudgets bestehen. Auf DEV erreicht RUT als ergänzende Sättigungsperspektive mit der linearen Probe 95 % des eigenen 200k-Niveaus bereits bei 10.000 Labels, während R0 hierfür 50.000 Labels benötigt. Beim MLP liegen die entsprechenden B95-Punkte bei 50.000 beziehungsweise 100.000 Labels. Auf FINAL liegt B95 dagegen für R0 und RUT jeweils bei 50.000 Labels mit der linearen Probe und bei 100.000 Labels mit dem MLP. Die frühere relative Sättigung von RUT auf DEV überträgt sich somit nicht auf diese FINAL-Kennzahl. Da B95 jeweils auf das eigene Endniveau einer Variante bezogen ist, wird die absolute Performance-Suffizienz gegenüber vollständig trainierten Referenzen erst in FF3 geprüft. Zur zusätzlichen Prüfung der Label-Effizienz außerhalb des PhreshPhish-Datenbestands werden R0 und RUT auf dem unabhängig erhobenen Phishing Website Dataset von Putra (2023) verglichen. Auf dem zeitlich früheren Datenbestand werden identische, verschachtelte Stichproben von 200,

500, 1.000 und 2.000 gelabelten Webseiten für zehn gepaarte Linear-Probes verwendet und auf dem zeitlich späteren Bestand ausgewertet. Über die gesamte externe Lernkurve erreicht RUT eine mittlere AP-AULC von 91,98 % gegenüber 89,45 % für R0. Die gepaarte Differenz beträgt +2,54 Prozentpunkte (95 %-KI [2,16; 2,91], 10/10 positive Paare, $p = 0,001953$).

Tabelle 6.4.: FF2: Externe Label-Effizienz von R0 und RUT auf dem Putra-Datensatz.

Labels	R0 AP	RUT AP	Δ AP	95 %-KI
200	83,91%	86,51%	+2,60 pp	[1,70; 3,51]
500	88,96%	91,76%	+2,79 pp	[2,22; 3,36]
1.000	91,70%	94,05%	+2,35 pp	[2,02; 2,69]
2.000	93,40%	95,61%	+2,21 pp	[1,85; 2,56]

Die zusätzliche Zielanpassung von Quell-RUT auf dem frühen Putra-Pool verbessert dieses Ergebnis nicht. Ihre mittlere AP-AULC fällt von 91,98 % auf 90,84 %; die gepaarte Differenz beträgt $-1,14$ Prozentpunkte (95 %-KI $[-1,50; -0,78]$, zehn negative Paare, $p = 0,001953125$). Die budgetweisen AP-Differenzen betragen bei 200, 500, 1.000 und 2.000 Labels $-2,28$, $-1,31$, $-0,49$ und $-0,51$ Prozentpunkte. Auch diese vier Unterschiede bleiben nach Holm-Korrektur signifikant ($p_{\text{Holm}} \leq 0,01171875$). Der Vorteil von Quell-RUT gegenüber R0 und die Verschlechterung durch eine weitere Zielanpassung betreffen verschiedene Interventionen; der zweite Befund begrenzt eine pauschale Empfehlung wiederholten TAPT.

RUT erreicht damit an allen vier externen Labelbudgets eine höhere mittlere AP. Sämtliche budgetweisen Vergleiche bleiben nach Holm-Korrektur signifikant ($p_{\text{Holm}} = 0,007812$). Der innerhalb von PhreshPhish beobachtete Vorteil der task-adaptierten Repräsentation bleibt somit auch unter begrenzter gelabelter Supervision auf dem unabhängig erhobenen Webseitenbestand bestehen. Abbildung 6.2 fasst abschließend die internen Lernkurven der vier Repräsentationsvarianten zusammen. Die externe Putra-Auswertung wird aufgrund des abweichenden Budgetrasters separat in Tabelle 6.4 ausgewiesen.




Abbildung 6.2.: FF2: Lernkurven der Repräsentationsvarianten über die sieben Labelbudgets mit linearer und MLP-Probe.

Eigene Darstellung; KI-unterstützt.

6.4. FF3: Erreichen des 200k-Referenzniveaus

FF3 verbindet die Labelkurven mit den fünf Evaluationsbedingungen. Zunächst wird der zentrale Vergleich zwischen RUT und R0 bei 20.000 Labels auf zehn gepaarte Wiederholungen erweitert. Auf OFFICIAL_TEST erreicht RUT eine TPR von 77,51 % gegenüber 71,43 % für R0. Die mittlere gepaarte Differenz beträgt damit +6,08 Prozentpunkte (95%-KI [5,38; 6,79]); alle zehn Paare zeigen einen positiven Unterschied ($p = 0,001953$).

Auch auf Domain-OOD, Template-OOD, Domain+Template-OOD und Late Q4 liegt RUT über R0. Die mittleren Unterschiede betragen +5,64, +6,26, +5,89 und +5,51 Prozentpunkte. Die vier p-Werte bleiben nach Holm-Korrektur signifikant ($p_{\text{Holm}} = 0,007812$). Gleichzeitig ist die mittlere FPR von RUT in allen fünf Bedingungen niedriger als diejenige von R0.

Anschließend wird RUT über das vollständige Budgetraster mit zwei Referenzen verglichen, die jeweils mit 200.000 Labels trainiert wurden. Gegen R0@200k bleiben Repräsentationsformat und Linear Probe identisch. Ein RUT-Budget wird nur dann als ausreichend bewertet, wenn die festgelegte Nichtunterlegenheitsbedingung von einem Prozentpunkt in allen fünf Evaluationsbedingungen erfüllt wird und die anschließende Holm-Korrektur über die sieben Budgetentscheidungen bestehen bleibt. Abbildung 6.3 zeigt die absoluten mittleren TPR-Werte der RUT-Repräsentation über die fünf Evaluationsbedingungen und ausgewählte Trainingsbudgets. Die Werte steigen in allen Bedingungen mit wachsendem Labelbudget. Die Darstellung allein legt jedoch noch keine ausreichende Budgetstufe fest; hierfür ist der statistische Vergleich mit den beiden 200k-Referenzen maßgeblich.




Abbildung 6.3.: FF3: Mittlere RUT-TPR über fünf Evaluationsbedingungen und ausgewählte Labelbudgets, N10-Mittelwerte.

Eigene Darstellung; KI-unterstützt.

Gegen R0@200k reichen 20.000 Labels nach dieser Entscheidungsregel noch nicht aus. Der ungünstigste mittlere TPR-Abstand tritt auf Late Q4 auf und beträgt −1,37 Prozentpunkte. Mit 50.000 Labels wird die Nichtunterlegenheitsbedingung dagegen in allen fünf Bedingungen erfüllt; die korrigierte Entscheidung bleibt nach Holm signifikant ($p_{\text{Holm}} = 0,006836$). Die mittlere TPR von RUT50k liegt dabei in allen fünf Bedingungen um +3,24 bis +3,62 Prozentpunkte über R0@200k. Gleichzeitig fällt die mittlere realisierte FPR um 0,079 bis 0,180 Prozentpunkte niedriger aus. Als zweite Referenz dient die unabhängig trainierte TF-IDF/XGBoost-Pipeline mit 200.000 Labels. Tabelle 6.5 zeigt die Ergebnisse für die beiden RUT-Budgets von 20.000 und 50.000 Labels. Bereits RUT20k erreicht in allen fünf Bedingungen mindes-

tens die mittlere XGBoost-TPR und zugleich eine niedrigere mittlere FPR. Der kleinste TPR-Vorsprung beträgt auf Late Q4 allerdings nur +0,09 Prozentpunkte.

Die fünf einzelnen Nichtunterlegenheitstests für RUT20k erfüllen jeweils die 1-pp-Bedingung, die gemeinsame Budgetentscheidung erreicht nach der Holm-Korrektur über alle sieben getesteten Budgets jedoch nicht das festgelegte Signifikanzniveau ($p_{\text{Holm}} = 0,173233$). RUT20k übertrifft XGBoost@200k damit deskriptiv in allen fünf betrachteten Bedingungen, reicht für die strengere statistische Budgetentscheidung jedoch nicht aus.

Tabelle 6.5.: FF3: RUT bei 20k und 50k Labels gegenüber TF-IDF/XGBoost@200k, N10-Mittelwerte.

Bedingung	XGB@200k		RUT20k		RUT50k	
	TPR	FPR	TPR	FPR	TPR	FPR
Official	76,96 %	0,618 %	77,51 %	0,520 %	81,55 %	0,537 %
Domain-OOD	76,98 %	1,219 %	78,21 %	0,951 %	82,19 %	0,979 %
Template-OOD	76,75 %	0,604 %	77,38 %	0,516 %	81,63 %	0,533 %
Domain+Template	76,75 %	1,186 %	78,14 %	0,938 %	82,33 %	0,966 %
Late Q4	73,97 %	1,127 %	74,06 %	0,681 %	79,04 %	0,728 %

Mit 50.000 Labels wird die Nichtunterlegenheitsbedingung gegenüber XGBoost@200k in allen fünf Bedingungen erfüllt. Der gemeinsame p-Wert beträgt $2,561 \times 10^{-6}$ und nach Holm-Korrektur $1,281 \times 10^{-5}$. Die mittlere TPR von RUT50k liegt je nach Bedingung um +4,59 bis +5,58 Prozentpunkte höher, während gleichzeitig eine um 0,071 bis 0,398 Prozentpunkte niedrigere FPR erreicht wird.

50.000 Labels sind damit die kleinste untersuchte RUT-Stufe, die die festgelegte Nichtunterlegenheitsbedingung sowohl gegenüber R0@200k als auch gegenüber TF-IDF/XGBoost@200k über alle fünf Evaluationsbedingungen erfüllt. Gegenüber einem Labelbudget von 200.000 Instanzen entspricht dies einer Reduktion der gelabelten Downstream-Trainingsmenge um 75 %. Der vorausgehende TAPT-Schritt auf 200.000 ungelabelten Webseiten bleibt davon unberührt.

Die ergänzende Sensitivitätsanalyse mit TPR-Margen von 0,0, 0,5, 1,0 und 2,0 Prozentpunkten bestätigt die Stabilität dieser Budgetentscheidung. In allen vier Fällen bleiben 50.000 Labels die kleinste RUT-Stufe, die die jeweilige Testentscheidung gegenüber beiden 200k-Referenzen erfüllt. Auch ohne zugelassenen TPR-Nachteil ($\Delta = 0,0$ pp) bleibt RUT50k gegenüber R0@200k ($p_{\text{Holm}} = 0,006836$) und TF-IDF/XGBoost@200k ($p_{\text{Holm}} = 6,286 \times 10^{-5}$) statistisch gestützt. RUT20k reicht gegenüber R0@200k selbst bei einer auf 2,0 Prozentpunkte erweiterten Marge nicht aus ($p_{\text{Holm}} = 0,593750$); gegenüber XGBoost@200k wird 20k erst bei dieser 2-pp-Marge statistisch gestützt ($p_{\text{Holm}} = 0,008464$). Die gemeinsame 50k-Entscheidung bleibt damit über den untersuchten Margenbereich von 0 bis 2 Prozentpunkten unverändert.

Abbildung 6.4 stellt für beide Referenzen jeweils den ungünstigsten mittleren TPR-Abstand über die fünf Evaluationsbedingungen dar. Bei 20.000 Labels liegt RUT gegenüber XGBoost bereits knapp oberhalb der Null-Linie, gegenüber R0@200k jedoch noch unter der festgelegten Marge. Ab 50.000 Labels sind die mittleren Abstände zu beiden Referenzen in allen Bedingungen positiv.




Abbildung 6.4.: FF3: Schlechtester mittlerer TPR-Abstand von RUT gegenüber R0@200k und TF-IDF/XGBoost@200k über die fünf Evaluationsbedingungen.

Eigene Darstellung; KI-unterstützt.

6.5. FF4: Inkrementeller Systembeitrag und URL-first-Verarbeitung

FF4 untersucht den zusätzlichen Beitrag der einzelnen Systembestandteile. Hierfür wird RUT als gemeinsame Repräsentationsbasis verwendet und auf getrennten Development-Daten eine Folge von vier Varianten verglichen: URL-only (P_0), URL+Text mit gleichgewichteter Fusion (P_1), URL+Text+DOM mit gleichgewichteter Fusion (P_2) und dieselben drei Modalitäten mit lernbarem Gating (P_3). Alle Varianten erhalten innerhalb einer Replikation dieselben 20.000 Labels und werden über zehn gepaarte Wiederholungen verglichen. CAL und FINAL werden für diese Analyse nicht verwendet.

Die mittlere TPR steigt entlang dieser Varianten von 87,932 % auf 93,116 %, 93,844 % und schließlich 94,420 %. Den größten zusätzlichen Beitrag liefert der HTML-Text: $P_1 - P_0$ beträgt +5,184 Prozentpunkte (95%-KI [4,324; 6,044], 10/10 positive Paare). Durch den DOM-Zweig steigt die TPR um weitere +0,728 Prozentpunkte (95%-KI [0,305; 1,151], 10/10 positive Paare). Der Übergang von gleichgewichteter zu lernbarer Gating-Fusion erhöht sie um weitere +0,576 Prozentpunkte (95%-KI [0,226; 0,926], 9/10 positive Paare). Alle drei Vergleiche bleiben nach der gemeinsamen Holm-Korrektur signifikant ($p_{\text{Holm}} = 0,00585938$). Die realisierte ENG_META-FPR steigt entlang der Varianten leicht von 0,400 % auf 0,616 %; gleichzeitig sinkt FPR@TPR90 von 0,528 % auf 0,260 %.

Die Komponentenablation wurde nach Festlegung der finalen Architektur ergänzend durchgeführt und diente nicht zu deren nachträglicher Auswahl. Sie zeigt jedoch, dass jeder der drei hinzugefügten Bestandteile im festgelegten Vergleich einen positiven zusätzlichen Beitrag leistet. Passend dazu erreicht die bereits eingefrorene Gated-TRI-Konfiguration auch auf FINAL in allen fünf Bedingungen eine höhere TPR als die gleichgewichtete Fusion. Auf OFFICIAL_TEST steigt die TPR von 95,65 % auf 96,12 %; in den vier zusätzlichen Bedingungen beträgt der Unterschied 0,38 bis 0,54 Prozentpunkte. Für die Systemperspektive wird anschließend das eingefrorene TRI-Vollsystem mit der bereits vor dem FINAL-Zugriff festgelegten URL-first-Kaskade verglichen. Auf OFFICIAL_TEST erreicht TRI Full 96,12 % TPR bei 0,666 % FPR, die Kaskade 95,77 % TPR bei 0,680 % FPR. Die eingefrorene Routingkonfiguration eskaliert 14,93 % der Webseiten; für 85,07 % wird die Entscheidung bereits nach der URL-Stufe abgeschlossen.

6. Empirische Evaluation

sen. Im In-Memory-Benchmark sinkt die Median-Latenz von 30,18 auf 11,95 ms und der Durchsatz steigt von 183,2 auf 447,0 Seiten/s, entsprechend dem 2,44-Fachen.

Tabelle 6.6.: FF4: In-Memory-Benchmark des mit 200k Labels trainierten Vollsystems und seiner eingefrorenen URL-first-Kaskade.

Kennzahl	TRI Full	TRI-Kaskade
TPR, Official	96,12 %	95,77 %
FPR, Official	0,666 %	0,680 %
Eskalation, Official	100,00 %	14,93 %
Median-Latenz, DEV, Batch 1	30,18 ms	11,95 ms
95. Perzentil, DEV, Batch 1	47,40 ms	32,14 ms
Durchsatz, DEV, Batch 32	183,18 Seiten/s	447,02 Seiten/s
Durchsatz-Standardabweichung, drei Läufe	1,32 Seiten/s	2,95 Seiten/s
Peak-VRAM, DEV, Batch 1	1.022,32 MiB	966,77 MiB
Peak-VRAM, DEV, Batch 32	1.199,81 MiB	1.051,72 MiB

Der ergänzende Frontend-Vergleich untersucht anschließend eine andere Frage. TRI-Fallback und Routinglogik bleiben gleich; lediglich die URL-Repräsentation wird zwischen URL_BASE und URL_TAPT variiert. Für beide Varianten werden auf Development dieselben zulässigen TPR-Abweichungen gegenüber dem Vollsistem verwendet. Diese Analyse ist von der zuvor eingefrorenen Kaskadenkonfiguration mit einer Eskalationsrate von 14,93 % zu unterscheiden; die absoluten Eskalationsraten beider Versuchsblöcke sind deshalb nicht direkt miteinander vergleichbar.

Abbildung 6.5 fasst die beiden für FF4 zentralen Architektur- und Ressourcenbefunde zusammen. Panel (a) zeigt die sequenzielle Komponentenablation, Panel (b) die mittlere Eskalationsrate auf dem vollständigen Official-Testbestand über die vier untersuchten TPR-Toleranzen.




Abbildung 6.5.: FF4: Sequenzielle Komponentenablation und URL-first-Frontendvergleich von URL_BASE und URL_TAPT.

Eigene Darstellung; KI-unterstützt.

Bei der primären Toleranz von einem Prozentpunkt sinkt der ungewichtete Szenariomittelwert der Eskalationsrate mit dem task-adaptierten URL-Frontend von 41,125 % auf 28,728 %. Die fünf Szenarien überlappen; dieser Makromittelwert beschreibt deshalb keine disjunkte Gesamtpopulation. Der Unterschied beträgt 12,397 Prozentpunkte. Der entsprechende Makromittelwert des Anteils früher URL-Entscheidungen beträgt 71,272 %. Die niedrigere Eskalationsrate von URL_TAPT zeigt sich in allen fünf Evaluationsbedingungen und liegt dort zwischen 10,810 und 13,438 Prozentpunkten unter URL_BASE. Die mittlere TPR-Abweichung vom Vollsistem beträgt $-0,791$ Prozentpunkte, die mittlere FPR-Differenz $-0,014$ Pro-

zentpunkte. Unter derselben auf Development festgelegten TPR-Toleranz benötigt das task-adaptierte URL-Frontend damit seltener die nachgelagerte vollständige multimodale Verarbeitung.

Auf dem vollständigen OFFICIAL_TEST beträgt die mittlere Eskalationsrate 35,746 % für URL_BASE und 23,514 % für URL_TAPT (Differenz $-12,232$ Prozentpunkte, fünf Läufe). URL_TAPT schließt dort 76,486 % der Webseiten im URL-Pfad ab. Gegenüber dem Vollsistem beträgt die TPR-Differenz $-0,940$ und die FPR-Differenz $+0,016$ Prozentpunkte. Die niedrigere Eskalation geht somit mit einem kleinen Qualitätsverlust gegenüber dem Vollsistem einher; die auf DEV gewählte Toleranz garantiert keine identische Test-TPR.

6.6. Ergänzende Unsicherheits- und Prävalenzeinordnung

Ergänzend zur Betriebspunktanalyse werden AP und $P_{\geq 90}$ auf dem festen OFFICIAL_TEST mit 1.000 stratifizierten Bootstrap-Replikationen ausgewertet. TRI Full erreicht eine AP von 99,679 % mit einem 95-%-Percentile-Intervall von [99,659; 99,700] % sowie ein $P_{\geq 90}$ von 99,714 % [99,673; 99,753] %. Die Kaskade erreicht eine AP von 98,539 % [98,476; 98,602] % und ein $P_{\geq 90}$ von 99,776 % [99,742; 99,815] %. Die engen Intervalle zeigen eine geringe Stichprobenunsicherheit dieser Rankingmetriken auf dem festen Testbestand. Für die absolute Höhe precision-basierter Kennzahlen ist zusätzlich die Klassenprävalenz relevant, also der Anteil phishingbezogener Webseiten innerhalb der Evaluationsmenge. Der OFFICIAL_TEST enthält 76.800 Phishing- und 91.260 Benign-Instanzen und weist damit einen Phishing-Anteil von 45,70 % auf. Dies entspricht nahezu der für den regulären PhreshPhish-Testbestand berichteten Base Rate von 46 % (vgl. [Dalton et al. (2026), S. 6–7]). Zur Einordnung wird deshalb eine reine Base-Rate-Sensitivität von $P_{\geq 90}$ berechnet. Für die ausgewählte Schwelle werden die klassenspezifischen Scoreverteilungen konstant gehalten und ausschließlich die angenommene Prävalenz verändert. Mit der beobachteten Precision P_0 und der Testprävalenz $\pi_0 = 76.800/168.060$ gilt

$$\lambda = \frac{1 - P_0}{P_0} \frac{\pi_0}{1 - \pi_0} = \frac{\text{FPR}_*}{\text{TPR}_*}, \quad \text{Precision}_\pi = \frac{\pi}{\pi + (1 - \pi)\lambda}.$$

Hierbei kennzeichnet * die für $P_{\geq 90}$ ausgewählte empirische Schwelle. Die Umrechnung benötigt keinen Recall von exakt 90 %. Sie bildet einen reinen Prior-Shift ab; Veränderungen des klassenspezifischen Fehlerverhaltens sind darin nicht enthalten.

Tabelle 6.7.: Base-Rate-Sensitivität von $P_{\geq 90}$.

Phishing-Base-Rate	TRI Full	TRI-Kaskade
45,70 %	99,714 %	99,776 %
5 %	95,62 %	96,54 %
1 %	80,74 %	84,27 %

Die rechnerischen Werte bei 1 % Base Rate betragen 80,74 % für TRI Full und 84,27 % für die Kaskade. Sie sind keine Messungen auf einem neu erhobenen Bestand mit dieser Prävalenz. Ein direkter Vergleich mit separat konstruierten PhreshPhish-Benchmarks wäre wegen unterschiedlicher Testzusammensetzung und nicht abgeglichenen Metrikimplementierung nicht belastbar. Die primäre Systembewertung stützt sich weiterhin auf TPR und FPR am festgelegten Betriebspunkt.

6.7. Szenarioanalyse am eingefrorenen Betriebspunkt

Für die betriebliche Prüfmenge ist die Precision an der tatsächlich auf CAL festgelegten Schwelle maßgeblich. Die für $P_{\geq 90}$ ausgewählte Schwelle aus Abschnitt 6.6 ist davon zu unterscheiden. Aus den FINAL-Rohscores und Labels ergeben sich für TRI Full 73.819 TP, 608 FP und 2.981 FN sowie für die Kaskade 73.551 TP, 621 FP und 3.249 FN. Bei 76.800 Phishing- und 91.260 benignen Seiten entsprechen diese Counts den in FF4 berichteten Betriebsraten. Für ein angenommenes Volumen N auswertbarer Webseiten und einen Phishinganteil π werden daraus folgende Erwartungswerte berechnet:

$$TP_{\pi} = N\pi \text{ TPR}, \quad FP_{\pi} = N(1 - \pi) \text{ FPR}, \quad FN_{\pi} = N\pi(1 - \text{TPR}).$$

Die modellseitige Alarmmenge beträgt $A_{\pi} = TP_{\pi} + FP_{\pi}$ und ihre Precision TP_{π}/A_{π} . Tabelle 6.8 verwendet ausschließlich ungerundete Ausgangsraten. Die gewählten Prävalenzen und 10.000 Seiten sind Vergleichsszenarien und keine Messwerte eines Unternehmens.

Tabelle 6.8.: Erwartete Fallzahlen je 10.000 auswertbaren Webseiten am eingefrorenen Betriebspunkt bei reinem Prior-Shift.

Phishinganteil	System	TP	FP	FN	Alarme	Precision
0,1 %	TRI Full	9,61	66,56	0,39	76,17	12,62 %
	Kaskade	9,58	67,98	0,42	77,56	12,35 %
1 %	TRI Full	96,12	65,96	3,88	162,08	59,30 %
	Kaskade	95,77	67,37	4,23	163,14	58,71 %
5 %	TRI Full	480,59	63,29	19,41	543,88	88,36 %
	Kaskade	478,85	64,64	21,15	543,49	88,11 %

Bei 1 % Phishing beträgt die operative Precision somit 59,30 % beziehungsweise 58,71 %. Die höheren umgerechneten $P_{\geq 90}$ -Werte von 80,74 % und 84,27 % beschreiben einen anderen Schwellenpunkt. Sie dürfen nicht mit den hier verwendeten TPR-/FPR-Werten kombiniert werden. Bei 0,1 % Phishing sind selbst mit TRI Full nur 12,62 % der Modellalarms tatsächliche Phishingfälle. Ein Einsatz auf einem weniger angereicherten Bestand kann damit trotz kleiner FPR einen hohen Fehlalarmanteil erzeugen. Auch ein vorgefilterter Eingang garantiert keine bestimmte Prävalenz oder Modellgüte.

Ebenso hängt die Kaskadeneskalation von der Klassenmischung ab. Die Rückrechnung mit den eingefrorenen Float32-Routergrenzen ergibt 5.849 Eskalationen unter 91.260 benignen Seiten ($e_0 = 6,409\%$) und 19.248 unter 76.800 Phishingseiten ($e_1 = 25,06\%$). Für reine Prävalenzänderungen gilt

$$e_{\pi} = (1 - \pi)e_0 + \pi e_1.$$

Bei 1 % Phishing ergeben sich daher 6,596 % beziehungsweise rund 660 zusätzliche multimodale Pfade je 10.000 Seiten. Die gemessenen 14,933 % gelten für die ursprüngliche Testmischung mit 45,70 % Phishing. Beide Größen bezeichnen Modellverarbeitung, keine menschliche Eskalation. Aus dem veränderten Routinganteil wird keine neue Laufzeit abgeleitet, da klassenspezifische Zeitmessungen fehlen. Die Szenariorechnung und ihre Rohscoreprüfung sind im Begleitmaterial als `scripts/business_analysis.py` reproduzierbar; der lokale Betriebsrechner erlaubt weitere ausdrücklich angenommene Volumina.

7. Diskussion und Schlussbetrachtung

Das Kapitel beantwortet die vier Forschungsfragen, grenzt die Aussagekraft der internen und externen Ergebnisse ein und leitet daraus ein betriebliches Einsatz- und Pilotkonzept ab.

7.1. Interpretation und Beantwortung der Forschungsfragen

FF1 – task-adaptive Repräsentationsanpassung. R0 bildet bereits einen allgemein selbstüberwacht vortrainierten Ausgangspunkt. Der in dieser Arbeit gemessene Effekt beschreibt daher den zusätzlichen Nutzen der task-adaptiven Weiteranpassung. RU und RT verbessern die Downstream-Leistung gegenüber R0, während RUT mit beiden Probes die höchste mittlere TPR erreicht. Der N10-Vergleich bestätigt diesen Vorteil auf FINAL: Auf OFFICIAL_TEST liegt RUT bei 20.000 Labels um +6,08 Prozentpunkte über R0; in den vier zusätzlichen Evaluationsbedingungen beträgt der Unterschied +5,51 bis +6,26 Prozentpunkte und bleibt nach Holm-Korrektur signifikant.

Damit zeigt sich ein zusätzlicher Repräsentationsnutzen der Anpassung auf dem ungelabelten Webseitenpool, obwohl die Ausgangsencoder bereits selbstüberwacht vortrainiert sind. Die in Kapitel 3 dargestellten spezialisierten URL-Repräsentationsverfahren verdeutlichen die Relevanz einer domänennäheren Repräsentationsbildung für URL-basierte Sicherheitsaufgaben (vgl. [Maneriker et al. (2021), PDF-S. 1–2]; [Wang et al. (2023), Abstract, o. S.]; [Li et al. (2025), S. 1–2 und 12]). Die vorliegende Untersuchung betrachtet diesen Zusammenhang für die zusätzliche task-adaptive Anpassung zweier Informationszweige innerhalb desselben Versuchsprotokolls.

Die faktorielle Betrachtung zeigt zugleich, dass sich die einzelnen Adaptationsgewinne nicht vollständig addieren. Die Interaktion beträgt –5,10 Prozentpunkte für die lineare und –2,83 Prozentpunkte für die MLP-Probe. URL- und HTML-Text-TAPT liefern damit jeweils einen positiven Beitrag, weisen bei gemeinsamer Anpassung jedoch eine teilweise Überlappung ihrer Effekte auf. RUT bleibt dennoch die Variante mit der höchsten absoluten Downstream-Leistung.

Der vorgelagerte kontrastive Versuchsblock ist davon getrennt zu interpretieren. Die getesteten kontrastiven Varianten lagen unter der damaligen Basis- und MLM-Konfiguration, wurden jedoch nicht unter dem finalen R0/RU/RT/RUT-Protokoll erneut trainiert. Daraus lässt sich keine allgemeine Aussage über kontrastives Lernen gegenüber MLM-basiertem TAPT ableiten.

FF2 – Einfluss der Labelverfügbarkeit. Der RUT-Vorteil bleibt über alle untersuchten internen Labelbudgets von 2.000 bis 200.000 Instanzen bestehen. Bei kleineren Trainingsmengen ist der Abstand zu R0 besonders ausgeprägt; mit zunehmender gelabelter Supervision verringert er sich, ohne vollständig zu verschwinden. Die task-adaptive Repräsentationsanpassung verbessert damit nicht nur einen einzelnen Betriebspunkt, sondern den Verlauf der gesamten Lernkurve.

Für die Einordnung ist die Trennung der beiden Lernphasen relevant. Der TAPT-Schritt verwendet den 200.000 Instanzen umfassenden SSL-Pool ohne Downstream-Labels. Erst im anschließenden Klassifikationstraining wird der Umfang der verfügbaren gelabelten Supervision variiert. Die Sensitivität gegenüber reduziertem gelabeltem Trainingsumfang wird auch für spezialisierte URL-Repräsentationen als relevante Evaluationsdimension betrachtet (vgl. [Li et al. (2025), S. 12]). Die B95-Auswertung weist ausschließlich auf DEV auf eine frühere relative Sättigung von RUT hin; auf FINAL erreichen R0 und RUT das jeweilige relative Ziel bei denselben geprüften Budgets. Da sich B95 jeweils auf das eigene 200k-Endniveau einer Variante bezieht, beantwortet diese Kennzahl jedoch nicht, ob ein reduziertes RUT-Budget auch das absolute Niveau einer vollständig trainierten Referenz erreicht. Diese Frage wird durch FF3 gesondert geprüft.

Die externe Evaluation auf dem Phishing Website Dataset von Putra (2023) erweitert diese Einordnung über den PhreshPhish-Datenbestand hinaus. Bei identischen gelabelten Zielinstanzen erreicht RUT über die vier Budgets von 200 bis 2.000 Webseiten eine um 2,54 Prozentpunkte höhere AP-AULC als R0 (95 %-KI [2,16; 2,91], 10/10 positive Paare, $p = 0,001953$). Auch die vier einzelnen Budgetvergleiche fallen mit AP-Vorteilen zwischen +2,21 und +2,79 Prozentpunkten zugunsten von RUT aus und bleiben nach Holm-Korrektur signifikant. Der Nutzen der task-adaptierten Repräsentation zeigt sich damit nicht ausschließlich innerhalb der ursprünglichen PhreshPhish-Lernkurve. Im untersuchten externen Datenbestand bildet RUT auch bei begrenzter neuer gelabelter Supervision die günstigere Ausgangsbasis für die Downstream-Klassifikation. Der Befund stützt damit die Annahme, dass eine zuvor auf ungelabelten Webseitendaten angepasste Repräsentation die spätere Anpassung an eine neue Zielumgebung erleichtern kann.

Die ergänzende Putra-Zielanpassung verschlechtert dagegen die AP-AULC um 1,14 Prozentpunkte. Mehr selbstüberwachtes Vortraining führt folglich in diesem Protokoll nicht zwangsläufig zu besseren Repräsentationen. Der Versuch isoliert weder die Ursache der Verschlechterung noch eine optimale Adaptationsstärke; insbesondere Lernrate, Trainingsdauer und Korpusgröße wurden hier nicht systematisch variiert.

FF3 – Erreichen des Referenzniveaus bei reduziertem Labelbudget. Die formale Budgetanalyse zeigt, dass 50.000 Labels die kleinste untersuchte RUT-Stufe sind, die das festgelegte Vergleichsniveau gegenüber R0@200k über alle fünf Evaluationsbedingungen einschließlich Holm-Korrektur erreicht. Die mittlere TPR von RUT50k liegt dabei um +3,24 bis +3,62 Prozentpunkte über R0@200k; zugleich fällt die realisierte FPR niedriger aus.

Auch gegenüber TF-IDF/XGBoost@200k ist 50.000 die kleinste statistisch gestützte Budgetstufe. RUT20k liegt zwar bereits in allen fünf Bedingungen mindestens auf der mittleren XGBoost-TPR und weist gleichzeitig eine niedrigere mittlere FPR auf, besteht jedoch die Korrektur über das vollständige Budgetraster nicht. Mit RUT50k beträgt der TPR-Abstand zu XGBoost je nach Evaluationsbedingung +4,59 bis +5,58 Prozentpunkte. Da sich bei diesem Vergleich sowohl Repräsentation als auch Klassifikator ändern, dient XGBoost als zusätzliche Referenz für das erreichbare Leistungsniveau und nicht als isolierter Nachweis eines TAPT-Effekts.

Im untersuchten Linear-Probe-Protokoll reichen damit 50.000 gelabelte Instanzen aus, um das festgelegte Leistungsniveau beider mit 200.000 Labels trainierten Referenzen zu erreichen. Bezogen auf die

Downstream-Supervision entspricht dies einer Reduktion um 75 %. Der vorausgehende TAPT-Schritt auf dem vollständigen ungelabelten Webseitenpool bleibt davon unberührt. Die Margensensitivität bestätigt die 50k-Entscheidung zusätzlich über den untersuchten Bereich von 0 bis 2 Prozentpunkten. Die zusätzlichen internen Evaluationsbedingungen zeigen, dass diese Relation nicht auf den vollständigen Finalbestand beschränkt ist. Dies ist insbesondere vor dem in Kapitel 3 diskutierten Problem datensatzabhängiger Evaluationsresultate relevant (vgl. [Rashid et al. (2024), Abstract, o. S.]; [Dalton et al. (2026), S. 5–6]). Die Domain-, Template- und Zeitbedingungen sind jedoch nicht als kausale Einzeltests verschiedener Formen von Distribution Shift zu verstehen. Sie prüfen, ob die in FF1 und FF2 identifizierten Leistungsrelationen unter veränderter Zusammensetzung der Testdaten erhalten bleiben.

Die realisierte FPR liegt insbesondere auf den domainbezogenen Teilmengen teilweise oberhalb des auf CAL angestrebten Betriebspunkts. Eine stabile Rangfolge der Modelle bedeutet daher nicht, dass ein einmal kalibrierter Schwellenwert unter jeder Datenverteilung dieselbe FPR erzeugt. Repräsentationsrobustheit und Betriebspunktkalibration sind entsprechend als getrennte Fragestellungen zu behandeln. Auch die ergänzende Prävalenzanalyse aus Abschnitt 6.6 betrifft eine andere Eigenschaft der Evaluation. Unter konstant gehaltenem klassenspezifischem Fehlerverhalten sinkt $P_{\geq 90}$ bei einer rechnerischen Phishing-Base-Rate von 1 % auf 80,74 % für TRI Full beziehungsweise 84,27 % für die Kaskade. Die Analyse verdeutlicht damit die Abhängigkeit precision-basierter Kennzahlen von der Klassenprävalenz.

FF4 – multimodale Systemkomponenten und URL-first-Verarbeitung. Die sequenzielle Komponentenablation zeigt positive zusätzliche Beiträge aller drei Erweiterungsschritte. Den größten Zuwachs liefert HTML-Text mit +5,184 Prozentpunkten TPR gegenüber URL-only. Der DOM-Zweig erhöht die TPR anschließend um weitere +0,728 Prozentpunkte und das lernbare Gating um +0,576 Prozentpunkte. Alle drei benachbarten Vergleiche bleiben nach Holm-Korrektur signifikant.

Die Ergebnisse zeigen damit für das implementierte System, dass die in Kapitel 3 diskutierten textuellen und strukturellen Webseiteninformationen über die URL hinaus zusätzliche Klassifikationsinformation bereitstellen können (vgl. [Aljofey et al. (2022), S. 1–2 und 13]; [Yoon et al. (2024), S. 13 und 15]). Gleichzeitig unterscheiden sich ihre marginalen Beiträge: Der HTML-Text erzeugt den größten zusätzlichen Effekt, während DOM und Gating kleinere, aber statistisch gestützte Verbesserungen liefern. TRI Full erreicht auf OFFICIAL_TEST 96,12 % TPR bei 0,666 % FPR und bildet die leistungsstärkste Variante des implementierten Gesamtsystems. Die URL-first-Kaskade ergänzt diese Architektur um eine gestufte Verarbeitung. In der eingefrorenen Routingkonfiguration werden 14,93 % der Webseiten an den vollständigen TRI-Pfad eskaliert; die TPR beträgt 95,77 %. Gleichzeitig sinkt die Median-Latenz von 30,18 auf 11,95 ms und der gemessene In-Memory-Durchsatz steigt von 183,2 auf 447,0 Seiten pro Sekunde. Die Kaskade realisiert damit das in Kapitel 3 aufgegriffene Prinzip einer mehrstufigen Verarbeitung, ohne den multimodalen Pfad für unsichere Fälle aufzugeben (vgl. [Liu et al. (2021), Abstract, o. S.]). Der Frontend-Vergleich verbindet schließlich Repräsentations- und Systemebene. Bei derselben auf Development festgelegten TPR-Toleranz von einem Prozentpunkt sinkt die mittlere Eskalationsrate auf OFFICIAL_TEST von 35,746 % mit URL_BASE auf 23,514 % mit URL_TAPT (fünf Läufe). Die task-adaptierte URL-Repräsentation ermöglicht innerhalb dieses Routingprotokolls damit häufiger eine Entscheidung in der ersten Verarbeitungsstufe. Der Repräsentationsvorteil wirkt sich folglich nicht nur auf die Klassifikationsleistung eines einzelnen Modells, sondern auch auf die Verarbeitungstiefe des Gesamtsystems aus.

Die zentrale Forschungsfrage wird damit auf drei Ebenen beantwortet: zusätzlicher Repräsentationsnutzen durch TAPT, geringerer gelabelter Trainingsbedarf im Probe-Protokoll und eine steuerbare Verarbeitungstiefe des darauf aufbauenden multimodalen Systems.

7.2. Limitationen und Aussagegrenzen

Die internen Generalisierungsanalysen beruhen auf demselben PhreshPhish-Data-Freeze. Der ergänzende Integritätsaudit schließt für die prüfbaren OOD-Instanzen exakte Überschneidungen der Domains beziehungsweise Template-Hashes mit SUP, DEV, CAL und dem SSL/TAPT-Pool aus. Semantisch ähnliche Webseiten, Near-Duplicates und fehlende Domainwerte werden dadurch jedoch nicht vollständig erfasst. Die zusätzliche Evaluation auf dem unabhängig erhobenen Putra-Datensatz erweitert die Untersuchung um eine externe Datenquelle. Sie bestätigt den RUT-R0-Vorteil für die Label-Effizienz mit einer linearen Downstream-Probe, umfasst jedoch nur einen einzelnen zusätzlichen Webseitenbestand. Die Übertragbarkeit auf weitere Erhebungszeiträume, Datenquellen und Zielumgebungen bleibt daher offen. Zudem adressiert diese externe Prüfung die Repräsentations- und Label-Effizienz und nicht das vollständige multimodale TRI-System oder die URL-first-Kaskade. N5 und N10 variieren die Auswahl der gelabelten Trainingsinstanzen und das Downstream-Training, während die zugrunde liegenden TAPT-Checkpoints unverändert bleiben. Die berichteten Unsicherheiten erfassen damit nicht die Variation vollständig neu ausgeführter selbstüberwachter Vortrainingsläufe.

Die Reduktion von 200.000 auf 50.000 Instanzen betrifft ausschließlich die gelabelte Downstream-Supervision. Für TAPT werden weiterhin 200.000 Webseiten verarbeitet. Der PhreshPhish-Bestand stellt grundsätzlich Klasseninformationen bereit; diese werden im SSL-Pool für das selbstüberwachte Training technisch nicht verwendet und erst für die späteren Downstream-Experimente wieder zugeordnet. Die Untersuchung quantifiziert damit den methodischen Nutzen einer ohne Downstream-Labels durchgeführten Repräsentationsanpassung, nicht den betrieblichen Prozess der erstmaligen Erhebung und Annotation der Daten. Die verwendete 1-pp-Nichtunterlegenheitsmarge ist eine analytische Entscheidungsschwelle und keine betrieblich validierte Servicegrenze. Die ergänzende Margensensitivität reduziert die Abhängigkeit der zentralen FF3-Entscheidung von dieser konkreten Festlegung, ersetzt jedoch keine anwendungsspezifische Festlegung zulässiger Qualitätsverluste.

Die Klassenbalance der Budgetstichproben wird anhand bereits vorhandener Poollabels hergestellt. Die Budgetanalyse simuliert daher begrenzte gelabelte Trainingsmengen, aber keinen vollständig budgetierten Annotationsprozess. Labels für Development, Kalibration und Evaluation sowie die Information zur klassenweisen Auswahl sind in den 50.000 Trainingslabels nicht enthalten. Eine betriebliche Einsparung von 75 % des gesamten Annotationsaufwands lässt sich daraus nicht ableiten.

Die fünf internen Testszenarien überlappen; ihre Ergebnisse sind keine fünf unabhängigen Replikationen. Exakte Sign-Flip-p-Werte beziehen sich auf die vollständige Enumeration der Vorzeichen, setzen für ihre inferenzielle Interpretation aber eine entsprechende Symmetrie beziehungsweise Austauschbarkeit der Paardifferenzen voraus. Mit zehn Replikationen ist diese Annahme nur eingeschränkt prüfbar. Die nachträglichen Welch-Vergleiche mit XGBoost sind ergänzende Evidenz auf derselben Testpopulation,

keine unabhängige Bestätigung. Ein gespeicherter Analyseplan nach früherem FINAL-Zugriff ersetzt keine prospektive Vorregistrierung auf einem unberührten Testset.

Die Putra-Erhebungen enden 2023 und liegen damit vor dem verwendeten PhreshPhish-Bestand aus 2025. Der interne frühe/späte Putra-Schnitt schützt vor direkter Nutzung seiner Testinstanzen im Zieltraining; die Gesamtauswertung ist jedoch kein prospektiver Nachweis für zukünftige Angriffe. Eine mögliche Überschneidung mit den ursprünglichen allgemeinen BERT-/RoBERTa-Vortrainingskorpora wurde nicht überprüft.

Weitere Grenzen betreffen die Eingabeverarbeitung. Der HTML-Textencoder verarbeitet maximal 256 Tokens und erfasst daher nicht notwendigerweise den vollständigen HTML-Inhalt. Der DOM-Zweig basiert auf einer statischen Rekonstruktion des gespeicherten HTML und nicht auf einem browsergerenderten Laufzeit-DOM. Die gemessenen Latenz-, Durchsatz- und Peak-VRAM-Werte gelten ausschließlich für den In-Memory-Modellpfad ohne Netzwerkzugriffe, Rendering, Datenträger-I/O und vorgelagertes HTML-Parsing.

7.3. Betriebliches Einsatzkonzept und Handlungsempfehlung

Einsatzaufgabe und Verantwortlichkeit. Konzipiert wird die Vorprüfung verdächtiger Webseiten für die Sicherheitseinheit eines Kreditinstituts oder dessen IT-Dienstleister. Aus URL, gesichertem HTML und Meldekontext entsteht ein Klassifikationshinweis mit Modellversion und Schwellenentscheidung für die fachliche Bearbeitung. Tatsächliche Abläufe, Meldevolumina und Ressourcen der Volksbank wurden nicht erhoben; der folgende Prozess ist eine eigene Konzeption.

Die technische Vorfilterung großer Ereignismengen für die anschließende menschliche Analyse wird auch in NIST SP 800-61r3 empfohlen (vgl. [Nelson et al. (2025), S. 25]). Für die Priorisierung und Validierung sind dort zudem Auswirkungen, Dringlichkeit und weiterer Fallkontext maßgeblich (vgl. [Nelson et al. (2025), S. 26–27]). Für den vorliegenden Entwurf folgt daraus eine unterstützende Rolle des Klassifikators: Die Sicherheitseinheit verantwortet die Fallbewertung und Folgemaßnahmen. Ein hoher Modellscore allein beschreibt weder den betrieblichen Schaden noch eine kalibrierte Phishingwahrscheinlichkeit. Automatische Sperrungen sind deshalb kein Bestandteil dieses Konzepts.

Isolierte Erfassung, Netzwerkabruf, Ticketschnittstelle und Prüfoberfläche sind erforderliche Erweiterungen des Prototyps. Die Eingaben müssen den untersuchten URL-/HTML-/DOM-Daten entsprechen. Nicht auswertbare Seiten werden gesondert fachlich geklärt. Modellnegative Seiten erhalten keine Freigabe als sicher. Relevanter Kontext, etwa eine berichtete Zugangsdatenpreisgabe, kann unabhängig vom Modell eine sofortige Prüfung erfordern.




Abbildung 7.1.: Konzipierte Einbettung der Webseitenklassifikation in die fachliche Fallprüfung. Nur der grau hinterlegte Modellpfad wurde experimentell untersucht.

Eigene Darstellung; KI-unterstützt.

Modellwahl nach tatsächlichem Engpass. Tabelle 7.1 vergleicht das mit 200.000 Labels trainierte TRI-System, seine Kaskade und seinen separat gemessenen URL-Zweig.

Tabelle 7.1.: Gemessene Alternativen und daraus abgeleitete Einsatzentscheidung. TPR/FPR: FINAL; Durchsatz: DEV-In-Memory-Benchmark auf Tesla T4.

Variante	TPR	FPR	Seiten/s	Konzeptionelle Einordnung
URL-Pfad	93,16 %	0,682 %	865,9	Höchster Durchsatz; mehr übersehene Phishingfälle.
TRI Full	96,12 %	0,666 %	183,2	Startpunkt bei Qualitätsvorrang und ausreichender Rechenkapazität.
TRI-Kaskade	95,77 %	0,680 %	447,0	Option bei nachgewiesenem Rechengengpass und akzeptiertem Qualitätsverlust.

Bei begrenztem Pilotumfang sprechen höhere TPR und niedrigere FPR für TRI Full. Die Kaskade erhöht den gemessenen Durchsatz um den Faktor 2,44, erzeugt aber zusätzliche Fehlalarme und übersehene Phishingfälle. Als Größenordnung entsprechen 10.000 Seiten beim gemessenen mittleren Durchsatz 54,59 Sekunden für TRI Full und 22,37 Sekunden für die Kaskade: 32,22 Sekunden Differenz. Diese DEV-Benchmark-Referenz umfasst weder die gesamte Bearbeitungskette noch eine auf andere Prävalenzen angepasste Laufzeit. Der Geschwindigkeitsvorteil ist deshalb mit tatsächlichem Eingang, Hardware und Wartezeiten abzuwägen.

Prüfmenge und Qualitätsfolgen. Die Szenarien aus Abschnitt 6.7 machen die nachgelagerte Aufgabe greifbar. Bei 10.000 auswertbaren Seiten und angenommenen 1 % Phishing liefert TRI Full rund 162

Modellalarme: etwa 96 erkannte Phishingfälle und 66 Fehllalarme; rund vier Phishingfälle bleiben modellnegativ. Die Kaskade erzeugt rechnerisch 1,41 zusätzliche Fehllalarme und 0,35 zusätzliche übersehene Phishingfälle je 10.000 Seiten. Der schnellere URL-Pfad übersieht bei derselben Annahme 6,84 statt 3,88 Phishingfälle. Eine kleinere Alarmmenge kann somit auch durch schlechtere Erkennung entstehen.

Werden alle Modellalarme geprüft, beschreibt A_π zunächst nur diesen Teil der menschlichen Prüfmengen. Bei einer im Pilot zu messenden mittleren Bearbeitungszeit t_A in Minuten beträgt der entsprechende Aufwand $A_\pi t_A / 60$ Stunden. Kontextfälle, nicht auswertbare Seiten, Negativstichproben und Folgemaßnahmen kommen hinzu. Eine Personal- oder Kosteneinsparung wurde nicht gemessen. Ebenso wenig sind die rund 660 zusätzlichen Modellpfade der Kaskade im 1%-Szenario 660 menschliche Prüffälle. Der beiliegende Betriebsrechner trennt diese Größen und erlaubt eigene, kenntlich gemachte Volumen-, Prävalenz- und Zeitannahmen.

Datenstrategie bei begrenzter Annotation. Die Label-Effizienz liefert eine zweite, von der Laufzeit getrennte Handlungsempfehlung: Eine vorhandene RUT-Repräsentation ist ein begründeter Ausgangspunkt für begrenztes gelabeltes Nachtraining. Intern erreicht RUT50k das festgelegte Referenzniveau der 200k-Verfahren; extern erzielt RUT auf Putra über 200 bis 2.000 Ziel-Labels einen AP-AULC-Vorteil von 2,54 Prozentpunkten. Der interne 50k-Nachweis gilt allerdings für lineare Probes auf eingefrorenen Repräsentationen. Die in diesem Einsatzkonzept verwendeten Full-/Kaskadenwerte stammen aus einem mit 200k Labels trainierten System. Eine Kombination von 50k Trainingslabels mit dessen 96,12 % TPR wurde nicht nachgewiesen.

Die 75 % Reduktion betrifft zudem ausschließlich Downstream-Trainingslabels; Entwicklung, Kalibration, Evaluation, Datenerhebung und TAPT bleiben eigene Aufwandspositionen. Für einen neuen Betrieb sollte zunächst eine Lernkurve mit geprüftem Zielmaterial erhoben werden. Zusätzliche Ziel-TAPT wäre eine separat zu bewertende Option, da sie im ergänzenden Putra-Versuch die AP-AULC um 1,14 Prozentpunkte verschlechterte. Geprüfte Fälle dürfen erst nach Dokumentation und Rollentrennung für spätere Modellstände genutzt werden. Derselbe Fall darf nicht zugleich Nachtraining und dessen Erfolgskontrolle dienen.

Pilotierung und messbare Freigabeentscheidung. Als nächster Entwicklungsschritt wird ein Parallelbetrieb vorgeschlagen, bei dem der bestehende fachliche Prüfprozess die Fallentscheidung weiterhin trifft. TRI Full und Kaskade bewerten dieselben neu eingehenden auswertbaren Fälle. Modellstand, Schwellen, Routing und die Erfolgskriterien werden vor der Pilotbewertung festgelegt. Kalibration auf neuem Zielmaterial und anschließende zeitlich getrennte Bewertung ermöglichen eine Überprüfung des tatsächlichen Betriebspunkts. Die fachlichen Labels sollten möglichst ohne Kenntnis der Modellentscheidung vergeben werden.

Tabelle 7.2.: Vorgeschlagene Prüfkriterien für die betriebliche Weiterentwicklung; noch keine gemessene Freigabe.

Prüfdimension	Zu erfassender Nachweis und Entscheidung
Datenabdeckung	Anteil auswertbarer Fälle und Ursachen fehlender Eingaben; gesonderte Bearbeitung der Ausfälle muss möglich sein.
Detektionsqualität	TPR, FPR und Precision mit Unsicherheit auf unabhängig geprüften Fällen; die Sicherheitseinheit legt akzeptable Grenzen vor Auswertung fest. Die CAL-Ziel-FPR von 0,5 % ist keine bereits bestätigte Betriebsgrenze.
Prüfkapazität	Alarmer, Kontextfälle, Negativstichprobe, mittlere Prüfzeit und Rückstand; tatsächlicher Aufwand muss in die vereinbarte Kapazität passen.
Verarbeitung	Gesamtlatenz einschließlich Erfassung, Durchsatz und Modellrouting; Kaskade nur bei relevantem Ressourcenvorteil und vertretbaren zusätzlichen Fehlern.
Änderungskontrolle	Bei Qualitätsverschlechterung zuerst Datenabdeckung und Betriebspunkt prüfen; Rekalibration und Nachtraining getrennt bewerten und an zeitlich späteren Fällen erneut prüfen.

Werden nur Modellalarmer gelabelt, bleiben übersehene Phishingfälle unbekannt. Der Pilot benötigt daher entweder eine vollständige fachliche Referenzbewertung oder zusätzlich eine Zufallsstichprobe modellnegativer Fälle mit dokumentierten Auswahlwahrscheinlichkeiten. Bei ungleichen Prüfanteilen müssen Prävalenz und Fehlerraten entsprechend gewichtet werden. Das Konzept verbindet damit die vorhandenen Ergebnisse mit einer überprüfbaren Einführungsentscheidung: Qualitätsvorrang im ersten Pilot, Kaskade bei nachgewiesenem Ressourcenbedarf und gezielte Labelverwendung für spätere Modellanpassungen.

7.4. Fazit und Ausblick

Die zusätzliche task-adaptive Anpassung bereits vortrainierter URL- und HTML-Text-Encoder verbessert im untersuchten Protokoll die Phishing-Erkennung. RUT erreicht bei 20.000 Labels auf dem vollständigen FINAL-Bestand eine um 6,08 Prozentpunkte höhere mittlere TPR als R0. Die Adaptationseffekte überlagern sich teilweise.

50.000 Labels bilden die kleinste geprüfte RUT-Stufe, welche die festgelegte Nichtunterlegenheitsentscheidung gegenüber R0@200k und TF-IDF/XGBoost@200k in allen fünf Evaluationsbedingungen erfüllt. Die Reduktion um 75 % betrifft ausschließlich die gelabelte Downstream-Trainingsmenge des Linear-Probe-Protokolls; die anschließenden Full-/Kaskadenwerte beruhen auf 200.000 Trainingslabels. Auf dem externen Putra-Bestand verbessert Quell-RUT die AP-AULC gegenüber R0 um 2,54 Prozentpunkte; die zusätzliche Putra-Anpassung verschlechtert sie hingegen um 1,14 Prozentpunkte. Weitere selbstüberwachte Anpassung ist damit kein allgemeines Verbesserungsversprechen.

HTML-Text, DOM und Gating liefern im sequenziellen DEV-Vergleich jeweils einen zusätzlichen Beitrag. TRI Full erreicht auf FINAL 96,12 % TPR bei 0,666 % FPR. Die URL-first-Kaskade eskaliert 14,93 % der Fälle und erreicht 95,77 % TPR. Ihr DEV-In-Memory-Durchsatz ist 2,44-mal so hoch wie der des Vollsystems; die Messung umfasst nicht die gesamte Verarbeitungskette.

Das betriebliche Einsatzkonzept sieht TRI Full zur unterstützenden Webseitenvorprüfung vor; die Kaskade ist bei nachgewiesenem Rechenengpass zu prüfen. Bei angenommenen 1 % Phishing erzeugt TRI Full je 10.000 Seiten rund 162 Modellalarme, darunter 66 Fehlalarme. Modellrouting, Alarmmenge und menschliche Prüfung bleiben getrennte Größen, deren Übertragung der vorgeschlagene Pilot überprüfen soll.

Feste TAPT-Checkpoints, nachträgliche Analysen und der retrospektive externe Test begrenzen die Verallgemeinerung. Ausstehend sind unabhängige Vortrainingswiederholungen, zukünftige externe Systemtests, Kostenmessungen sowie die betriebliche Prüfung von Rekalibration und Drift-Erkennung.

Literaturverzeichnis

Die angegebenen Fundstellen beziehen sich auf die im jeweiligen Eintrag ausgewiesene Fassung. PDF-S. bezeichnet die physische Seitenzählung einer unpaginierten Quelle; o. S. kennzeichnet unpaginierte Webquellen.

Aljofey, Ali; Jiang, Qingshan; Rasool, Abdur; Chen, Hui; Liu, Wenying; Qu, Qiang und Wang, Yang (2022): An effective detection approach for phishing websites using URL and HTML features. In: *Scientific Reports*, 12, Artikel 8842. <https://www.nature.com/articles/s41598-022-10841-5.pdf>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Anti-Phishing Working Group (APWG) (Hrsg.; 2025): *Phishing Activity Trends Report. 1st Quarter 2025*. https://docs.apwg.org/reports/apwg_trends_report_q1_2025.pdf. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Arevalo, John; Solorio, Tamar; Montes-y-Gómez, Manuel und González, Fabio A. (2017): Gated Multimodal Units for Information Fusion. In: *5th International Conference on Learning Representations (ICLR 2017), Workshop Track*. <https://arxiv.org/pdf/1702.01992>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Baltrušaitis, Tadas; Ahuja, Chaitanya und Morency, Louis-Philippe (2019): Multimodal Machine Learning: A Survey and Taxonomy. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), S. 423–443. <https://ieeexplore.ieee.org/document/8269806>. Seitenangaben im Text beziehen sich auf die Autorenfassung mit 20 PDF-Seiten. <https://arxiv.org/abs/1705.09406>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Bengio, Yoshua (2009): Learning Deep Architectures for AI. In: *Foundations and Trends in Machine Learning*, 2(1), S. 1–127. <https://doi.org/10.1561/22000000006>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Botsch, Benny (2023): *Maschinelles Lernen – Grundlagen und Anwendungen. Mit Beispielen in Python*. Springer Spektrum, Berlin, Heidelberg. ISBN 978-3-662-67277-8. <https://doi.org/10.1007/978-3-662-67277-8>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Chen, Ting; Kornblith, Simon; Norouzi, Mohammad und Hinton, Geoffrey (2020): A Simple Framework for Contrastive Learning of Visual Representations. In: *Proceedings of the 37th International Conference on Machine Learning*, Proceedings of Machine Learning Research, 119, S. 1597–1607. PMLR. <https://proceedings.mlr.press/v119/chen20j/chen20j.pdf>. Seitenangaben im Text nach physischer PDF-Zählung. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Collobert, Ronan; Weston, Jason; Bottou, Léon; Karlen, Michael; Kavukcuoglu, Koray und Kuksa, Pavel (2011): Natural Language Processing (Almost) from Scratch. In: *Journal of Machine Learning Research*, 12, S. 2493–2537. <https://www.jmlr.org/papers/v12/collobert11a.html>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Cybenko, George (1989): Approximation by superpositions of a sigmoidal function. In: *Mathematics of Control, Signals, and Systems*, 2(4), S. 303–314. <https://link.springer.com/article/10.1007/BF02551274>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Dalton, Thomas; Gowda, Hemanth; Rao, Girish; Pargi, Sachin; Hadj Khodabakhshi, Alireza; Romb, Joseph; Jou, Stephan und Marwah, Manish (2026): PhreshPhish: A Real-World, High-Quality, Large-Scale Phishing Website Dataset and Benchmark. arXiv Preprint, arXiv:2507.10854v2, Fassung vom 11.02.2026. <https://arxiv.org/abs/2507.10854v2>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Devlin, Jacob; Chang, Ming-Wei; Lee, Kenton und Toutanova, Kristina (2019): BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Volume 1, S. 4171–4186. Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Dhamija, Rachna; Tygar, J. D. und Hearst, Marti (2006): Why Phishing Works. In: *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI 2006)*, S. 581–590. ACM. <https://doi.org/10.1145/1124772.1124861>. Verwendete Autorenfassung; PDF-Seitenzählung (10 Seiten). https://people.eecs.berkeley.edu/~tygar/papers/Phishing/why_phishing_works.pdf. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Dror, Rotem; Baumer, Gili; Bogomolov, Marina und Reichart, Roi (2017): Replicability Analysis for Natural Language Processing: Testing Significance with Multiple Datasets. In: *Transactions of the Association for Computational Linguistics*, 5, S. 471–486. https://doi.org/10.1162/tac1_a_00074. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Ericsson, Linus; Gouk, Henry; Loy, Chen Change und Hospedales, Timothy M. (2022): Self-Supervised Representation Learning: Introduction, Advances, and Challenges. In: *IEEE Signal Processing Magazine*, 39(3), S. 42–62. <https://doi.org/10.1109/MSP.2021.3134634>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

European Union Agency for Cybersecurity (ENISA) (Hrsg.; 2020): *How to set up CSIRT and SOC. Good Practice Guide*. European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/how-to-set-up-csirt-and-soc>. <https://doi.org/10.2824/056764>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

European Union Agency for Cybersecurity (ENISA) (Hrsg.; 2021): *Cybersecurity for SMEs – Challenges and Recommendations*. European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/enisa-report-cybersecurity-for-smes>. <https://doi.org/10.2824/770352>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

European Union Agency for Cybersecurity (ENISA) (Hrsg.; 2024): *ENISA Threat Landscape 2024*. European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/enisa-threat-landscape-2024>. <https://doi.org/10.2824/0710888>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

European Union Agency for Cybersecurity (ENISA) (Hrsg.; 2025a): *ENISA Threat Landscape 2025*, Version 1.2 (Januar 2026). European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/enisa-threat-landscape-2025>. <https://doi.org/10.2824/1946374>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

European Union Agency for Cybersecurity (ENISA) (Hrsg.; 2025b): *ENISA Threat Landscape: Finance Sector. January 2023 to June 2024*. European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/enisa-threat-landscape-finance-sector>. <https://doi.org/10.2824/5410466>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Gao, Tianyu; Yao, Xingcheng und Chen, Danqi (2021): SimCSE: Simple Contrastive Learning of Sentence Embeddings. In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, S. 6894–6910. Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.emnlp-main.552>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Gui, Jie; Chen, Tuo; Zhang, Jing; Cao, Qiong; Sun, Zhenan; Luo, Hao und Tao, Dacheng (2024): A Survey on Self-Supervised Learning: Algorithms, Applications, and Future Trends. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(12), S. 9052–9071. <https://doi.org/10.1109/TPAMI.2024.3415112>. Verwendete paginierte Autorenfassung; Textbeleg auf S. 1. <https://arxiv.org/abs/2301.05712>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Gururangan, Suchin; Marasović, Ana; Swayamdipta, Swabha; Lo, Kyle; Beltagy, Iz; Downey, Doug und Smith, Noah A. (2020): Don't Stop Pretraining: Adapt Language Models to Domains and Tasks. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, S. 8342–8360. Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.acl-main.740>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Holm, Sture (1979): A Simple Sequentially Rejective Multiple Test Procedure. In: *Scandinavian Journal of Statistics*, 6(2), S. 65–70. <https://www.jstor.org/stable/4615733>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Holt, Charles A. und Sullivan, Sean P. (2023): Permutation Tests for Experimental Data. In: *Experimental Economics*, 26(4), S. 775–812. <https://doi.org/10.1007/s10683-023-09799-6>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Kipf, Thomas N. und Welling, Max (2017): Semi-Supervised Classification with Graph Convolutional Networks. In: *5th International Conference on Learning Representations (ICLR 2017)*. <https://openreview.net/forum?id=SJU4ayYg1>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Koh, Pang Wei; Sagawa, Shiori; Marklund, Henrik; Xie, Sang Michael; Zhang, Marvin; Balsubramani, Akshay; Hu, Weihua; Yasunaga, Michihiro; Phillips, Richard Lanus; Gao, Irena; Lee, Tony; David, Etienne; Stavness, Ian; Guo, Wei; Earnshaw, Berton; Haque, Imran; Beery, Sara M.; Leskovec, Jure; Kundaje, Anshul; Pierson, Emma; Levine, Sergey; Finn, Chelsea und Liang, Percy (2021): WILDS: A Benchmark of in-the-Wild Distribution Shifts. In: *Proceedings of the 38th International Conference on Machine Learning*, Proceedings of Machine Learning Research, 139, S. 5637–5664. PMLR. <https://proceedings.mlr.press/v139/koh21a.html>. Seitenangaben im Text nach physischer PDF-Zählung. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

LeCun, Yann; Bengio, Yoshua und Hinton, Geoffrey (2015): Deep Learning. In: *Nature*, 521, S. 436–444. <https://doi.org/10.1038/nature14539>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Li, Yujie; Liu, Yiwei; Li, Peiyue; Jia, Yifan und Wang, Yanbin (2025): Continuous multi-task pre-training for malicious URL detection and webpage classification. In: *Computer Networks*, 270, Artikel 111513. <https://www.sciencedirect.com/science/article/pii/S1389128625004803>. Seitenangaben im Text beziehen sich auf Version 2 der Autorenfassung (17 Seiten). <https://arxiv.org/abs/2402.11495v2>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Liu, Dong-Jie; Geng, Guang-Gang; Jin, Xiao-Bo und Wang, Wei (2021): An efficient multistage phishing website detection model based on the CASE feature framework: Aiming at the real web environment. In: *Computers & Security*, 110, Artikel 102421. <https://www.sciencedirect.com/science/article/pii/S0167404821002455>. Textbeleg: Abstract der unpaginierten Verlags-Webfassung. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Liu, Yinhan; Ott, Myle; Goyal, Naman; Du, Jingfei; Joshi, Mandar; Chen, Danqi; Levy, Omer; Lewis, Mike; Zettlemoyer, Luke und Stoyanov, Veselin (2019): RoBERTa: A Robustly Optimized BERT Pre-training Approach. arXiv Preprint, arXiv:1907.11692. <https://arxiv.org/abs/1907.11692>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Maneriker, Pranav; Stokes, Jack W.; Garcia Lazo, Edir; Carutasu, Diana; Tajaddodianfar, Farid und Gururajan, Arun (2021): URLTran: Improving Phishing URL Detection Using Transformers. In: *MILCOM 2021 – 2021 IEEE Military Communications Conference (MILCOM)*, S. 197–204. IEEE. <https://ieeexplore.ieee.org/document/9653028>. Verwendete Autorenfassung; PDF-Seitenzählung (10 Seiten). <https://arxiv.org/abs/2106.05256>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Manning, Christopher D.; Raghavan, Prabhakar und Schütze, Hinrich (2008): *Introduction to Information Retrieval*. Cambridge University Press, Cambridge. ISBN 978-0-521-86571-5. <https://nlp.stanford.edu/IR-book/>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Mikolov, Tomas; Sutskever, Ilya; Chen, Kai; Corrado, Greg S. und Dean, Jeff (2013): Distributed Representations of Words and Phrases and their Compositionality. In: *Advances in Neural Information Processing Systems 26*, S. 3111–3119. <https://proceedings.neurips.cc/paper/2013/hash/9aa42b31882ec039965f3c4923ce901b-Abstract.html>. Die Textbelege beziehen sich auf die PDF-interne Seitenzählung 1–9. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Nelson, Alex; Rekhi, Sanjay; Souppaya, Murugiah und Scarfone, Karen (2025): *Incident Response Recommendations and Considerations for Cybersecurity Risk Management: A CSF 2.0 Community Profile*. NIST Special Publication 800-61r3, April 2025. <https://doi.org/10.6028/NIST.SP.800-61r3>. Textbelege nach gedruckter Seitenzählung. Abruf und Quellenabgleich am 13.09.2026.

Opara, Chidimma; Chen, Yingke und Wei, Bo (2024): Look Before You Leap: Detecting Phishing Web Pages by Exploiting Raw URL and HTML Characteristics. In: *Expert Systems with Applications*, 236, Artikel 121183. <https://doi.org/10.1016/j.eswa.2023.121183>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Purwanto, Rizka Widyarini; Pal, Arindam; Blair, Alan und Jha, Sanjay (2022): PhishSim: Aiding Phishing Website Detection With a Feature-Free Tool. In: *IEEE Transactions on Information Forensics and Security*, 17, S. 1497–1512. <https://doi.org/10.1109/TIFS.2022.3164212>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Putra, I Kadek Agus Ariesta (2023): *Phishing Website Dataset*. Version 1, veröffentlicht am 02.07.2023. Datensatz, Zenodo. <https://doi.org/10.5281/zenodo.8041387>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Raschka, Sebastian (2018): Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. arXiv Preprint, arXiv:1811.12808. <https://doi.org/10.48550/arXiv.1811.12808>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Rashid, Fariza; Doyle, Ben; Han, Soyeon Caren und Seneviratne, Suranga (2024): Phishing URL detection generalisation using Unsupervised Domain Adaptation. In: *Computer Networks*, 245, Artikel 110398. <https://www.sciencedirect.com/science/article/pii/S1389128624002305>. Textbeleg: Abstract der unpaginierten Verlags-Webfassung. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Reddi, Vijay Janapa; Cheng, Christine; Kanter, David; Mattson, Peter; Schmuelling, Guenther; Wu, Carole-Jean; Anderson, Brian; Breughe, Maximilien; Charlebois, Mark; Chou, William; Chukka, Ramesh; Coleman, Cody; Davis, Sam; Deng, Pan; Diamos, Greg; Duke, Jared; Fick, Dave; Gardner, J. Scott; Hubara, Itay; Idgunji, Sachin; Jablin, Thomas B.; Jiao, Jeff; St. John, Tom; Kanwar, Pankaj; Lee, David; Liao, Jeffery; Lokhmotov, Anton; Massa, Francisco; Meng, Peng; Mickevicius, Paulius; Osborne, Colin; Pekhimenko, Gennady; Rajan, Arun Tejusve Raghunath; Sequeira, Dilip; Sirasao, Ashish; Sun, Fei; Tang, Hanlin; Thomson, Michael; Wei, Frank; Wu, Ephrem; Xu, Lingjie; Yamada, Koichi; Yu, Bing; Yuan, George; Zhong, Aaron; Zhang, Peizhao und Zhou, Yuchen (2020): MLPerf Inference Benchmark. In: *2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture (ISCA)*, S. 446–459. IEEE. <https://doi.org/10.1109/ISCA45697.2020.00045>. Seitenangaben im Text beziehen sich auf die Autorenfassung (15 Seiten). <https://arxiv.org/abs/1911.02549>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Reimers, Nils und Gurevych, Iryna (2017): Reporting Score Distributions Makes a Difference: Performance Study of LSTM-networks for Sequence Tagging. In: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, S. 338–348. Association for Computational Linguistics. <https://doi.org/10.18653/v1/D17-1035>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Roh, Yuji; Heo, Geon und Whang, Steven Euijong (2021): A Survey on Data Collection for Machine Learning: A Big Data–AI Integration Perspective. In: *IEEE Transactions on Knowledge and Data Engineering*, 33(4), S. 1328–1347. <https://doi.org/10.1109/TKDE.2019.2946162>. Verwendete paginierte Autorenfassung; Textbeleg auf S. 1. <https://arxiv.org/abs/1811.03402>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Rumelhart, David E.; Hinton, Geoffrey E. und Williams, Ronald J. (1986): Learning Representations by Back-Propagating Errors. In: *Nature*, 323, S. 533–536. <https://doi.org/10.1038/323533a0>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Saito, Takaya und Rehmsmeier, Marc (2015): The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. In: *PLOS ONE*, 10(3), Artikel e0118432. <https://doi.org/10.1371/journal.pone.0118432>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Turney, Peter D. und Pantel, Patrick (2010): From Frequency to Meaning: Vector Space Models of Semantics. In: *Journal of Artificial Intelligence Research*, 37, S. 141–188. <https://doi.org/10.1613/JAIR.2934>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Vaswani, Ashish; Shazeer, Noam; Parmar, Niki; Uszkoreit, Jakob; Jones, Llion; Gomez, Aidan N.; Kaiser, Łukasz und Polosukhin, Illia (2017): Attention Is All You Need. In: *Advances in Neural Information Processing Systems 30*, S. 5998–6008. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>. Die Textbelege beziehen sich auf die PDF-interne Seitenzählung 1–11. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Viola, Paul und Jones, Michael J. (2004): Robust Real-Time Face Detection. In: *International Journal of Computer Vision*, 57(2), S. 137–154. <https://doi.org/10.1023/B:VISI.0000013087.49260.FB>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Wang, Yanbin; Zhu, Weifan; Xu, Haitao; Qin, Zhan; Ren, Kui und Ma, Wenrui (2023): A Large-Scale Pretrained Deep Model for Phishing URL Detection. In: *2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, S. 1–5. IEEE. <https://ieeexplore.ieee.org/document/10095719>. Inhaltlich zitiert wird der unpaginierte Abstract zum Beitrag im IEEE Resource Center. <https://resourcecenter.ieee.org/conferences/icassp-2023/spsicassp23vid2453>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Yoon, Jun-Ho; Buu, Seok-Jun und Kim, Hae-Jung (2024): Phishing Webpage Detection via Multi-Modal Integration of HTML DOM Graphs and URL Features Based on Graph Convolutional and Transformer Networks. In: *Electronics*, 13(16), Artikel 3344. <https://doi.org/10.3390/electronics13163344>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Zhang, Yue; Hong, Jason I. und Cranor, Lorrie Faith (2007): CANTINA: A Content-Based Approach to Detecting Phishing Web Sites. In: *Proceedings of the 16th International Conference on World Wide Web (WWW 2007)*, S. 639–648. ACM. <https://doi.org/10.1145/1242572.1242659>. Verwendete Autorenfassung; PDF-Seitenzählung (10 Seiten). <https://www.cs.cmu.edu/afs/cs.cmu.edu/Web/People/jasonh/publications/www2007-cantina-final.pdf>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Zhou, Pan; Yang, Wenwen; Chen, Wei; Wang, Yanfeng und Jia, Jia (2019): Modality Attention for End-to-End Audio-Visual Speech Recognition. In: *2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, S. 6565–6569. IEEE. <https://ieeexplore.ieee.org/document/8683733>. Verwendete Autorenfassung; PDF-Seitenzählung (5 Seiten). <https://hcsi.cs.tsinghua.edu.cn/Paper/Paper19/ICASSP19-ZHOU PAN.pdf>. Abruf bzw. erneuter Quellenabgleich am 12.09.2026.

Ehrenwörtliche Erklärung

Hiermit erkläre ich ehrenwörtlich,

1. dass ich die vorliegende Arbeit mit dem Titel
Self-Supervised Learning zur Phishing-Detektion – Konzeption, prototypische Entwicklung und Evaluation eines lernbasierten Klassifikationssystems
ohne fremde Hilfe angefertigt habe,
2. dass ich alle wörtlich oder sinngemäß übernommenen Zitate aus anderen Quellen an den entsprechenden Stellen innerhalb der Arbeit eindeutig gekennzeichnet habe,
3. dass diese Arbeit noch nicht in gleicher oder ähnlicher Form sowie vollständig oder auszugsweise einer anderen Prüfungsbehörde vorgelegt wurde,
4. dass alle von mir eingereichten digitalen Versionen der Arbeit mit den eventuell ausgedruckten und eingereichten Artefakten in Papierform inhaltlich zu 100 Prozent übereinstimmen.

Ich bin mir bewusst, dass eine falsche Erklärung rechtliche Folgen haben wird.

Ort, Datum

Unterschrift

A. Ergänzende Implementierungs- und Prüfdetails

A.1. Implementierungsauszüge

Die folgenden Auszüge gehören zu den in Kapitel 5 erläuterten Implementierungsschritten. Die vollständigen Notebooks und die nachvollziehbaren Prüfskripte liegen in den digitalen Artefakten. Kürzungen innerhalb der Ausschnitte sind keine lauffähigen Ersatzprogramme.

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
   def train_url_tapt(batch_size):
3     seed_all(MASTER_SEED)
     urls = read_ssl_urls() # labels are never read here
5
     enc = url_tok(
7         urls,
         truncation=True,
9         max_length=URL_MAX_LEN,
         padding=False
11    )
     model = AutoModelForMaskedLM.from_pretrained(
13         URL_BASE_SRC, token=HF_TOKEN, **url_kwargs
     ).to(DEVICE)
15
     coll = DataCollatorForLanguageModeling(
17         tokenizer=url_tok,
         mlm_probability=URL_MLM_PROB
19     )
     opt = torch.optim.AdamW(
21         model.parameters(),
         lr=URL_TAPT_LR,
23         weight_decay=URL_TAPT_WEIGHT_DECAY
     )
25
     total = len(dl) * URL_TAPT_EPOCHS
27     sched = get_linear_schedule_with_warmup(
         opt, int(URL_TAPT_WARMUP_FRAC * total), total
29     )
```

Listing A.1: Zentraler Trainingsaufbau des URL-TAPT – gekürzter Originalausschnitt

A. Ergänzende Implementierungs- und Prüfdetails

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
  url_high = thr_fpr(
3     ET["url"][yt == 0],
    .001
5 )

7 pos = np.sort(ET["url"][yt == 1])
  k = max(1, int(math.floor(.01 * len(pos))))
9 url_low = float(
    np.nextafter(pos[k - 1], -np.inf)
11 )
```

Listing A.2: Bestimmung der Development-basierten Kaskadenschwellen

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
  hi = us >= url_high
3 lo = us <= url_low
  esc = ~(hi | lo)
5
  out[hi] = 1e9
7 out[lo] = -1e9
```

Listing A.3: Routingentscheidung der URL-first-Kaskade – gekürzter zusammenhängender Originalauszug

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
  def stable_rank(series, salt):
3     return np.fromiter(
        (
5         int(
            hashlib.sha256(
7                 (salt + "|" + x).encode()
            ).hexdigest()[:16],
9             16
        )
11     for x in series.astype(str)
    ),
13     dtype=np.uint64,
    count=len(series)
15 )
```

Listing A.4: Deterministische Rangbildung für die Datenpartitionierung

```

1  # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
   def process_row(row, include_label=True):
3      s, _ = clipped_html(row.get("html"))
      no_comments = COMMENT_RE.sub(" ", s)
5
      toks = []
7      for slash, tag in TAG_RE.findall(no_comments):
          toks.append(("/" if slash else "") + normalize_tag(tag))
9          if len(toks) >= STRUCT_MAX_TOKENS:
              break
11         struct = " ".join(toks)

13         txt = SCRIPT_STYLE_RE.sub(" ", no_comments)
         txt = TAG_STRIP_RE.sub(" ", txt)
15         txt = html_std.unescape(txt)
         txt = WS_RE.sub(" ", txt).strip()[:TEXT_MAX_CHARS]
17

         tags, parents, depths, attrs, children, _ = parse_dom(s)
19         out = {
             "text": txt,
21             "html_struct": struct,
             "template_hash": hashlib.sha256(
23                 struct.encode("utf-8", "ignore")
             ).hexdigest(),
25             "dom_tag": tags,
             "dom_parent_idx": parents,
27             "dom_depth": depths,
             "dom_attr_count": attrs,
29             "dom_child_count": children,
         }
31     return out

```

Listing A.5: Aufbereitung von HTML-Text und strukturellen Webseiteninformationen – gekürzter Originalausschnitt

A. Ergänzende Implementierungs- und Prüfdetails

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
   for role, outdir in ROLE_DIRS.items():
3       x = df[df._role.eq(role)].copy()
       if not len(x):
5           continue

       if role == "SSL_POOL":
           x["_ssl_rank"] = x["_ssl_rank"].astype(int)
           x = x.drop(columns=["label"], errors="ignore")

11      x = x.drop(columns=["_role", "_ssl_rank"], errors="ignore")
       x.to_parquet(
13          outdir / f"part-{counters[role]:05d}.parquet",
          index=False,
15          compression="zstd"
       )
17     counters[role] += 1
```

Listing A.6: Physische Entfernung der Klassenlabels aus dem SSL-Pool

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
   def freeze_last(model, n):
3       for p in model.parameters():
           p.requires_grad = False

5
       layers = getattr(
7           getattr(model, "encoder", None),
           "layer",
9           None
       )
11      if layers is None:
           layers = getattr(
13               getattr(model, "transformer", None),
                   "layer",
15               None
           )
17      if layers is None:
           raise RuntimeError(type(model))
19
       for layer in layers[-n:]:
21           for p in layer.parameters():
               p.requires_grad = True
23
       if getattr(model, "pooler", None) is not None:
25           for p in model.pooler.parameters():
               p.requires_grad = True
```

Listing A.7: Partielle Freigabe der Transformerencoder

A. Ergänzende Implementierungs- und Prüfdetails

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
2 class DOMEncoder(nn.Module):
3     def __init__(self):
4         super().__init__()
5         self.tag = nn.Embedding(len(DOM_VOCAB), 96, padding_idx=PAD)
6         self.depth = nn.Embedding(32, 16)
7         self.attr = nn.Embedding(32, 8)
8         self.child = nn.Embedding(32, 8)
9         self.inp = nn.Linear(128, DOM_DIM)
10        self.layers = nn.ModuleList(
11            [GCNLayer(DOM_DIM) for _ in range(DOM_LAYERS)]
12        )
13        self.att = nn.Linear(DOM_DIM, 1)
14
15    def nodes(self, g):
16        x = self.inp(torch.cat([
17            self.tag(g["tag"]), self.depth(g["depth"]),
18            self.attr(g["attr"]), self.child(g["child"])
19        ], 1))
20
21        for layer in self.layers:
22            x = layer(x, g["edge"])
23        return x
```

Listing A.8: GCN-basierte Repräsentation des statischen DOM – gekürzter Originalausschnitt

```
1 # KI-Unterstützung: siehe KI-Erklärung der Arbeit.
2 logits = m(g)
3 mask = g["mask"]
4 if mask.any():
5     loss = F.cross_entropy(
6         logits[mask],
7         g["orig"][mask]
8     )
9     opt.zero_grad(set_to_none=True)
10    loss.backward()
11    torch.nn.utils.clip_grad_norm_(
12        m.parameters(), 1
13    )
14    opt.step()
```

Listing A.9: Rekonstruktionsverlust des DOM-SSL – gekürzter Originalausschnitt aus dem Trainingsloop

```

# KI-Unterstützung: siehe KI-Erklärung der Arbeit.
2 class DeepFusion(nn.Module):
    def __init__(self, use_dom):
4         super().__init__()
        self.gate = nn.Sequential(
6             nn.Linear(PROJ_DIM, 64),
            nn.GELU(),
8             nn.Linear(64, 1)
        )

10
        nm = 3 if use_dom else 2
12        self.head = nn.Sequential(
            nn.Linear(PROJ_DIM * (nm + 1), 512),
14            nn.GELU(),
            nn.Dropout(.2),
16            nn.Linear(512, 128),
            nn.GELU(),
18            nn.Linear(128, 1)
        )

20
    def forward(self, u, t, g=None):
22        zs = self.encode(u, t, g)
        st = torch.stack(zs, 1)
24        gw = torch.softmax(self.gate(st).squeeze(-1), 1)
        weighted = (st * gw[:, :, None]).sum(1)
26        main = self.head(
            torch.cat(zs + [weighted], 1)
28        ).squeeze(-1)
        return main, gw

```

Listing A.10: Kern der multimodalen DUAL-/TRI-Fusion – gekürzter Architekturausschnitt

A.2. Reproduktionsumfang

Die digitale Fassung enthält die Ergebnisdateien der Primäranalysen, getrennte ergänzende Versuchsblöcke und die beim abschließenden Review verwendeten Prüfskripte. `empirical_audit.py` rekonstruiert die aggregierten Kennzahlen und statistischen Entscheidungen; `raw_score_audit.py` prüft Vorhersagescores gegen wiedergewonnene Testlabels, reproduziert die stratifzierten Bootstrap-Intervalle und trainiert die externen Linear-Probes auf den gespeicherten Repräsentationen neu.

Die Neutrainings verwenden unveränderte Auswahlhashes und Modellvorgaben. Sie ersetzen keine Wiederholung des selbstüberwachten Encodertrainings. Einzelne Rangmetriken können bei einer erneuten Optimierung numerisch abweichen; die Differenzen zu den historischen Exporten werden im beigegeführten Prüfbericht ausgewiesen. Die Latenz- und Durchsatzprüfung kann nur die exportierten Messaggregate, deren Rechenbeziehungen und den Messcode nachvollziehen, da die einzelnen Zeitmessungen nicht exportiert wurden.